

# Inferência estatística frequentista

Prof. Bartolomeu Zamprogno

Departamento de Estatística  
Centro de Ciências Exatas  
Universidade Federal do Espírito Santo

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Interesse: como uma variável se comporta em determinada população;

# Introdução

- Interesse: como uma variável se comporta em determinada população;
- Problema: o acesso a população por completo é inviável ou impossível;

# Introdução

- Interesse: como uma variável se comporta em determinada população;
- Problema: o acesso a população por completo é inviável ou impossível;
- A distribuição verdadeira da variável é desconhecida;


- Interesse: como uma variável se comporta em determinada população;
- Problema: o acesso a população por completo é inviável ou impossível;
- A distribuição verdadeira da variável é desconhecida;
- Solução:
  - ▶ propor um modelo probabilístico dependente de um, ou mais, parâmetros;

- Interesse: como uma variável se comporta em determinada população;
- Problema: o acesso a população por completo é inviável ou impossível;
- A distribuição verdadeira da variável é desconhecida;
- Solução:
  - ▶ propor um modelo probabilístico dependente de um, ou mais, parâmetros;
  - ▶ através de uma amostra **estimar** e **testar hipóteses** com respeito a esse(s) parâmetro(s).



# Exemplo 1


- Seja  $X$  a resistência a tensão de um componente utilizado em um chassi de automóvel;
- Suponha que  $n$  observações de  $X$  foram feitas e forneceram os valores  $x_1, x_2, \dots, x_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?

# Exemplo 1


- Seja  $X$  a resitência a tensão de um componente utilizado em um chassi de automóvel;
- Suponha que  $n$  observações de  $X$  foram feitas e forneceram os valores  $x_1, x_2, \dots, x_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?
- O modelo  $N(\mu, \sigma^2)$  parece ser adequado!

# Exemplo 1


- Seja  $X$  a resitência a tensão de um componente utilizado em um chassi de automóvel;
- Suponha que  $n$  observações de  $X$  foram feitas e forneceram os valores  $x_1, x_2, \dots, x_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?
- O modelo  $N(\mu, \sigma^2)$  parece ser adequado!
- Quais valores de  $\mu$  e  $\sigma^2$  são apropriados?

# Exemplo 1


- Seja  $X$  a resistência a tensão de um componente utilizado em um chassi de automóvel;
- Suponha que  $n$  observações de  $X$  foram feitas e forneceram os valores  $x_1, x_2, \dots, x_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?
- O modelo  $N(\mu, \sigma^2)$  parece ser adequado!
- Quais valores de  $\mu$  e  $\sigma^2$  são apropriados?
- Estimar  $\mu$  e  $\sigma^2$ !

## Exemplo 2


- Seja  $T$  o tempo de cura de um paciente com determinada doença após a administração de determinado medicamento.;
- Suponha que  $n$  observações de  $T$  foram feitas e forneceram os valores  $t_1, t_2, \dots, t_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?

## Exemplo 2


- Seja  $T$  o tempo de cura de um paciente com determinada doença após a administração de determinado medicamento.;
- Suponha que  $n$  observações de  $T$  foram feitas e forneceram os valores  $t_1, t_2, \dots, t_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?
- O modelo  $Exp(\lambda)$  parece ser adequado!

## Exemplo 2


- Seja  $T$  o tempo de cura de um paciente com determinada doença após a administração de determinado medicamento.;
- Suponha que  $n$  observações de  $T$  foram feitas e forneceram os valores  $t_1, t_2, \dots, t_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?
- O modelo  $Exp(\lambda)$  parece ser adequado!
- Qual valor de  $\lambda$  é apropriado?

## Exemplo 2

- Seja  $T$  o tempo de cura de um paciente com determinada doença após a administração de determinado medicamento.;
- Suponha que  $n$  observações de  $T$  foram feitas e forneceram os valores  $t_1, t_2, \dots, t_n$ ;
- O histograma das observações realizadas é apresentado abaixo:



- Qual modelo probabilístico conjecturar para esses dados?
- O modelo  $Exp(\lambda)$  parece ser adequado!
- Qual valor de  $\lambda$  é apropriado?
- Estimar  $\lambda$ !



# Diferenças entre estatística descritiva e inferencial

## Estatística descritiva

- Os dados já foram observados (pós-experimental);

# Diferenças entre estatística descritiva e inferencial

## Estatística descritiva

- Os dados já foram observados (pós-experimental);
- As ferramentas não permitem a extrapolação dos resultados para toda a população.

# Diferenças entre estatística descritiva e inferencial

## Estatística descritiva

- Os dados já foram observados (pós-experimental);
- As ferramentas não permitem a extrapolação dos resultados para toda a população.

## Inferência estatística

- Raciocínio pré-experimental, estabelecendo um modelo para as observações (como se os dados não tivessem sido observados);

# Diferenças entre estatística descritiva e inferencial

## Estatística descritiva

- Os dados já foram observados (pós-experimental);
- As ferramentas não permitem a extrapolação dos resultados para toda a população.

## Inferência estatística

- Raciocínio pré-experimental, estabelecendo um modelo para as observações (como se os dados não tivessem sido observados);
- Os resultados obtidos podem ser extrapolados e fornecerem conclusões para toda a população.

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Seja  $X$  v.a. com distribuição de probabilidades  $f$  (função de probabilidades se  $X$  é discreta e função de densidade se  $X$  é contínua);

# Parâmetros

- Seja  $X$  v.a. com distribuição de probabilidades  $f$  (função de probabilidades se  $X$  é discreta e função de densidade se  $X$  é contínua);
- Um **parâmetro** é qualquer quantidade **constante** que dependa de  $f$ .

## Exemplos:



- Seja  $X$  v.a. com distribuição de probabilidades  $f$  (função de probabilidades se  $X$  é discreta e função de densidade se  $X$  é contínua);
- Um **parâmetro** é qualquer quantidade **constante** que dependa de  $f$ .

## Exemplos:

- A probabilidade de sucesso  $p$  de um ensaio de Bernoulli;

- Seja  $X$  v.a. com distribuição de probabilidades  $f$  (função de probabilidades se  $X$  é discreta e função de densidade se  $X$  é contínua);
- Um **parâmetro** é qualquer quantidade **constante** que dependa de  $f$ .

## Exemplos:

- A probabilidade de sucesso  $p$  de um ensaio de Bernoulli;
- O valor esperado  $\mu = E(X)$  de uma v.a.  $X$ ;

# Parâmetros

- Seja  $X$  v.a. com distribuição de probabilidades  $f$  (função de probabilidades se  $X$  é discreta e função de densidade se  $X$  é contínua);
- Um **parâmetro** é qualquer quantidade **constante** que dependa de  $f$ .

## Exemplos:

- A probabilidade de sucesso  $p$  de um ensaio de Bernoulli;
- O valor esperado  $\mu = E(X)$  de uma v.a.  $X$ ;
- A variância  $\sigma^2 = Var(X)$  de uma v.a.  $X$ ;

- Seja  $X$  v.a. com distribuição de probabilidades  $f$  (função de probabilidades se  $X$  é discreta e função de densidade se  $X$  é contínua);
- Um **parâmetro** é qualquer quantidade **constante** que dependa de  $f$ .

## Exemplos:

- A probabilidade de sucesso  $p$  de um ensaio de Bernoulli;
- O valor esperado  $\mu = E(X)$  de uma v.a.  $X$ ;
- A variância  $\sigma^2 = Var(X)$  de uma v.a.  $X$ ;
- A taxa de ocorrências  $\lambda$  de uma Poisson;

- Seja  $X$  v.a. com distribuição de probabilidades  $f$  (função de probabilidades se  $X$  é discreta e função de densidade se  $X$  é contínua);
- Um **parâmetro** é qualquer quantidade **constante** que dependa de  $f$ .

## Exemplos:

- A probabilidade de sucesso  $p$  de um ensaio de Bernoulli;
- O valor esperado  $\mu = E(X)$  de uma v.a.  $X$ ;
- A variância  $\sigma^2 = Var(X)$  de uma v.a.  $X$ ;
- A taxa de ocorrências  $\lambda$  de uma Poisson;
- O mínimo  $a$  e o máximo  $b$  de uma v.a.  $X \sim U[a, b]$ .

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- A população não pode ser completamente observada;

- A população não pode ser completamente observada;
- Embora constantes, os parâmetros são desconhecidos!



- A população não pode ser completamente observada;
- Embora constantes, os parâmetros são desconhecidos!
- Uma **amostra** pode ser utilizada para aproximar os parâmetros;

- A população não pode ser completamente observada;
- Embora constantes, os parâmetros são desconhecidos!
- Uma **amostra** pode ser utilizada para aproximar os parâmetros;
- Uma amostra selecionada por conveniência pode acarretar os seguintes problemas:

- A população não pode ser completamente observada;
- Embora constantes, os parâmetros são desconhecidos!
- Uma **amostra** pode ser utilizada para aproximar os parâmetros;
- Uma amostra selecionada por conveniência pode acarretar os seguintes problemas:
  - ▶ resultados tendenciosos;

- A população não pode ser completamente observada;
- Embora constantes, os parâmetros são desconhecidos!
- Uma **amostra** pode ser utilizada para aproximar os parâmetros;
- Uma amostra selecionada por conveniência pode acarretar os seguintes problemas:
  - ▶ resultados tendenciosos;
  - ▶ o comportamento probabilístico desconhecido;

- A população não pode ser completamente observada;
- Embora constantes, os parâmetros são desconhecidos!
- Uma **amostra** pode ser utilizada para aproximar os parâmetros;
- Uma amostra selecionada por conveniência pode acarretar os seguintes problemas:
  - ▶ resultados tendenciosos;
  - ▶ o comportamento probabilístico desconhecido;
- Necessidade de uma amostra representativa;

- A população não pode ser completamente observada;
- Embora constantes, os parâmetros são desconhecidos!
- Uma **amostra** pode ser utilizada para aproximar os parâmetros;
- Uma amostra selecionada por conveniência pode acarretar os seguintes problemas:
  - ▶ resultados tendenciosos;
  - ▶ o comportamento probabilístico desconhecido;
- Necessidade de uma amostra representativa;
- Principal solução → mecanismo aleatório para selecionar a amostra.

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

## Definição

*Seja  $X$  uma v.a. Uma amostra aleatória (a.a.) de  $X$  é um conjunto de observações independentes entre si e com a mesma distribuição de  $X$ .*



## Definição

*Seja  $X$  uma v.a. Uma amostra aleatória (a.a.) de  $X$  é um conjunto de observações independentes entre si e com a mesma distribuição de  $X$ .*

- Uma a.a. é caracterizada pré-experimentalmente;

## Definição

*Seja  $X$  uma v.a. Uma amostra aleatória (a.a.) de  $X$  é um conjunto de observações independentes entre si e com a mesma distribuição de  $X$ .*

- Uma a.a. é caracterizada pré-experimentalmente;
- As observações ainda não foram coletadas;

## Definição

*Seja  $X$  uma v.a. Uma amostra aleatória (a.a.) de  $X$  é um conjunto de observações independentes entre si e com a mesma distribuição de  $X$ .*

- Uma a.a. é caracterizada pré-experimentalmente;
- As observações ainda não foram coletadas;
- Portanto, uma a.a. é um conjunto de **v.a.**;

## Definição

*Seja  $X$  uma v.a. Uma amostra aleatória (a.a.) de  $X$  é um conjunto de observações independentes entre si e com a mesma distribuição de  $X$ .*

- Uma a.a. é caracterizada pré-experimentalmente;
- As observações ainda não foram coletadas;
- Portanto, uma a.a. é um conjunto de **v.a.**;
- Uma a.a. de  $X$  de tamanho  $n$  é denotada  $X_1, \dots, X_n$ .

## Definição

*Seja  $X$  uma v.a. Uma amostra aleatória (a.a.) de  $X$  é um conjunto de observações independentes entre si e com a mesma distribuição de  $X$ .*

- Uma a.a. é caracterizada pré-experimentalmente;
- As observações ainda não foram coletadas;
- Portanto, uma a.a. é um conjunto de **v.a.**;
- Uma a.a. de  $X$  de tamanho  $n$  é denotada  $X_1, \dots, X_n$ .

**Exercício:** Em uma população de  $N$  indivíduos,  $K$  possuem determinada característica. Suponha que desejamos selecionar  $n$  indivíduos para inferir sobre a verdadeira proporção  $K/N$  de indivíduos com essa característica. Uma a.a. seria obtida se realizássemos o sorteio dos indivíduos com ou sem reposição?

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Exemplo

Considere um experimento de Bernoulli com probabilidade de sucesso  $p$  (desconhecida) e seja  $X$  a v.a. que associa o valor 1 se esse experimento resulta sucesso e 0 caso contrário. Dizemos que  $X$  é uma v.a. de Bernoulli com parâmetro  $p$  e escrevemos  $X \sim Ber(p)$ . Note que também temos  $X \sim B(1, p)$ .

# Exemplo

Considere um experimento de Bernoulli com probabilidade de sucesso  $p$  (desconhecida) e seja  $X$  a v.a. que associa o valor 1 se esse experimento resulta sucesso e 0 caso contrário. Dizemos que  $X$  é uma v.a. de Bernoulli com parâmetro  $p$  e escrevemos  $X \sim Ber(p)$ . Note que também temos  $X \sim B(1, p)$ .

- Como tirar conclusões sobre a probabilidade de sucesso  $p$ ?



# Exemplo

Considere um experimento de Bernoulli com probabilidade de sucesso  $p$  (desconhecida) e seja  $X$  a v.a. que associa o valor 1 se esse experimento resulta sucesso e 0 caso contrário. Dizemos que  $X$  é uma v.a. de Bernoulli com parâmetro  $p$  e escrevemos  $X \sim Ber(p)$ . Note que também temos  $X \sim B(1, p)$ .

- Como tirar conclusões sobre a probabilidade de sucesso  $p$ ?
- Podemos coletar uma a.a.  $X_1, \dots, X_n$  de  $X$ ;

# Exemplo

Considere um experimento de Bernoulli com probabilidade de sucesso  $p$  (desconhecida) e seja  $X$  a v.a. que associa o valor 1 se esse experimento resulta sucesso e 0 caso contrário. Dizemos que  $X$  é uma v.a. de Bernoulli com parâmetro  $p$  e escrevemos  $X \sim Ber(p)$ . Note que também temos  $X \sim B(1, p)$ .

- Como tirar conclusões sobre a probabilidade de sucesso  $p$ ?
- Podemos coletar uma a.a.  $X_1, \dots, X_n$  de  $X$ ;
- Após coletar a amostra podemos calcular a **proporção amostral**  $\hat{p}$ ;

# Exemplo

Considere um experimento de Bernoulli com probabilidade de sucesso  $p$  (desconhecida) e seja  $X$  a v.a. que associa o valor 1 se esse experimento resulta sucesso e 0 caso contrário. Dizemos que  $X$  é uma v.a. de Bernoulli com parâmetro  $p$  e escrevemos  $X \sim Ber(p)$ . Note que também temos  $X \sim B(1, p)$ .

- Como tirar conclusões sobre a probabilidade de sucesso  $p$ ?
- Podemos coletar uma a.a.  $X_1, \dots, X_n$  de  $X$ ;
- Após coletar a amostra podemos calcular a **proporção amostral**  $\hat{p}$ ;
- Podemos usar o valor que  $\hat{p}$  **fornecerá** como aproximação de  $p$ ;

# Exemplo

Considere um experimento de Bernoulli com probabilidade de sucesso  $p$  (desconhecida) e seja  $X$  a v.a. que associa o valor 1 se esse experimento resulta sucesso e 0 caso contrário. Dizemos que  $X$  é uma v.a. de Bernoulli com parâmetro  $p$  e escrevemos  $X \sim Ber(p)$ . Note que também temos  $X \sim B(1, p)$ .

- Como tirar conclusões sobre a probabilidade de sucesso  $p$ ?
- Podemos coletar uma a.a.  $X_1, \dots, X_n$  de  $X$ ;
- Após coletar a amostra podemos calcular a **proporção amostral**  $\hat{p}$ ;
- Podemos usar o valor que  $\hat{p}$  **fornecerá** como aproximação de  $p$ ;
- Mas, antes de observar a a.a.,  $\hat{p}$  é v.a., pois é função de v.a.'s;

# Exemplo

Considere um experimento de Bernoulli com probabilidade de sucesso  $p$  (desconhecida) e seja  $X$  a v.a. que associa o valor 1 se esse experimento resulta sucesso e 0 caso contrário. Dizemos que  $X$  é uma v.a. de Bernoulli com parâmetro  $p$  e escrevemos  $X \sim Ber(p)$ . Note que também temos  $X \sim B(1, p)$ .

- Como tirar conclusões sobre a probabilidade de sucesso  $p$ ?
- Podemos coletar uma a.a.  $X_1, \dots, X_n$  de  $X$ ;
- Após coletar a amostra podemos calcular a **proporção amostral**  $\hat{p}$ ;
- Podemos usar o valor que  $\hat{p}$  **fornecerá** como aproximação de  $p$ ;
- Mas, antes de observar a a.a.,  $\hat{p}$  é v.a., pois é função de v.a.'s;
- Como dizer se  $\hat{p}$  será uma boa aproximação para  $p$  sem conhecer  $p$  (e antes de observar a amostra)?

## Definição

Sejam  $X$  v.a. cuja distribuição depende de um parâmetro  $\theta$  e  $X_1, \dots, X_n$  a.a. de tamanho  $n$  de  $X$ . Um **estimador**  $\hat{\theta}$  de  $\theta$  é qualquer função da amostra  $X_1, \dots, X_n$  utilizada para aproximar (estimar) o valor de  $\theta$ . Isto é,

$$\hat{\theta} = \hat{\theta}(X_1, \dots, X_n).$$

- Suponha que a amostra observada (ponto amostral) foi  $x_1, \dots, x_n$ , isto é, que

$$X_1 = x_1, \dots, X_n = x_n.$$

A realização de  $\hat{\theta}$ ,  $\hat{\theta}(x_1, \dots, x_n)$ , é denominada **estimativa**.

# Exemplos de estimadores

Dada uma a.a.  $X_1, \dots, X_n$ , alguns exemplos de estimadores são:

- O total  $\sum_{i=1}^n X_i$ ;

# Exemplos de estimadores

Dada uma a.a.  $X_1, \dots, X_n$ , alguns exemplos de estimadores são:

- O total  $\sum_{i=1}^n X_i$ ;
- A média  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ;



# Exemplos de estimadores

Dada uma a.a.  $X_1, \dots, X_n$ , alguns exemplos de estimadores são:

- O total  $\sum_{i=1}^n X_i$ ;
- A média  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ;
- A variância (viciada)  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ ;

# Exemplos de estimadores

Dada uma a.a.  $X_1, \dots, X_n$ , alguns exemplos de estimadores são:

- O total  $\sum_{i=1}^n X_i$ ;
- A média  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ;
- A variância (viciada)  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ ;
- A variância (não viciada)  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ;

# Exemplos de estimadores

Dada uma a.a.  $X_1, \dots, X_n$ , alguns exemplos de estimadores são:

- O total  $\sum_{i=1}^n X_i$ ;
- A média  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ;
- A variância (viciada)  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ ;
- A variância (não viciada)  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ;
- O mínimo  $X_{(1)} = \min\{X_1, \dots, X_n\}$ ;

# Exemplos de estimadores

Dada uma a.a.  $X_1, \dots, X_n$ , alguns exemplos de estimadores são:

- O total  $\sum_{i=1}^n X_i$ ;
- A média  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ;
- A variância (viciada)  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ ;
- A variância (não viciada)  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ;
- O mínimo  $X_{(1)} = \min\{X_1, \dots, X_n\}$ ;
- O máximo  $X_{(n)} = \max\{X_1, \dots, X_n\}$ ;

# Exemplos de estimadores

Dada uma a.a.  $X_1, \dots, X_n$ , alguns exemplos de estimadores são:

- O total  $\sum_{i=1}^n X_i$ ;
- A média  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ;
- A variância (viciada)  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ ;
- A variância (não viciada)  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ;
- O mínimo  $X_{(1)} = \min\{X_1, \dots, X_n\}$ ;
- O máximo  $X_{(n)} = \max\{X_1, \dots, X_n\}$ ;
- A proporção  $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$  (se a a.a. for de uma v.a. Bernoulli).

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Estimadores  $\rightarrow$  pré-observacional  $\rightarrow$  são v.a.'s;

# Distribuição amostral

- Estimadores  $\rightarrow$  pré-observacional  $\rightarrow$  são v.a.'s;
- Estimadores tem distribuição de probabilidades denominada **distribuição amostral**.



# Distribuição amostral

- Estimadores  $\rightarrow$  pré-observacional  $\rightarrow$  são v.a.'s;
- Estimadores tem distribuição de probabilidades denominada **distribuição amostral**.

## Definição

*Seja  $X$  v.a. com distribuição de probabilidades dependente de um parâmetro  $\theta$ . Seja  $\hat{\theta}$  um estimador de  $\theta$ . A distribuição amostral de  $\hat{\theta}$  é a distribuição de probabilidades da v.a. (estimador)  $\hat{\theta}$ .*

# Distribuição amostral

- Estimadores  $\rightarrow$  pré-observacional  $\rightarrow$  são v.a.'s;
- Estimadores tem distribuição de probabilidades denominada **distribuição amostral**.

## Definição

*Seja  $X$  v.a. com distribuição de probabilidades dependente de um parâmetro  $\theta$ . Seja  $\hat{\theta}$  um estimador de  $\theta$ . A distribuição amostral de  $\hat{\theta}$  é a distribuição de probabilidades da v.a. (estimador)  $\hat{\theta}$ .*

- A distribuição amostral depende principalmente:

# Distribuição amostral

- Estimadores  $\rightarrow$  pré-observacional  $\rightarrow$  são v.a.'s;
- Estimadores tem distribuição de probabilidades denominada **distribuição amostral**.

## Definição

*Seja  $X$  v.a. com distribuição de probabilidades dependente de um parâmetro  $\theta$ . Seja  $\hat{\theta}$  um estimador de  $\theta$ . A distribuição amostral de  $\hat{\theta}$  é a distribuição de probabilidades da v.a. (estimador)  $\hat{\theta}$ .*

- A distribuição amostral depende principalmente:
  - ▶ da distribuição da v.a.  $X$  cuja amostra  $X_1, \dots, X_n$  foi coletada;

# Distribuição amostral

- Estimadores  $\rightarrow$  pré-observacional  $\rightarrow$  são v.a.'s;
- Estimadores tem distribuição de probabilidades denominada **distribuição amostral**.

## Definição

*Seja  $X$  v.a. com distribuição de probabilidades dependente de um parâmetro  $\theta$ . Seja  $\hat{\theta}$  um estimador de  $\theta$ . A distribuição amostral de  $\hat{\theta}$  é a distribuição de probabilidades da v.a. (estimador)  $\hat{\theta}$ .*

- A distribuição amostral depende principalmente:
  - ▶ da distribuição da v.a.  $X$  cuja amostra  $X_1, \dots, X_n$  foi coletada;
  - ▶ do tipo de amostragem realizada.

# Exemplo

Suponha nove indivíduos: dois com nenhum filho; três com um filho; e quatro com dois filhos. Denote  $X$  como o número de filhos de um indivíduo selecionado ao acaso dessa população.

# Exemplo

Suponha nove indivíduos: dois com nenhum filho; três com um filho; e quatro com dois filhos. Denote  $X$  como o número de filhos de um indivíduo selecionado ao acaso dessa população. Temos que a função de probabilidades de  $X$  é dada por:

$X$	0	1	2
$P_X$	$\frac{2}{9}$	$\frac{1}{3}$	$\frac{4}{9}$

# Exemplo

Suponha nove indivíduos: dois com nenhum filho; três com um filho; e quatro com dois filhos. Denote  $X$  como o número de filhos de um indivíduo selecionado ao acaso dessa população. Temos que a função de probabilidades de  $X$  é dada por:

$X$	0	1	2
$P_X$	$\frac{2}{9}$	$\frac{1}{3}$	$\frac{4}{9}$

O valor esperado de  $X$  é  $\mu = E(X) = \frac{11}{9} = 1.22$ .

## Exemplo

Suponha nove indivíduos: dois com nenhum filho; três com um filho; e quatro com dois filhos. Denote  $X$  como o número de filhos de um indivíduo selecionado ao acaso dessa população. Temos que a função de probabilidades de  $X$  é dada por:

$X$	0	1	2
$P_X$	$\frac{2}{9}$	$\frac{1}{3}$	$\frac{4}{9}$

O valor esperado de  $X$  é  $\mu = E(X) = \frac{11}{9} = 1.22$ .

Um pesquisador desconhece a distribuição de  $X$  e o valor de  $\mu$ . Para inferir sobre  $\mu$ , esse pesquisador:

- coletará uma amostra **com reposição** de  $X$  de tamanho  $n = 2$ :  $X_1, X_2$ ;
- utilizará  $\bar{X} = \frac{X_1 + X_2}{2}$  para estimar  $\mu$ .

Encontremos a distribuição amostral de  $\bar{X}$ .



## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
$(0, 0)$	$4/81$	0

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5
(1, 1)	1/9	1

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5
(1, 1)	1/9	1
(1, 2)	4/27	1.5

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5
(1, 1)	1/9	1
(1, 2)	4/27	1.5
(2, 0)	8/81	1

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5
(1, 1)	1/9	1
(1, 2)	4/27	1.5
(2, 0)	8/81	1
(2, 1)	4/27	1.5



## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5
(1, 1)	1/9	1
(1, 2)	4/27	1.5
(2, 0)	8/81	1
(2, 1)	4/27	1.5
(2, 2)	16/81	2
Total	1	-

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5
(1, 1)	1/9	1
(1, 2)	4/27	1.5
(2, 0)	8/81	1
(2, 1)	4/27	1.5
(2, 2)	16/81	2
Total	1	-

Distribuição de  $\bar{X}$  é:

$\bar{X}$	0	0.5	1	1.5	2
$P_{\bar{X}}$	$\frac{4}{81}$	$\frac{4}{27}$	$\frac{25}{81}$	$\frac{8}{27}$	$\frac{16}{81}$

## Exemplo - cont.

A tabela abaixo mostra os possíveis **pontos amostrais**; suas respectivas probabilidades e as estimativas geradas por esses pontos.

$(x_1, x_2)$	$P_{X_1, X_2}(x_1, x_2)$	$\bar{x}$
(0, 0)	4/81	0
(0, 1)	2/27	0.5
(0, 2)	8/81	1
(1, 0)	2/27	0.5
(1, 1)	1/9	1
(1, 2)	4/27	1.5
(2, 0)	8/81	1
(2, 1)	4/27	1.5
(2, 2)	16/81	2
Total	1	-

Distribuição de  $\bar{X}$  é:

$\bar{X}$	0	0.5	1	1.5	2
$P_{\bar{X}}$	$\frac{4}{81}$	$\frac{4}{27}$	$\frac{25}{81}$	$\frac{8}{27}$	$\frac{16}{81}$

O valor esperado de  $\bar{X}$  é:

$$\begin{aligned}\mu_{\bar{X}} &= \frac{2}{27} + \frac{25}{81} + \frac{12}{27} + \frac{32}{81} \\ &= \frac{1}{81}(6 + 25 + 36 + 32) \\ &= \frac{99}{81} = \frac{11}{9} = \mu\end{aligned}$$

**Exercício:** Refaça o exemplo anterior com amostragem **sem** reposição para verificar que a distribuição amostral de  $\bar{X}$  é modificada. Verifique a distribuição amostral de  $S^2$ .

- A diferença na distribuição amostral provocada por amostragem com e sem reposição é menos evidente quando o tamanho da população é grande;
- Esse efeito é nulo para populações infinitas;
- No exemplo anterior a amostragem com reposição fornece uma a.a.;
- De agora em diante consideraremos apenas amostras aleatórias.

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Consistência e distribuição amostral assintótica

## Teorema

(Populações infinitas) Seja  $X_1, \dots, X_n$  a.a. de  $X$ , onde  $E(X) = \mu$  e  $\text{Var}(X) = \sigma^2 < \infty$ . Então  $E(\bar{X}) = \mu$  e  $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ , onde  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  é a média amostral.

## Teorema

(Teorema Central do Limite - TCL) Seja  $X_1, \dots, X_n$  a.a. de  $X$ , onde  $E(X) = \mu$  e  $\text{Var}(X) = \sigma^2 < \infty$ . Então a v.a.

$$Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

tem distribuição aproximadamente normal padrão. A aproximação fica melhor com o aumento de  $n$ .

## Corolário

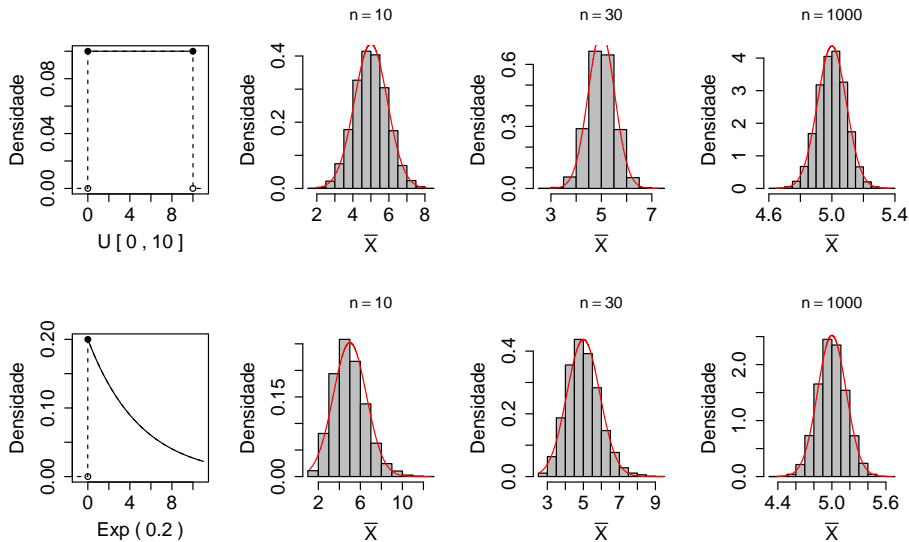
(Populações infinitas) Seja  $X_1, \dots, X_n$  a.a. de  $X \sim \text{Ben}(p)$ . Então, se  $\hat{p}$  for a proporção amostral,

$$Z_n = \frac{\hat{p} - p}{\sqrt{p(1-p)/n}}$$

tem distribuição aproximadamente normal-padrão. A aproximação fica melhor com o aumento de  $n$ .

- A média amostral tem distribuição aproximadamente normal com parâmetros  $\mu$  e  $\frac{\sigma^2}{n}$ ;
- A aproximação se torna melhor com o aumento do tamanho amostral  $n$ ;
- O valor de  $n$  necessário para que a aproximação seja boa depende da distribuição dos dados;
- Dados provenientes de distribuições assimétricas exigem o valor de  $n$  maior.

Número de amostras coletadas: 10000.





## Exemplo

Seja  $T$  o tempo em meses que uma lâmpada produzida por determinada empresa dura até queimar. Suponha que  $T \sim \text{Exp}(\lambda)$ , onde  $\lambda = 0.25$ . Uma sala é iluminada por essa lâmpada. Caso queime uma lâmpada ela é imediatamente trocada. Se há 36 dessas lâmpadas no estoque. Qual a probabilidade que não haja mais lâmpadas em estoque em menos de 9 anos?

Primeiramente:

- $\mu = E(T) = \frac{1}{\lambda} = \frac{1}{0.25} = 4$ ;
- $\sigma^2 = \text{Var}(T) = \frac{1}{\lambda^2} = 16$ .

Portanto, temos que

$$\begin{aligned} P\left(\sum_{i=1}^{36} T_i < 9 \times 12\right) &= P(\bar{T} < 3) = P\left(\frac{\bar{T} - \mu}{\sigma/\sqrt{n}} < \frac{3 - 4}{4/\sqrt{36}}\right) \\ &= P(Z_n < -1.5) \approx P(Z < -1.5) \\ &= 0.05591 \end{aligned}$$

A aproximação acima se deve ao TCL.

## Exemplo

Seja  $T$  o tempo em meses que uma lâmpada produzida por determinada empresa dura até queimar. Suponha que  $T \sim \text{Exp}(\lambda)$ , onde  $\lambda = 0.25$ . Uma sala é iluminada por essa lâmpada. Caso queime uma lâmpada ela é imediatamente trocada. Se há 36 dessas lâmpadas no estoque. Qual a probabilidade que não haja mais lâmpadas em estoque em menos de 9 anos?

Primeiramente:

- $\mu = E(T) = \frac{1}{\lambda} = \frac{1}{0.25} = 4$ ;
- $\sigma^2 = \text{Var}(T) = \frac{1}{\lambda^2} = 16$ .

Portanto, temos que

$$\begin{aligned} P\left(\sum_{i=1}^{36} T_i < 9 \times 12\right) &= P(\bar{T} < 3) = P\left(\frac{\bar{T} - \mu}{\sigma/\sqrt{n}} < \frac{3 - 4}{4/\sqrt{36}}\right) \\ &= P(Z_n < -1.5) \approx P(Z < -1.5) \\ &= 0.05591 \end{aligned}$$

A aproximação acima se deve ao TCL. A probabilidade exata é 0.05588.

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

Podemos dividir a tarefa de estimação de parâmetros em:

- Estimação pontual:
  - ▶ lida com a avaliação do desempenho de um estimador;
- Estimação intervalar:
  - ▶ lida com a construção de intervalos que englobam a variabilidade do estimador no processo de estimação.

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;

# Estimação pontual

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;
- Um estimador de  $\theta$  é qualquer função de  $X_1, \dots, X_n$  utilizada para aproximar o valor de  $\theta$ ;

# Estimação pontual

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;
- Um estimador de  $\theta$  é qualquer função de  $X_1, \dots, X_n$  utilizada para aproximar o valor de  $\theta$ ;
- Assim sendo, é possível definir diversos estimadores para um determinado parâmetro;



# Estimação pontual

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;
- Um estimador de  $\theta$  é qualquer função de  $X_1, \dots, X_n$  utilizada para aproximar o valor de  $\theta$ ;
- Assim sendo, é possível definir diversos estimadores para um determinado parâmetro;
- Como avaliar a qualidade desses estimadores?

# Estimação pontual

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;
- Um estimador de  $\theta$  é qualquer função de  $X_1, \dots, X_n$  utilizada para aproximar o valor de  $\theta$ ;
- Assim sendo, é possível definir diversos estimadores para um determinado parâmetro;
- Como avaliar a qualidade desses estimadores?
- Resposta:

# Estimação pontual

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;
- Um estimador de  $\theta$  é qualquer função de  $X_1, \dots, X_n$  utilizada para aproximar o valor de  $\theta$ ;
- Assim sendo, é possível definir diversos estimadores para um determinado parâmetro;
- Como avaliar a qualidade desses estimadores?
- Resposta:
  - ▶ Vício;

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;
- Um estimador de  $\theta$  é qualquer função de  $X_1, \dots, X_n$  utilizada para aproximar o valor de  $\theta$ ;
- Assim sendo, é possível definir diversos estimadores para um determinado parâmetro;
- Como avaliar a qualidade desses estimadores?
- Resposta:
  - ▶ Vício;
  - ▶ Erro-padrão;

- Sejam  $X$  v.a.,  $X_1, \dots, X_n$  uma a.a. de  $X$  e  $\theta$  um parâmetro;
- Um estimador de  $\theta$  é qualquer função de  $X_1, \dots, X_n$  utilizada para aproximar o valor de  $\theta$ ;
- Assim sendo, é possível definir diversos estimadores para um determinado parâmetro;
- Como avaliar a qualidade desses estimadores?
- Resposta:
  - ▶ Vício;
  - ▶ Erro-padrão;
  - ▶ Erro Quadrático Médio (EQM).

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Deve ser **esperado** de um bom estimador que ele forneça o verdadeiro valor do parâmetro;

- Deve ser **esperado** de um bom estimador que ele forneça o verdadeiro valor do parâmetro;
- O vício de um estimador mede, em média, quanto o estimador se distancia do parâmetro.



- Deve ser **esperado** de um bom estimador que ele forneça o verdadeiro valor do parâmetro;
- O vício de um estimador mede, em média, quanto o estimador se distancia do parâmetro.

## Definição

*Seja  $\theta$  um parâmetro e  $\hat{\theta}$  um estimador de  $\theta$ . O vício (ou viés) de  $\hat{\theta}$  é definido por*

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta = \mu_{\hat{\theta}} - \theta,$$

*onde  $\mu_{\hat{\theta}} = E(\hat{\theta})$  é o valor esperado de  $\hat{\theta}$ .*

- Deve ser **esperado** de um bom estimador que ele forneça o verdadeiro valor do parâmetro;
- O vício de um estimador mede, em média, quanto o estimador se distancia do parâmetro.


## Definição

*Seja  $\theta$  um parâmetro e  $\hat{\theta}$  um estimador de  $\theta$ . O vício (ou viés) de  $\hat{\theta}$  é definido por*

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta = \mu_{\hat{\theta}} - \theta,$$

*onde  $\mu_{\hat{\theta}} = E(\hat{\theta})$  é o valor esperado de  $\hat{\theta}$ .*

- Dizemos que  $\hat{\theta}$  é não viciado (ou não viesado) se seu vício  $B(\hat{\theta}) = 0$ .



$\hat{\theta}_V$  não viciado

$\hat{\theta}_A$  viciado

# Exemplo 1

Suponha que serão observadas  $n - 1 \geq 1$  observações  $X_1, \dots, X_{n-1}$  de  $X$ , com  $\mu = E(X)$ . Defina a média dessas  $n - 1$  observações por  $\bar{X}_{n-1} = \frac{1}{n-1} \sum_{i=1}^{n-1} X_i$ . Suponha que uma nova observação  $X_n$  ficará disponível. Considere os seguintes estimadores de  $\mu$ :

$$\hat{\mu}_1 = \frac{n-1}{n} \bar{X}_{n-1} + \frac{1}{n} X_n \quad \text{e} \quad \hat{\mu}_2 = \frac{\bar{X}_{n-1} + X_n}{2}.$$

Qual deles é não viciado?

Temos que

$$E(\hat{\mu}_1) = \frac{n-1}{n} E(\bar{X}_{n-1}) + \frac{1}{n} E(X_n) = \frac{n-1}{n} \mu + \frac{1}{n} \mu = \mu$$

e

$$E(\hat{\mu}_2) = \frac{E(\bar{X}_{n-1} + X_n)}{2} = \frac{E(\bar{X}_{n-1}) + E(X_n)}{2} = \frac{\mu + \mu}{2} = \mu.$$

Portanto, ambos são não viesados.

## Exemplo 2

O estimador  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  é viciado para estimar  $\sigma^2$ ! De fato,

$$\begin{aligned} E(\hat{\sigma}^2) &= \frac{1}{n} \sum_{i=1}^n E[(X_i - \bar{X})^2] = \frac{1}{n} \sum_{i=1}^n E[(X_i - \mu - (\bar{X} - \mu))^2] \\ &= \frac{1}{n} \sum_{i=1}^n E[(X_i - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu) + (\bar{X} - \mu)^2] \\ &= \frac{1}{n} \sum_{i=1}^n \left\{ \sigma^2 - 2E \left[ (X_i - \mu) \left( \frac{1}{n} \sum_j (X_j - \mu) \right) \right] + E[(\bar{X} - \mu)^2] \right\} \\ &= \frac{1}{n} \sum_{i=1}^n \left\{ \sigma^2 - \frac{2}{n} \sum_j E[(X_i - \mu)(X_j - \mu)] + \frac{\sigma^2}{n} \right\} \\ &= \frac{1}{n} \sum_{i=1}^n \left\{ \sigma^2 - \frac{2\sigma^2}{n} + \frac{\sigma^2}{n} \right\} = \sigma^2 - \frac{\sigma^2}{n} \end{aligned}$$

# Exercício

Tendo em vista o exemplo anterior, mostre que  $S^2$  é um estimador **não** viesado de  $\sigma^2$ .

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Erro-padrão

- Estimadores são v.a.;
- Além do vício, é importante saber a sua variabilidade;
- Podemos comparar dois estimadores não viesados pelo seu **Erro-padrão**.

## Definição


*Seja  $\hat{\theta}$  estimador de  $\theta$ . Denominamos erro-padrão de  $\hat{\theta}$  o desvio-padrão de  $\hat{\theta}$ . Notação:  $EP(\hat{\theta}) = \sqrt{Var(\hat{\theta})}$ .*

## Definição

*Sejam  $\hat{\theta}_1$  e  $\hat{\theta}_2$  estimadores não viesados de  $\theta$ . Dizemos que  $\hat{\theta}_1$  é mais eficiente que  $\hat{\theta}_2$  se  $EP(\hat{\theta}_1) < EP(\hat{\theta}_2)$ .*



$\hat{\theta}_V$  mais eficiente que  $\hat{\theta}_A$



## Exemplo 1 - cont.

Verifiquemos o Erro-padrão de  $\hat{\mu}_1$  e de  $\hat{\mu}_2$ . Temos que

$$\begin{aligned} \text{Var}(\hat{\mu}_1) &= \text{Var}\left(\frac{n-1}{n}\bar{X}_{n-1} + \frac{1}{n}X_n\right) = \left(\frac{n-1}{n}\right)^2 \frac{\sigma^2}{n-1} + \frac{1}{n^2}\sigma^2 \\ &= \frac{n-1+1}{n^2}\sigma^2 = \frac{1}{n}\sigma^2 \end{aligned}$$

e

$$\begin{aligned} \text{Var}(\hat{\mu}_2) &= \text{Var}\left(\frac{\bar{X}_{n-1} + x_n}{2}\right) = \frac{1}{4}(\text{Var}(\bar{X}_{n-1}) + \text{Var}(X_n)) \\ &= \frac{1}{4}\left(\frac{\sigma^2}{n-1} + \sigma^2\right) = \frac{n}{4(n-1)}\sigma^2 \end{aligned}$$

Vejamos quando  $\hat{\mu}_1$  é mais eficiente do que  $\hat{\mu}_2$ . De fato,

$$\begin{aligned} \text{Var}(\hat{\mu}_1) < \text{Var}(\hat{\mu}_2) &\Rightarrow \frac{\sigma^2}{n} < \frac{n\sigma^2}{4(n-1)} \Rightarrow n^2 - 4n + 4 > 0 \\ &\Rightarrow (n-2)^2 > 0 \Rightarrow n \neq 2 \Rightarrow n > 2. \end{aligned}$$

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Como comparar estimadores que tenham vícios diferentes?

# Erro Quadrático Médio

- Como comparar estimadores que tenham vícios diferentes?
- Reposta: Erro quadrático médio!

## Definição

Seja  $\hat{\theta}$  estimador de  $\theta$ . Definimos o Erro Quadrático Médio (EQM) de  $\hat{\theta}$  por

$$EQM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2].$$

**Exercício:** Mostre que o EQM pode ser escrito como a soma do vício e da variância do estimador, isto é,

$$EQM(\hat{\theta}) = [B(\hat{\theta})]^2 + Var(\hat{\theta})$$

## Exemplo 2 - cont.

No Exemplo 2, mostramos que  $B(\hat{\sigma}^2) = -\frac{\sigma^2}{n}$ . É possível mostrar que  $B(S^2) = 0$  e que (se  $X \sim N(\mu, \sigma^2)$ ):

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1} \quad \text{e} \quad \text{Var}(\hat{\sigma}^2) = \left(\frac{n-1}{n}\right)^2 \frac{2\sigma^4}{n-1}.$$

Logo, os EQM's de  $S^2$  e de  $\hat{\sigma}^2$  são, respectivamente,

$$\text{EQM}(S^2) = \frac{2\sigma^4}{n-1} \quad \text{e} \quad \text{EQM}(\hat{\sigma}^2) = \left(\frac{\sigma^2}{n}\right)^2 + \frac{(n-1)2\sigma^4}{n^2} = \frac{2\sigma^4}{n} - \frac{\sigma^4}{n^2}$$

Logo, em termos de EQM, vemos que  $\hat{\sigma}^2$  é melhor do que  $S^2$ .

## Definição


Seja  $\hat{\theta}$  um estimador do parâmetro  $\theta$ . Dizemos que  $\hat{\theta}$  é **consistente** se seu EQM tende a zero quando o tamanho da amostra tende a infinito. Isto é, se

$$\lim_{n \rightarrow \infty} EQM(\hat{\theta}) = 0$$

- A definição acima implica que  $\hat{\theta}$  é consistente se seu vício e sua variância tendem a 0;
- Em poucas palavras, quando um estimador é consistente suas estimativas tendem a ser próximas do verdadeiro valor do parâmetro

## Distribuição amostral de um estimador consistente com

$$n < n < n$$





# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Estimação intervalar

- Mesmo que o estimador tenha boas características, é possível que a estimativa fornecida seja muito diferente do parâmetro;

# Estimação intervalar

- Mesmo que o estimador tenha boas características, é possível que a estimativa fornecida seja muito diferente do parâmetro;
- Esse problema pode ser catastrófico caso o estimador tenha grande variabilidade;

# Estimação intervalar

- Mesmo que o estimador tenha boas características, é possível que a estimativa fornecida seja muito diferente do parâmetro;
- Esse problema pode ser catastrófico caso o estimador tenha grande variabilidade;
- Idéia: através de intervalos incorporar a variabilidade do estimador no processo de estimação.

# Estimação intervalar

- Mesmo que o estimador tenha boas características, é possível que a estimativa fornecida seja muito diferente do parâmetro;
- Esse problema pode ser catastrófico caso o estimador tenha grande variabilidade;
- Idéia: através de intervalos incorporar a variabilidade do estimador no processo de estimação.

## Definição

*Seja  $\theta$  um parâmetro e  $\hat{\theta}$  um estimador de  $\theta$ . Um Intervalo de Confiança (IC) para  $\theta$  com coeficiente de confiança  $\gamma$  é qualquer intervalo  $[Li(\hat{\theta}); Ls(\hat{\theta})]$  tal que*

$$P\left([Li(\hat{\theta}); Ls(\hat{\theta})] \supset \{\theta\}\right) = P\left(Li(\hat{\theta}) \leq \theta \leq Ls(\hat{\theta})\right) = \gamma.$$

*Notação:  $IC(\theta; \gamma) = [Li(\hat{\theta}); Ls(\hat{\theta})]$ .*

- O intervalo de confiança é aleatório!

- O intervalo de confiança é aleatório!
- A probabilidade descrita na definição anterior se refere ao intervalo conter (ou cobrir) o parâmetro;

- O intervalo de confiança é aleatório!
- A probabilidade descrita na definição anterior se refere ao intervalo conter (ou cobrir) o parâmetro;
- A probabilidade anterior **não** se refere ao parâmetro pertencer ao intervalo;




- O intervalo de confiança é aleatório!
- A probabilidade descrita na definição anterior se refere ao intervalo conter (ou cobrir) o parâmetro;
- A probabilidade anterior **não** se refere ao parâmetro pertencer ao intervalo;
- O parâmetro é **constante**, portanto não faz sentido associar probabilidades a ele;

- O intervalo de confiança é aleatório!
- A probabilidade descrita na definição anterior se refere ao intervalo conter (ou cobrir) o parâmetro;
- A probabilidade anterior **não** se refere ao parâmetro pertencer ao intervalo;
- O parâmetro é **constante**, portanto não faz sentido associar probabilidades a ele;
- Após observada a amostra o intervalo não é mais aleatório, assim a probabilidade de ele conter o parâmetro é 0 ou 1;

- Se coletássemos várias amostras e, para cada uma, calculássemos o IC, esperaríamos que,  $100\gamma\%$  dos IC's contivessem o parâmetro;

- Se coletássemos várias amostras e, para cada uma, calculássemos o IC, esperaríamos que,  $100\gamma\%$  dos IC's contivessem o parâmetro;
- Por esse motivo, dizemos que temos uma **confiança**  $\gamma$ , isto é, uma interpretação frequentista;

- Se coletássemos várias amostras e, para cada uma, calculássemos o IC, esperaríamos que,  $100\gamma\%$  dos IC's contivessem o parâmetro;
- Por esse motivo, dizemos que temos uma **confiança**  $\gamma$ , isto é, uma interpretação frequentista;
- Em outras palavras, após coletar uma amostra não saberemos se o intervalo calculado cobrirá o parâmetro. Entretanto, a construção do intervalo garante que isso ocorre em  $100\gamma\%$  das vezes.



# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

## IC para $\mu$ com $\sigma^2$ conhecida

Encontremos um IC para  $\mu$  em função de  $\bar{X}$ . Seja  $z_{\frac{\gamma}{2}}$  o número tal que  $P(-z_{\frac{\gamma}{2}} < Z < z_{\frac{\gamma}{2}}) = \gamma$ , onde  $Z \sim N(0, 1)$ . De fato, pelo TCL

$$\begin{aligned}\gamma &= P\left(-z_{\frac{\gamma}{2}} < Z < z_{\frac{\gamma}{2}}\right) \approx P\left(-z_{\frac{\gamma}{2}} < Z_n < z_{\frac{\gamma}{2}}\right) \\ &= P\left(-z_{\frac{\gamma}{2}} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < z_{\frac{\gamma}{2}}\right) = P\left(-z_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < z_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}}\right) \\ &= P\left(\bar{X} - z_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}}\right)\end{aligned}$$

Logo um IC para  $\mu$  com coeficiente de confiança  $\gamma$  é dado por

$$IC(\mu; \gamma) = \left[ \bar{X} - z_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}}; \bar{X} + z_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}} \right].$$



# Exemplo

Uma máquina estava regulada para encher pacotes de café com peso médio de  $500g$  e variância de  $196g^2$ . Uma a.a. de 49 pacotes forneceu média de  $485g$ . O que podemos dizer sobre a verdadeira média com confiança de 95%?

# Exemplo

Uma máquina estava regulada para encher pacotes de café com peso médio de  $500g$  e variância de  $196g^2$ . Uma a.a. de 49 pacotes forneceu média de  $485g$ . O que podemos dizer sobre a verdadeira média com confiança de 95%?

Temos que  $\bar{x} = 485$ ,  $n = 49$ ,  $\sigma^2 = 196$  e  $\gamma = 0.95$ . Primeiramente,  $z_{\frac{\gamma}{2}} = z_{0.475} = 1.96$ . Logo,

$$IC(\mu; 0.95) = \left[ 485 - 1.96 \times \frac{14}{7}; 485 + 1.96 \times \frac{14}{7} \right] = [481.08; 488.92].$$

# Exemplo

Uma máquina estava regulada para encher pacotes de café com peso médio de  $500g$  e variância de  $196g^2$ . Uma a.a. de 49 pacotes forneceu média de  $485g$ . O que podemos dizer sobre a verdadeira média com confiança de 95%?

Temos que  $\bar{x} = 485$ ,  $n = 49$ ,  $\sigma^2 = 196$  e  $\gamma = 0.95$ . Primeiramente,  $z_{\frac{\gamma}{2}} = z_{0.475} = 1.96$ . Logo,

$$IC(\mu; 0.95) = \left[ 485 - 1.96 \times \frac{14}{7}; 485 + 1.96 \times \frac{14}{7} \right] = [481.08; 488.92].$$

Com confiança de 95% podemos afirmar que a máquina está desregulada.

- No exemplo anterior, supomos que a desregulagem afeta apenas a média com que os pacotes são preenchidos;

- No exemplo anterior, supomos que a desregulagem afeta apenas a média com que os pacotes são preenchidos;
- E se afetasse a variância?

- No exemplo anterior, supomos que a desregulagem afeta apenas a média com que os pacotes são preenchidos;
- E se afetasse a variância?
- Em outras palavras, e se  $\sigma^2$  for **desconhecida**?

## IC para $\mu$ com $\sigma^2$ desconhecida (grandes amostras)

Temos primeiramente que  $S^2$  é um estimador consistente de  $\sigma^2$ . Portanto, em grandes amostras ( $n$  muito grande),  $S^2 \approx \sigma^2$ .

## IC para $\mu$ com $\sigma^2$ desconhecida (grandes amostras)

Temos primeiramente que  $S^2$  é um estimador consistente de  $\sigma^2$ . Portanto, em grandes amostras ( $n$  muito grande),  $S^2 \approx \sigma^2$ . Daí podemos utilizar o seguinte IC para  $\mu$  quando  $\sigma^2$  é desconhecida:

$$IC(\mu; \gamma) = \left[ \bar{X} - z_{\frac{\gamma}{2}} \frac{S}{\sqrt{n}}; \bar{X} + z_{\frac{\gamma}{2}} \frac{S}{\sqrt{n}} \right].$$



## IC para $\mu$ com $\sigma^2$ desconhecida (grandes amostras)

Temos primeiramente que  $S^2$  é um estimador consistente de  $\sigma^2$ . Portanto, em grandes amostras ( $n$  muito grande),  $S^2 \approx \sigma^2$ . Daí podemos utilizar o seguinte IC para  $\mu$  quando  $\sigma^2$  é desconhecida:

$$IC(\mu; \gamma) = \left[ \bar{X} - z_{\frac{\gamma}{2}} \frac{S}{\sqrt{n}}; \bar{X} + z_{\frac{\gamma}{2}} \frac{S}{\sqrt{n}} \right].$$

Se o tamanho amostral é suficientemente grande, o IC acima fornece aproximadamente confiança  $\gamma$ .

## IC para $\mu$ com $\sigma^2$ desconhecida (amostras normais)

- Caso o valor de  $n$  seja pequeno, o valor fornecido por  $S^2$  pode estar distante de  $\sigma^2$ ;

## IC para $\mu$ com $\sigma^2$ desconhecida (amostras normais)

- Caso o valor de  $n$  seja pequeno, o valor fornecido por  $S^2$  pode estar distante de  $\sigma^2$ ;
- Portanto, a distribuição de  $\frac{\bar{X}-\mu}{S/\sqrt{n}}$  pode não ser muito próxima da de v.a.  $Z \sim N(0, 1)$ ;

## IC para $\mu$ com $\sigma^2$ desconhecida (amostras normais)

- Caso o valor de  $n$  seja pequeno, o valor fornecido por  $S^2$  pode estar distante de  $\sigma^2$ ;
- Portanto, a distribuição de  $\frac{\bar{X} - \mu}{S/\sqrt{n}}$  pode não ser muito próxima da de v.a.  $Z \sim N(0, 1)$ ;
- Entretanto, supondo que **os dados** são observados de uma v.a. normal, pode-se mostrar que a v.a.

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

## IC para $\mu$ com $\sigma^2$ desconhecida (amostras normais)

- Caso o valor de  $n$  seja pequeno, o valor fornecido por  $S^2$  pode estar distante de  $\sigma^2$ ;
- Portanto, a distribuição de  $\frac{\bar{X} - \mu}{S/\sqrt{n}}$  pode não ser muito próxima da de v.a.  $Z \sim N(0, 1)$ ;
- Entretanto, supondo que **os dados** são observados de uma v.a. normal, pode-se mostrar que a v.a.

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

- O símbolo  $T \sim t_r$  significa que a v.a.  $T$  tem uma distribuição  $t$ -student com  $r$  graus de liberdade (g.l.).

## IC para $\mu$ com $\sigma^2$ desconhecida (amostras normais)

- Caso o valor de  $n$  seja pequeno, o valor fornecido por  $S^2$  pode estar distante de  $\sigma^2$ ;
- Portanto, a distribuição de  $\frac{\bar{X} - \mu}{S/\sqrt{n}}$  pode não ser muito próxima da de v.a.  $Z \sim N(0, 1)$ ;
- Entretanto, supondo que **os dados** são observados de uma v.a. normal, pode-se mostrar que a v.a.

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

- O símbolo  $T \sim t_r$  significa que a v.a.  $T$  tem uma distribuição  $t$ -student com  $r$  graus de liberdade (g.l.).

## Comentário

*Em resumo se a v.a.  $X$  que será observada satisfizer  $X \sim N(\mu, \sigma^2)$ .  
Então*

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

*tem distribuição t-student com  $n - 1$  g.l.*

Utilizando o resultado anterior, encontremos um IC para  $\mu$  em função de  $\bar{X}$ . Seja  $t_{(\frac{\gamma}{2}; n-1)}$  o número tal que  $P\left(-t_{(\frac{\gamma}{2}; n-1)} < T < t_{(\frac{\gamma}{2}; n-1)}\right) = \gamma$ , onde  $T \sim t_{n-1}$ . De fato,

$$\begin{aligned}\gamma &= P\left(-t_{(\frac{\gamma}{2}; n-1)} < T < t_{(\frac{\gamma}{2}; n-1)}\right) = P\left(-t_{(\frac{\gamma}{2}; n-1)} < \frac{\bar{X} - \mu}{S/\sqrt{n}} < t_{(\frac{\gamma}{2}; n-1)}\right) \\ &= P\left(\bar{X} - t_{(\frac{\gamma}{2}; n-1)} \frac{S}{\sqrt{n}} < \mu < \bar{X} + t_{(\frac{\gamma}{2}; n-1)} \frac{S}{\sqrt{n}}\right)\end{aligned}$$

Logo quando  $\sigma^2$  é desconhecida e o tamanho amostral não é grande, se os dados vierem de uma v.a. normal, um IC para  $\mu$  com coeficiente de confiança  $\gamma$  é dado por

$$IC(\mu; \gamma) = \left[ \bar{X} - t_{(\frac{\gamma}{2}; n-1)} \frac{S}{\sqrt{n}}; \bar{X} + t_{(\frac{\gamma}{2}; n-1)} \frac{S}{\sqrt{n}} \right].$$



## Exemplo 1 - cont.

No exemplo dos sacos de café, suponha que em vez de 49, apenas 9 sacos tivessem sido coletados.

## Exemplo 1 - cont.

No exemplo dos sacos de café, suponha que em vez de 49, apenas 9 sacos tivessem sido coletados. Entretanto, suponha que os pesos dos sacos de café seguem uma distribuição normal.

## Exemplo 1 - cont.

No exemplo dos sacos de café, suponha que em vez de 49, apenas 9 sacos tivessem sido coletados. Entretanto, suponha que os pesos dos sacos de café seguem uma distribuição normal. Há suspeita de que a variância também pode ter sido alterada.

## Exemplo 1 - cont.

No exemplo dos sacos de café, suponha que em vez de 49, apenas 9 sacos tivessem sido coletados. Entretanto, suponha que os pesos dos sacos de café seguem uma distribuição normal. Há suspeita de que a variância também pode ter sido alterada. Por este motivo, a variância amostral foi calculada e forneceu  $s^2 = 225$ . O que podemos dizer sobre a situação da máquina.

## Exemplo 1 - cont.

No exemplo dos sacos de café, suponha que em vez de 49, apenas 9 sacos tivessem sido coletados. Entretanto, suponha que os pesos dos sacos de café seguem uma distribuição normal. Há suspeita de que a variância também pode ter sido alterada. Por este motivo, a variância amostral foi calculada e forneceu  $s^2 = 225$ . O que podemos dizer sobre a situação da máquina. Primeiramente, temos que  $t_{(\frac{\gamma}{2}; n-1)} = t_{(0.475; 8)} = 2,306$ .

## Exemplo 1 - cont.

No exemplo dos sacos de café, suponha que em vez de 49, apenas 9 sacos tivessem sido coletados. Entretanto, suponha que os pesos dos sacos de café seguem uma distribuição normal. Há suspeita de que a variância também pode ter sido alterada. Por este motivo, a variância amostral foi calculada e forneceu  $s^2 = 225$ . O que podemos dizer sobre a situação da máquina. Primeiramente, temos que  $t_{(\frac{\gamma}{2}; n-1)} = t_{(0.475; 8)} = 2,306$ . Logo,

$$IC(\mu; \gamma) = \left[ 485 - 2.306 \times \frac{15}{3}; 485 + 2.306 \times \frac{15}{3} \right] = [473.47; 496.53].$$

## Exemplo 1 - cont.

No exemplo dos sacos de café, suponha que em vez de 49, apenas 9 sacos tivessem sido coletados. Entretanto, suponha que os pesos dos sacos de café seguem uma distribuição normal. Há suspeita de que a variância também pode ter sido alterada. Por este motivo, a variância amostral foi calculada e forneceu  $s^2 = 225$ . O que podemos dizer sobre a situação da máquina. Primeiramente, temos que  $t_{(\frac{\gamma}{2}; n-1)} = t_{(0.475; 8)} = 2,306$ . Logo,

$$IC(\mu; \gamma) = \left[ 485 - 2.306 \times \frac{15}{3}; 485 + 2.306 \times \frac{15}{3} \right] = [473.47; 496.53].$$

Portanto, percebemos que a amplitude do intervalo aumentou significativamente. Entretanto, as conclusões obtidas não foram alteradas.

- $\uparrow \gamma \Rightarrow \uparrow \text{amplitude}$ ;



# Propriedades de IC

- $\uparrow \gamma \Rightarrow \uparrow \text{amplitude}$ ;
- $\uparrow \sigma^2 \Rightarrow \uparrow \text{amplitude}$ ;

- $\uparrow \gamma \Rightarrow \uparrow$  amplitude;
- $\uparrow \sigma^2 \Rightarrow \uparrow$  amplitude;
- $\uparrow n \Rightarrow \downarrow$  amplitude.

**Exercício:** Criar um IC para a probabilidade de sucesso  $p$  utilizando como estimador a proporção amostral  $\hat{p}$ . Note que a variância dependerá de  $p$  (que é desconhecido)! Qual solução você sugere?

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Objetivo: Testar afirmações sobre parâmetros populacionais.

- Objetivo: Testar afirmações sobre parâmetros populacionais.

## Definição

*Seja  $\theta$  um parâmetro da distribuição de um v.a.  $X$ . Uma hipótese é qualquer afirmação feita com relação a  $\theta$  que pode ser submetida a teste.*

- Objetivo: Testar afirmações sobre parâmetros populacionais.

## Definição

*Seja  $\theta$  um parâmetro da distribuição de um v.a.  $X$ . Uma hipótese é qualquer afirmação feita com relação a  $\theta$  que pode ser submetida a teste.*

**Exemplo:** Seja  $\theta$  um parâmetro populacional. Exemplos mais usuais de hipóteses com respeito a  $\theta$  são:

- Simples:  $\theta = \theta_0$ ;
- Compostas:
  - ▶  $\theta \geq \theta_0$  e  $\theta > \theta_0$  (unilateral);
  - ▶  $\theta \leq \theta_0$  e  $\theta < \theta_0$  (unilateral); e
  - ▶  $\theta \neq \theta_0$  (bilateral).

- Para realizar um teste de hipóteses estatístico devemos estabelecer corretamente as hipóteses:
  - ▶ nula - denotada por  $H_0$ , é aquela que será submetida a teste. Pode ser, ou não rejeitada; e
  - ▶ alternativa - denotada por  $H_1$ , é aquela que é aceita quando rejeitamos  $H_0$ .
- Geralmente, mas nem sempre,  $H_1$  representa o complementar de  $H_0$ ;
- Entretanto,  $H_0$  e  $H_1$  devem ser mutuamente excludentes.

## Definição

*Um teste de hipóteses é o procedimento de tomada de decisão sobre rejeitar, ou não,  $H_0$ .*



## Definição

*Um teste de hipóteses é o procedimento de tomada de decisão sobre rejeitar, ou não,  $H_0$ .*

- Como testar entre  $H_0$  e  $H_1$ ?

## Definição

*Um teste de hipóteses é o procedimento de tomada de decisão sobre rejeitar, ou não,  $H_0$ .*

- Como testar entre  $H_0$  e  $H_1$ ?
- Utilizar um estimador  $\hat{\theta}$  do parâmetro  $\theta$  para a tomada de decisão;

## Definição

*Um teste de hipóteses é o procedimento de tomada de decisão sobre rejeitar, ou não,  $H_0$ .*

- Como testar entre  $H_0$  e  $H_1$ ?
- Utilizar um estimador  $\hat{\theta}$  do parâmetro  $\theta$  para a tomada de decisão;
- O primeiro passo é estabelecer a Região Crítica (RC) do teste.

## Definição

*Um teste de hipóteses é o procedimento de tomada de decisão sobre rejeitar, ou não,  $H_0$ .*

- Como testar entre  $H_0$  e  $H_1$ ?
- Utilizar um estimador  $\hat{\theta}$  do parâmetro  $\theta$  para a tomada de decisão;
- O primeiro passo é estabelecer a Região Crítica (RC) do teste.

## Definição

*A região crítica de um teste de hipóteses é um conjunto de valores que, se fornecidos pelo estimador, levam a rejeição de  $H_0$ . Formalmente,*

$$RC_{H_0} = \{x : \text{se } \hat{\theta} = x, H_0 \text{ é rejeitada}\}.$$

## Definição

*Um teste de hipóteses é o procedimento de tomada de decisão sobre rejeitar, ou não,  $H_0$ .*

- Como testar entre  $H_0$  e  $H_1$ ?
- Utilizar um estimador  $\hat{\theta}$  do parâmetro  $\theta$  para a tomada de decisão;
- O primeiro passo é estabelecer a Região Crítica (RC) do teste.

## Definição

*A região crítica de um teste de hipóteses é um conjunto de valores que, se fornecidos pelo estimador, levam a rejeição de  $H_0$ . Formalmente,*

$$RC_{H_0} = \{x : \text{se } \hat{\theta} = x, H_0 \text{ é rejeitada}\}.$$

**Exemplo:** Suponha que desejamos testar  $H_0 : \mu \geq \mu_0$ . Uma RC natural para testar  $H_0$  seria  $RC_{H_0} = \{\bar{X} < x_c\}$ . Isto é, valores muito pequenos de  $\bar{X}$  indicariam que  $H_0$  deve ser rejeitada. O problema agora consistiria em determinar o **valor crítico**  $x_c$ , ou seja, determinar o que seria muito pequeno.

# Tipos de erros

- Decidir entre rejeitar, ou não,  $H_0$  pode acarretar em dois tipos de erros:

# Tipos de erros

- Decidir entre rejeitar, ou não,  $H_0$  pode acarretar em dois tipos de erros:
  - ▶ erro tipo 1 - ao rejeitarmos  $H_0$ , quando  $H_0$  é verdadeira;
  - ▶ erro tipo 2 - ao não rejeitamos  $H_0$ , quando  $H_0$  é falsa.

# Tipos de erros

- Decidir entre rejeitar, ou não,  $H_0$  pode acarretar em dois tipos de erros:
  - ▶ erro tipo 1 - ao rejeitarmos  $H_0$ , quando  $H_0$  é verdadeira;
  - ▶ erro tipo 2 - ao não rejeitarmos  $H_0$ , quando  $H_0$  é falsa.
- Pela decisão ser tomada com base em um estimador (v.a.) cada tipo de erro tem uma probabilidade de ocorrer:
  - ▶  $P(\text{erro tipo 1}) = P(\text{Rejeitar } H_0 | H_0 \text{ é verdadeira}) := \alpha(\theta)$ . A função  $\alpha(\theta)$  é denominada tamanho do teste;
  - ▶  $P(\text{erro tipo 2}) = P(\text{Não Rejeitar } H_0 | H_0 \text{ é falsa}) := \beta(\theta)$ . A função  $1 - \beta(\theta)$  é denominada poder do teste.



# Exemplo

Uma indústria utiliza um parafuso que deve satisfazer determinadas especificações. Uma dessas é a resistência à tração  $X$  (em  $kg/m^2$ ). Dependendo da localidade em que os parafusos são fabricados,  $X$  pode ter diferentes distribuições. Suponha que apenas as localidades  $A$  e  $B$  produzam os parafusos. Se o parafuso vem:

- de  $A$ , então  $E(X) = 145$  e  $\sigma^2 = 12^2$ ;
- de  $B$ , então  $E(X) = 155$  e  $\sigma^2 = 18^2$ .

## Exemplo

Uma indústria utiliza um parafuso que deve satisfazer determinadas especificações. Uma dessas é a resistência à tração  $X$  (em  $kg/m^2$ ). Dependendo da localidade em que os parafusos são fabricados,  $X$  pode ter diferentes distribuições. Suponha que apenas as localidades  $A$  e  $B$  produzam os parafusos. Se o parafuso vem:

- de  $A$ , então  $E(X) = 145$  e  $\sigma^2 = 12^2$ ;
- de  $B$ , então  $E(X) = 155$  e  $\sigma^2 = 18^2$ .

Um lote grande de parafusos será leiloado e a empresa deseja comprar esse lote somente se o mesmo vier da localidade  $B$ . No dia do leilão o leiloeiro divulgará a resistência à tração média de 36 parafusos escolhidos desse lote.

## Exemplo

Uma indústria utiliza um parafuso que deve satisfazer determinadas especificações. Uma dessas é a resistência à tração  $X$  (em  $kg/m^2$ ). Dependendo da localidade em que os parafusos são fabricados,  $X$  pode ter diferentes distribuições. Suponha que apenas as localidades  $A$  e  $B$  produzam os parafusos. Se o parafuso vem:

- de  $A$ , então  $E(X) = 145$  e  $\sigma^2 = 12^2$ ;
- de  $B$ , então  $E(X) = 155$  e  $\sigma^2 = 18^2$ .

Um lote grande de parafusos será leiloado e a empresa deseja comprar esse lote somente se o mesmo vier da localidade  $B$ . No dia do leilão o leiloeiro divulgará a resistência à tração média de 36 parafusos escolhidos desse lote. Podemos estabelecer as hipóteses nula e alternativa como sendo:

$$H_0 : \mu = 155, \sigma = 18 \quad \times \quad H_1 : \mu = 145, \sigma = 12.$$

Se decidirmos rejeitar  $H_0$  quando (por exemplo)  $\bar{X} < 150$ , cometeríamos os erros tipos 1 e 2 com quais probabilidades?

## Exemplo - cont.

Como neste caso  $H_0$  e  $H_1$  são ambas hipóteses simples,  $\alpha = \alpha(\mu = 155, \sigma = 18)$  e  $\beta = \beta(\mu = 145, \sigma = 12)$  são de fácil obtenção.

## Exemplo - cont.

Como neste caso  $H_0$  e  $H_1$  são ambas hipóteses simples,  $\alpha = \alpha(\mu = 155, \sigma = 18)$  e  $\beta = \beta(\mu = 145, \sigma = 12)$  são de fácil obtenção. De fato,

$$\begin{aligned}\alpha &= P(\text{erro tipo 1}) = P(\text{Rejeitar } H_0 | H_0 \text{ é verdadeira}) \\ &= P(\bar{X} < 150 | \mu = 155, \sigma = 18) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < \frac{150 - 155}{18/\sqrt{36}}\right) \\ &\approx P(Z < -1.67) = 0.0475\end{aligned}$$

## Exemplo - cont.

Como neste caso  $H_0$  e  $H_1$  são ambas hipóteses simples,  $\alpha = \alpha(\mu = 155, \sigma = 18)$  e  $\beta = \beta(\mu = 145, \sigma = 12)$  são de fácil obtenção. De fato,

$$\begin{aligned}\alpha &= P(\text{erro tipo 1}) = P(\text{Rejeitar } H_0 | H_0 \text{ é verdadeira}) \\ &= P(\bar{X} < 150 | \mu = 155, \sigma = 18) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < \frac{150 - 155}{18/\sqrt{36}}\right) \\ &\approx P(Z < -1.67) = 0.0475\end{aligned}$$

e, analogamente,

$$\begin{aligned}\beta &= P(\text{erro tipo 2}) = P(\text{Não Rejeitar } H_0 | H_0 \text{ é falsa}) \\ &= P(\bar{X} \geq 150 | \mu = 145, \sigma = 12) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \geq \frac{150 - 145}{12/\sqrt{36}}\right) \\ &\approx P(Z \geq 2.5) = 0.0062.\end{aligned}$$

## Exemplo - cont.

Embora tenhamos fixado a RC e depois verificado  $\alpha$  e  $\beta$ , o usual é encontrar a RC que fornece um valor pré-estabelecido para  $\alpha$ .

## Exemplo - cont.

Embora tenhamos fixado a RC e depois verificado  $\alpha$  e  $\beta$ , o usual é encontrar a RC que fornece um valor pré-estabelecido para  $\alpha$ . Primeiramente, devemos encontrar o “formato” da RC.



## Exemplo - cont.

Embora tenhamos fixado a RC e depois verificado  $\alpha$  e  $\beta$ , o usual é encontrar a RC que fornece um valor pré-estabelecido para  $\alpha$ . Primeiramente, devemos encontrar o “formato” da RC. Perceba que teremos evidências para rejeitar  $H_0$  se o valor de  $\bar{X}$  for “suficientemente” menor do que 155, isto é, se  $\bar{X} < x_c$ , para algum  $x_c < 155$ .

## Exemplo - cont.

Embora tenhamos fixado a RC e depois verificado  $\alpha$  e  $\beta$ , o usual é encontrar a RC que fornece um valor pré-estabelecido para  $\alpha$ . Primeiramente, devemos encontrar o “formato” da RC. Perceba que teremos evidências para rejeitar  $H_0$  se o valor de  $\bar{X}$  for “suficientemente” menor do que 155, isto é, se  $\bar{X} < x_c$ , para algum  $x_c < 155$ . Podemos encontrar o valor de  $x_c$  que forneça probabilidade de erro tipo 1 igual a 0.1 por exemplo.

## Exemplo - cont.

Embora tenhamos fixado a RC e depois verificado  $\alpha$  e  $\beta$ , o usual é encontrar a RC que fornece um valor pré-estabelecido para  $\alpha$ . Primeiramente, devemos encontrar o “formato” da RC. Perceba que teremos evidências para rejeitar  $H_0$  se o valor de  $\bar{X}$  for “suficientemente” menor do que 155, isto é, se  $\bar{X} < x_c$ , para algum  $x_c < 155$ . Podemos encontrar o valor de  $x_c$  que forneça probabilidade de erro tipo 1 igual a 0.1 por exemplo. Temos que

$$\begin{aligned} 0.1 &= \alpha = P(\text{erro tipo 1}) = P(\text{Rejeitar } H_0 | H_0 \text{ é verdadeira}) \\ &= P(\bar{X} < x_c | \mu = 155, \sigma = 18) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < \frac{x_c - 155}{18/\sqrt{36}}\right) \\ &\approx P\left(Z < \frac{x_c - 155}{3}\right) = P(Z < z), \end{aligned}$$

onde  $z = \frac{x_c - 155}{3}$ . Logo, devemos ter  $\frac{x_c - 155}{3} = z = -1.28 \Rightarrow x_c = 151.16$ .

## Exemplo - cont.

Embora tenhamos fixado a RC e depois verificado  $\alpha$  e  $\beta$ , o usual é encontrar a RC que fornece um valor pré-estabelecido para  $\alpha$ . Primeiramente, devemos encontrar o “formato” da RC. Perceba que teremos evidências para rejeitar  $H_0$  se o valor de  $\bar{X}$  for “suficientemente” menor do que 155, isto é, se  $\bar{X} < x_c$ , para algum  $x_c < 155$ . Podemos encontrar o valor de  $x_c$  que forneça probabilidade de erro tipo 1 igual a 0.1 por exemplo. Temos que

$$\begin{aligned} 0.1 = \alpha &= P(\text{erro tipo 1}) = P(\text{Rejeitar } H_0 | H_0 \text{ é verdadeira}) \\ &= P(\bar{X} < x_c | \mu = 155, \sigma = 18) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < \frac{x_c - 155}{18/\sqrt{36}}\right) \\ &\approx P\left(Z < \frac{x_c - 155}{3}\right) = P(Z < z), \end{aligned}$$

onde  $z = \frac{x_c - 155}{3}$ . Logo, devemos ter  $\frac{x_c - 155}{3} = z = -1.28 \Rightarrow x_c = 151.16$ .

**Exercício:** Encontre  $\beta$  para a RC acima.

## Definição

*O valor que fixamos para a probabilidade do erro tipo 1 é denominado nível de significância.*

## Definição

*O valor que fixamos para a probabilidade do erro tipo 1 é denominado nível de significância.*

- No exemplo anterior foi possível fixar o nível de significância e determinar  $\beta$  de maneira exata, pois as duas hipóteses eram simples!

## Definição

*O valor que fixamos para a probabilidade do erro tipo 1 é denominado nível de significância.*

- No exemplo anterior foi possível fixar o nível de significância e determinar  $\beta$  de maneira exata, pois as duas hipóteses eram simples!
- Como proceder no caso de hipóteses compostas?

## Definição

*O valor que fixamos para a probabilidade do erro tipo 1 é denominado nível de significância.*

- No exemplo anterior foi possível fixar o nível de significância e determinar  $\beta$  de maneira exata, pois as duas hipóteses eram simples!
- Como proceder no caso de hipóteses compostas?
  - ▶ Se  $H_0$  for composta (por exemplo  $\theta \leq \theta_0$ ), a probabilidade do erro tipo 1 é uma função do verdadeiro valor de  $\theta$  que é desconhecido sob  $H_0$ ;



## Definição


*O valor que fixamos para a probabilidade do erro tipo 1 é denominado nível de significância.*


- No exemplo anterior foi possível fixar o nível de significância e determinar  $\beta$  de maneira exata, pois as duas hipóteses eram simples!
- Como proceder no caso de hipóteses compostas?
  - ▶ Se  $H_0$  for composta (por exemplo  $\theta \leq \theta_0$ ), a probabilidade do erro tipo 1 é uma função do verdadeiro valor de  $\theta$  que é desconhecido sob  $H_0$ ;
  - ▶ Neste caso podemos ser conservadores e tomar o nível de significância como sendo a maior das probabilidades de erro tipo 1, isto é podemos fazer o nível de significância como  $\sup_{\theta} \alpha(\theta)$ ;


## Definição

*O valor que fixamos para a probabilidade do erro tipo 1 é denominado nível de significância.*

- No exemplo anterior foi possível fixar o nível de significância e determinar  $\beta$  de maneira exata, pois as duas hipóteses eram simples!
- Como proceder no caso de hipóteses compostas?
  - ▶ Se  $H_0$  for composta (por exemplo  $\theta \leq \theta_0$ ), a probabilidade do erro tipo 1 é uma função do verdadeiro valor de  $\theta$  que é desconhecido sob  $H_0$ ;
  - ▶ Neste caso podemos ser conservadores e tomar o nível de significância como sendo a maior das probabilidades de erro tipo 1, isto é podemos fazer o nível de significância como  $\sup_{\theta} \alpha(\theta)$ ;
  - ▶ Se o tamanho do teste  $\alpha(\theta)$  tiver comportamento monótono, então  $\sup_{\theta} \alpha(\theta) = \alpha(\theta_0)$  para ambos  $H_0 : \theta = \theta_0$ ,  $H_0 : \theta \leq \theta_0$  e  $H_0 : \theta \geq \theta_0$ .

$H_0$  $H_1$ 

$H_0$  $H_1$ 



- Devido a construção do teste de hipóteses,  $H_0$  sempre deve conter o sinal de igualdade;

- Devido a construção do teste de hipóteses,  $H_0$  sempre deve conter o sinal de igualdade;
- O nível de significância pode ser enxergado como um *tradeoff* entre  $\alpha$  e  $\beta$ ;

- Devido a construção do teste de hipóteses,  $H_0$  sempre deve conter o sinal de igualdade;
- O nível de significância pode ser enxergado como um *tradeoff* entre  $\alpha$  e  $\beta$ ;
- Pois:
  - ▶  $\uparrow \alpha \Rightarrow \downarrow \beta$ ;
  - ▶  $\downarrow \alpha \Rightarrow \uparrow \beta$ ;



- Devido a construção do teste de hipóteses,  $H_0$  sempre deve conter o sinal de igualdade;
- O nível de significância pode ser enxergado como um *tradeoff* entre  $\alpha$  e  $\beta$ ;
- Pois:
  - ▶  $\uparrow \alpha \Rightarrow \downarrow \beta$ ;
  - ▶  $\downarrow \alpha \Rightarrow \uparrow \beta$ ;
- Se o custo do erro tipo 1 for mais alto que o do erro tipo 2, devemos adotar um nível de significância baixo;

- Devido a construção do teste de hipóteses,  $H_0$  sempre deve conter o sinal de igualdade;
- O nível de significância pode ser enxergado como um *tradeoff* entre  $\alpha$  e  $\beta$ ;
- Pois:
  - ▶  $\uparrow \alpha \Rightarrow \downarrow \beta$ ;
  - ▶  $\downarrow \alpha \Rightarrow \uparrow \beta$ ;
- Se o custo do erro tipo 1 for mais alto que o do erro tipo 2, devemos adotar um nível de significância baixo;
- Se o custo do erro tipo 1 for mais baixo que o do erro tipo 2, devemos adotar um nível de significância alto (para indiretamente diminuir o valor de  $\beta$ );

- Devido a construção do teste de hipóteses,  $H_0$  sempre deve conter o sinal de igualdade;
- O nível de significância pode ser enxergado como um *tradeoff* entre  $\alpha$  e  $\beta$ ;
- Pois:
  - ▶  $\uparrow \alpha \Rightarrow \downarrow \beta$ ;
  - ▶  $\downarrow \alpha \Rightarrow \uparrow \beta$ ;
- Se o custo do erro tipo 1 for mais alto que o do erro tipo 2, devemos adotar um nível de significância baixo;
- Se o custo do erro tipo 1 for mais baixo que o do erro tipo 2, devemos adotar um nível de significância alto (para indiretamente diminuir o valor de  $\beta$ );
- Depois de fixado o nível de significância e obtida a RC, se  $H_1$  é composta, a probabilidade do erro tipo 2 não pode ser obtida de maneira exata e deve ser tratada como função de  $\theta$ ;

# Etapas de um teste de hipóteses

- 1 Estabelecer  $H_0$  e  $H_1$ ;

# Etapas de um teste de hipóteses

- 1 Estabelecer  $H_0$  e  $H_1$ ;
- 2 Observar o comportamento de  $H_1$  e determinar o “formato” apropriado da RC;

# Etapas de um teste de hipóteses

- 1 Estabelecer  $H_0$  e  $H_1$ ;
- 2 Observar o comportamento de  $H_1$  e determinar o “formato” apropriado da RC;
- 3 Fixar o nível de significância;

# Etapas de um teste de hipóteses

- 1 Estabelecer  $H_0$  e  $H_1$ ;
- 2 Observar o comportamento de  $H_1$  e determinar o “formato” apropriado da RC;
- 3 Fixar o nível de significância;
- 4 Determinar a RC correspondente ao nível de significância estabelecido;

# Etapas de um teste de hipóteses

- 1 Estabelecer  $H_0$  e  $H_1$ ;
- 2 Observar o comportamento de  $H_1$  e determinar o “formato” apropriado da RC;
- 3 Fixar o nível de significância;
- 4 Determinar a RC correspondente ao nível de significância estabelecido;
- 5 Observar o valor obtido para  $\hat{\theta}$  e verificar se pertence a RC (caso em que rejeitamos  $H_0$  ao nível de significância fixado). Se  $\hat{\theta}$  não pertencer a RC concluímos que a amostra não forneceu evidências suficientes para a rejeição de  $H_0$ .



# Etapas de um teste de hipóteses

- 1 Estabelecer  $H_0$  e  $H_1$ ;
- 2 Observar o comportamento de  $H_1$  e determinar o “formato” apropriado da RC;
- 3 Fixar o nível de significância;
- 4 Determinar a RC correspondente ao nível de significância estabelecido;
- 5 Observar o valor obtido para  $\hat{\theta}$  e verificar se pertence a RC (caso em que rejeitamos  $H_0$  ao nível de significância fixado). Se  $\hat{\theta}$  não pertencer a RC concluímos que a amostra não forneceu evidências suficientes para a rejeição de  $H_0$ .

Por que não podemos dizer que aceitamos  $H_0$ ?

# Etapas de um teste de hipóteses

- 1 Estabelecer  $H_0$  e  $H_1$ ;
- 2 Observar o comportamento de  $H_1$  e determinar o “formato” apropriado da RC;
- 3 Fixar o nível de significância;
- 4 Determinar a RC correspondente ao nível de significância estabelecido;
- 5 Observar o valor obtido para  $\hat{\theta}$  e verificar se pertence a RC (caso em que rejeitamos  $H_0$  ao nível de significância fixado). Se  $\hat{\theta}$  não pertencer a RC concluímos que a amostra não forneceu evidências suficientes para a rejeição de  $H_0$ .

Por que não podemos dizer que aceitamos  $H_0$ ? Pois não sabemos a probabilidade de erro ao fazermos tal afirmação!

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

- Um dos parâmetros de maior interesse é a média  $\mu$  de uma população;
- Podemos considerar as seguintes hipóteses a serem testadas:
  - ①  $H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0$ ;
  - ②  $H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0$ ;
  - ③  $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$ ;
- Nas hipóteses acima,  $\mu$  é um parâmetro, enquanto  $\mu_0$  é um número.

## Caso 1: $H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0;$$


- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .

## Caso 1: $H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




## Caso 1: $H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .






## Caso 1: $H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




## Caso 1: $H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




## Caso 1: $H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \leq \mu_0 \times H_1 : \mu > \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .



- Portanto,  $RC_{H_0} = \{\bar{X} > x_c\}$ ;
- Como determinar  $x_c$ ?

- Fixemos o nível de significância em  $\alpha$ ;
- Seja  $z_\alpha$  o valor tal que  $P(Z > z_\alpha) = \alpha$ ;
- Dessa forma, temos que

$$\begin{aligned}\alpha &= \sup \alpha(\mu) = \alpha(\mu_0) = P(\text{Rejeitar } H_0 | \mu = \mu_0) \\ &= P(\bar{X} > x_c | \mu = \mu_0) = P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > \frac{x_c - \mu_0}{\sigma/\sqrt{n}}\right) \\ &\approx P\left(Z > \frac{x_c - \mu_0}{\sigma/\sqrt{n}}\right).\end{aligned}$$

- Logo,  $\frac{x_c - \mu_0}{\sigma/\sqrt{n}} = z_\alpha \Rightarrow x_c = \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}}$ ;
- Assim, devemos rejeitar  $H_0$  ao nível de significância  $\alpha$  se

$$\bar{X} > \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}}.$$

## Caso 2: $H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0;$$


- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .

## Caso 2: $H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




## Caso 2: $H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




## Caso 2: $H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .






## Caso 2: $H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




## Caso 2: $H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu \geq \mu_0 \times H_1 : \mu < \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .



- Portanto,  $RC_{H_0} = \{\bar{X} < x_c\}$ ;
- Como determinar  $x_c$ ?

- Fixemos o nível de significância em  $\alpha$ ;
- Utilizando a mesma definição de  $z_\alpha$  para o caso 1, isto é,  $z_\alpha$  é o valor tal que  $P(Z > z_\alpha) = \alpha$ ;
- Dessa forma, temos que

$$\begin{aligned}\alpha &= \sup \alpha(\mu) = \alpha(\mu_0) = P(\text{Rejeitar } H_0 | \mu = \mu_0) \\ &= P(\bar{X} < x_c | \mu = \mu_0) = P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < \frac{x_c - \mu_0}{\sigma/\sqrt{n}}\right) \\ &\approx P\left(Z < \frac{x_c - \mu_0}{\sigma/\sqrt{n}}\right).\end{aligned}$$

- Logo,  $\frac{x_c - \mu_0}{\sigma/\sqrt{n}} = -z_\alpha \Rightarrow x_c = \mu_0 - z_\alpha \frac{\sigma}{\sqrt{n}}$ ;
- Assim, devemos rejeitar  $H_0$  ao nível de significância  $\alpha$  se

$$\bar{X} < \mu_0 - z_\alpha \frac{\sigma}{\sqrt{n}}.$$

### Caso 3: $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0;$$


- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$  **ou** muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .

### Caso 3: $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$  **ou** muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




### Caso 3: $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$  **ou** muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




### Caso 3: $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$  **ou** muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .




### Caso 3: $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$  **ou** muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .






### Caso 3: $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$

- Suponha que desejamos testar as hipóteses:

$$H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0;$$

- Podemos utilizar  $\bar{X}$  para testar as hipóteses acima;
- Perceba que, se  $\bar{X}$  fornecer um valor muito menor que  $\mu_0$  **ou** muito maior que  $\mu_0$ , teremos evidências para rejeitar  $H_0$  em favor de  $H_1$ .



- Portanto,

$$RC_{H_0} = \{\{\bar{X} < x_{c1}\} \cup \{\bar{X} > x_{c2}\}\};$$

- Como determinar  $x_{c1}$  e  $x_{c2}$ ?

- Fixemos o nível de significância em  $\alpha$ ;
- Novamente, tomando  $z_\alpha$  como o valor tal que  $P(Z > z_\alpha) = \alpha$ ;
- Dessa forma, temos que

$$\begin{aligned}
 \alpha &= P(\text{Rejeitar } H_0 | \mu = \mu_0) = P(\{\bar{X} < x_{c_1}\} \cup \{\bar{X} > x_{c_2}\} | \mu = \mu_0) \\
 &= P(\bar{X} < x_{c_1} | \mu = \mu_0) + P(\bar{X} > x_{c_2} | \mu = \mu_0) \\
 &= P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < \frac{x_{c_1} - \mu_0}{\sigma/\sqrt{n}}\right) + P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > \frac{x_{c_2} - \mu_0}{\sigma/\sqrt{n}}\right) \\
 &\approx \underbrace{P\left(Z < \frac{x_{c_1} - \mu_0}{\sigma/\sqrt{n}}\right)}_{\alpha/2} + \underbrace{P\left(Z > \frac{x_{c_2} - \mu_0}{\sigma/\sqrt{n}}\right)}_{\alpha/2}.
 \end{aligned}$$

- Logo,

$$\frac{x_{c1} - \mu_0}{\sigma/\sqrt{n}} = -z_{\frac{\alpha}{2}} \Rightarrow x_{c1} = \mu_0 - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

e

$$\frac{x_{c2} - \mu_0}{\sigma/\sqrt{n}} = z_{\frac{\alpha}{2}} \Rightarrow x_{c2} = \mu_0 + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}};$$

- Assim, devemos rejeitar  $H_0$  ao nível de significância  $\alpha$  se

$$\bar{X} < \mu_0 - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \text{ ou } \bar{X} > \mu_0 + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}.$$

# Exemplo

Os sistemas de escapamento de uma aeronave funcionam devido a um propelente sólido. A taxa de queima é uma característica importante desse produto. As especificações exigem que a taxa de queima seja de  $50 \text{ cm/s}$ . Sabemos de experiências anteriores que essa variável tem desvio-padrão  $2 \text{ cm/s}$ . Uma amostra de tamanho 25 forneceu taxa média de queima de  $51.3 \text{ cm/s}$ . Quais conclusões podem ser tiradas ao nível de significância de 0.05?

# Exemplo

Os sistemas de escapamento de uma aeronave funcionam devido a um propelente sólido. A taxa de queima é uma característica importante desse produto. As especificações exigem que a taxa de queima seja de  $50 \text{ cm/s}$ . Sabemos de experiências anteriores que essa variável tem desvio-padrão  $2 \text{ cm/s}$ . Uma amostra de tamanho 25 forneceu taxa média de queima de  $51.3 \text{ cm/s}$ . Quais conclusões podem ser tiradas ao nível de significância de 0.05?

- Temos que  $\bar{x} = 51.3$ ,  $\sigma = 2$  e  $n = 25$ ;

# Exemplo

Os sistemas de escapamento de uma aeronave funcionam devido a um propelente sólido. A taxa de queima é uma característica importante desse produto. As especificações exigem que a taxa de queima seja de  $50 \text{ cm/s}$ . Sabemos de experiências anteriores que essa variável tem desvio-padrão  $2 \text{ cm/s}$ . Uma amostra de tamanho 25 forneceu taxa média de queima de  $51.3 \text{ cm/s}$ . Quais conclusões podem ser tiradas ao nível de significância de 0.05?

- Temos que  $\bar{x} = 51.3$ ,  $\sigma = 2$  e  $n = 25$ ;
- As hipóteses são

$$H_0 : \mu = 50 \quad \times \quad H_1 : \mu \neq 50.$$

Logo,  $\mu_0 = 50$ ;

# Exemplo

Os sistemas de escapamento de uma aeronave funcionam devido a um propelente sólido. A taxa de queima é uma característica importante desse produto. As especificações exigem que a taxa de queima seja de  $50 \text{ cm/s}$ . Sabemos de experiências anteriores que essa variável tem desvio-padrão  $2 \text{ cm/s}$ . Uma amostra de tamanho 25 forneceu taxa média de queima de  $51.3 \text{ cm/s}$ . Quais conclusões podem ser tiradas ao nível de significância de 0.05?

- Temos que  $\bar{x} = 51.3$ ,  $\sigma = 2$  e  $n = 25$ ;
- As hipóteses são

$$H_0 : \mu = 50 \quad \times \quad H_1 : \mu \neq 50.$$

Logo,  $\mu_0 = 50$ ;

- O nível de significância é 0.05, então  $z_{\frac{\alpha}{2}} = z_{0.025} = 1.96$ ;

# Exemplo

Os sistemas de escapamento de uma aeronave funcionam devido a um propelente sólido. A taxa de queima é uma característica importante desse produto. As especificações exigem que a taxa de queima seja de  $50 \text{ cm/s}$ . Sabemos de experiências anteriores que essa variável tem desvio-padrão  $2 \text{ cm/s}$ . Uma amostra de tamanho 25 forneceu taxa média de queima de  $51.3 \text{ cm/s}$ . Quais conclusões podem ser tiradas ao nível de significância de 0.05?

- Temos que  $\bar{x} = 51.3$ ,  $\sigma = 2$  e  $n = 25$ ;
- As hipóteses são

$$H_0 : \mu = 50 \quad \times \quad H_1 : \mu \neq 50.$$

Logo,  $\mu_0 = 50$ ;

- O nível de significância é 0.05, então  $z_{\frac{\alpha}{2}} = z_{0.025} = 1.96$ ;
- Os valores críticos são  $x_{c_1} = 50 - 1.96 \frac{2}{5} = 49.216$  e  $x_{c_2} = 50 + 1.96 \frac{2}{5} = 50.784$ ;



## Exemplo

Os sistemas de escapamento de uma aeronave funcionam devido a um propelente sólido. A taxa de queima é uma característica importante desse produto. As especificações exigem que a taxa de queima seja de  $50 \text{ cm/s}$ . Sabemos de experiências anteriores que essa variável tem desvio-padrão  $2 \text{ cm/s}$ . Uma amostra de tamanho 25 forneceu taxa média de queima de  $51.3 \text{ cm/s}$ . Quais conclusões podem ser tiradas ao nível de significância de 0.05?

- Temos que  $\bar{x} = 51.3$ ,  $\sigma = 2$  e  $n = 25$ ;
- As hipóteses são

$$H_0 : \mu = 50 \quad \times \quad H_1 : \mu \neq 50.$$

Logo,  $\mu_0 = 50$ ;

- O nível de significância é 0.05, então  $z_{\frac{\alpha}{2}} = z_{0.025} = 1.96$ ;
- Os valores críticos são  $x_{c_1} = 50 - 1.96 \frac{2}{5} = 49.216$  e  $x_{c_2} = 50 + 1.96 \frac{2}{5} = 50.784$ ;
- Como  $\bar{x} > x_{c_2}$ , chegamos a conclusão que devemos rejeitar  $H_0$  ao nível de significância de 5%.

# Estrutura

## 1. Introdução

## 2. Conceitos básicos

### 2.1 Parâmetros

### 2.2 Amostra

- Amostra aleatória

### 2.3 Estimador

- Distribuição amostral
- Características assintóticas de  $\bar{X}$

## 3. Estimação

### 3.1 Estimação pontual

- Vício
- Erro-padrão
- EQM

### 3.2 Estimação intervalar

- IC para  $\mu$

## 4. Teste de hipóteses

### 4.1 Teste de hipóteses para $\mu$

- $\sigma^2$  conhecida
- $\sigma^2$  desconhecida

# Tamanho amostral grande

- Suponha que  $n$  é grande o suficiente, para supormos, com base na consistência de  $S^2$ , que  $S^2 \approx \sigma^2$ ;

# Tamanho amostral grande

- Suponha que  $n$  é grande o suficiente, para supormos, com base na consistência de  $S^2$ , que  $S^2 \approx \sigma^2$ ;
- Neste caso, todos os valores críticos vistos anteriormente podem ser aproximados substituindo  $\sigma^2$  por  $S^2$  em suas expressões;

# Tamanho amostral grande

- Suponha que  $n$  é grande o suficiente, para supormos, com base na consistência de  $S^2$ , que  $S^2 \approx \sigma^2$ ;
- Neste caso, todos os valores críticos vistos anteriormente podem ser aproximados substituindo  $\sigma^2$  por  $S^2$  em suas expressões;
- E se  $n$  não for suficientemente grande?

## $n$ pequeno (população normal)

- Considere o caso em que a variância  $\sigma^2$  é desconhecida, e o tamanho amostral  $n$  é pequeno;

## $n$ pequeno (população normal)

- Considere o caso em que a variância  $\sigma^2$  é desconhecida, e o tamanho amostral  $n$  é pequeno;
- Se pudermos supor que a v.a.  $X$  sendo observada segue distribuição normal;

## $n$ pequeno (população normal)

- Considere o caso em que a variância  $\sigma^2$  é desconhecida, e o tamanho amostral  $n$  é pequeno;
- Se pudermos supor que a v.a.  $X$  sendo observada segue distribuição normal;
- Vimos anteriormente que

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1};$$



## $n$ pequeno (população normal)

- Considere o caso em que a variância  $\sigma^2$  é desconhecida, e o tamanho amostral  $n$  é pequeno;
- Se pudermos supor que a v.a.  $X$  sendo observada segue distribuição normal;
- Vimos anteriormente que

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1};$$

- Assim, todos os valores críticos anteriores podem ser considerados com  $\sigma^2$  sendo substituído  $S^2$ . Entretanto, no lugar de  $z_\alpha$  e  $z_{\frac{\alpha}{2}}$ , devemos utilizar  $t_{(\alpha;n-1)}$  e  $t_{(\frac{\alpha}{2};n-1)}$ , respectivamente. Agora,  $t_{(\alpha;n-1)}$  é o valor tal que  $P(T > t_{(\alpha;n-1)}) = \alpha$ .

## Exemplo - cont.

Retornemos ao exemplo do propelente:

- Suponha que o desvio-padrão fosse desconhecido e que não podemos considerar  $n = 25$  uma amostra grande o suficiente;

## Exemplo - cont.

Retornemos ao exemplo do propelente:

- Suponha que o desvio-padrão fosse desconhecido e que não podemos considerar  $n = 25$  uma amostra grande o suficiente;
- Além disso, suponha que a taxa de queima desse propelente tenha distribuição normal;

## Exemplo - cont.

Retornemos ao exemplo do propelente:

- Suponha que o desvio-padrão fosse desconhecido e que não podemos considerar  $n = 25$  uma amostra grande o suficiente;
- Além disso, suponha que a taxa de queima desse propelente tenha distribuição normal;
- Agora, considere que a amostra forneceu desvio-padrão 2;

## Exemplo - cont.

Retornemos ao exemplo do propelente:

- Suponha que o desvio-padrão fosse desconhecido e que não podemos considerar  $n = 25$  uma amostra grande o suficiente;
- Além disso, suponha que a taxa de queima desse propelente tenha distribuição normal;
- Agora, considere que a amostra forneceu desvio-padrão 2;
- Desejamos testar as mesmas hipóteses ao mesmo nível de significância. Logo,  $\mu_0 = 50$ ;

## Exemplo - cont.

Retornemos ao exemplo do propelente:

- Suponha que o desvio-padrão fosse desconhecido e que não podemos considerar  $n = 25$  uma amostra grande o suficiente;
- Além disso, suponha que a taxa de queima desse propelente tenha distribuição normal;
- Agora, considere que a amostra forneceu desvio-padrão 2;
- Desejamos testar as mesmas hipóteses ao mesmo nível de significância. Logo,  $\mu_0 = 50$ ;
- Assim,  $t_{(\frac{\alpha}{2}; n-1)} = t_{(0.025; 24)} = 2.0639$ ;

## Exemplo - cont.

Retornemos ao exemplo do propelente:

- Suponha que o desvio-padrão fosse desconhecido e que não podemos considerar  $n = 25$  uma amostra grande o suficiente;
- Além disso, suponha que a taxa de queima desse propelente tenha distribuição normal;
- Agora, considere que a amostra forneceu desvio-padrão 2;
- Desejamos testar as mesmas hipóteses ao mesmo nível de significância. Logo,  $\mu_0 = 50$ ;
- Assim,  $t_{(\frac{\alpha}{2}; n-1)} = t_{(0.025; 24)} = 2.0639$ ;
- Os valores críticos são portanto

$$x_{c_1} = \mu_0 - t_{(\frac{\alpha}{2}; n-1)} \frac{S}{\sqrt{n}} = 50 - 2.0639 \frac{2}{5} = 49.174$$

e

$$x_{c_2} = \mu_0 + t_{(\frac{\alpha}{2}; n-1)} \frac{S}{\sqrt{n}} = 50 + 2.0639 \frac{2}{5} = 50.826;$$

## Exemplo - cont.

Retornemos ao exemplo do propelente:

- Suponha que o desvio-padrão fosse desconhecido e que não podemos considerar  $n = 25$  uma amostra grande o suficiente;
- Além disso, suponha que a taxa de queima desse propelente tenha distribuição normal;
- Agora, considere que a amostra forneceu desvio-padrão 2;
- Desejamos testar as mesmas hipóteses ao mesmo nível de significância. Logo,  $\mu_0 = 50$ ;
- Assim,  $t_{(\frac{\alpha}{2}; n-1)} = t_{(0.025; 24)} = 2.0639$ ;
- Os valores críticos são portanto

$$x_{c_1} = \mu_0 - t_{(\frac{\alpha}{2}; n-1)} \frac{S}{\sqrt{n}} = 50 - 2.0639 \frac{2}{5} = 49.174$$

e

$$x_{c_2} = \mu_0 + t_{(\frac{\alpha}{2}; n-1)} \frac{S}{\sqrt{n}} = 50 + 2.0639 \frac{2}{5} = 50.826;$$

- Como  $\bar{x} > x_{c_2}$ , rejeitar  $H_0$  ao nível de significância de 5%.



FIM!!!