# Representação dos números no computador Precisão da máquina

Algoritmos Numéricos - Topico 1 Computação numérica e Erros Prof. Cláudia G. Varassin DI/UFES emails:claudia.varassin@ufes.br e galarda@inf.ufes.br

Setembro 2020

## Sumário

- Representação dos números no computador
- Precisão da máquina

## Representando os números no computador

A unidade fundamental para se representar uma informação em um computador é chamada de palavra.

A palavra é um agrupamento dígitos.

Para os valores numéricos, há uma representação para os números inteiros e uma outra para os números com parte fracionária.

Vamos, em um primeiro momento entender como seria se em cada "posição" da palavra fosse possível armazenar um dígito da base decimal (valores: de 0 a 9).

Mais adiante, vamos ver como realmente isso ocorre, isto é, quando cada posição desta palavra armazena uma informção simples bem simples (0:ZERO/ 1:UM) ou (LIGADO ou DESLIGADO).

A palavra é, na verdade, um agrupamento de dígitos binários, um agrupamento de bits, de Blnary digiTS. Um agrupamento de Os e 1s que permite, via combinações, representar todo tipo de informação.

### Representando os números inteiros no computador

Para armazenar os inteiros, é preciso armazenar o seu sinal e os dígitos do número:



Se na "palavra" houver 11 " espaços " então um será para o sinal e os outros 10 reservados para armazenar os dígitos do número.

Ex 1: valor K = 444 nesta palavara

Exe 2: O valor L= -1234567891 nesta palavra

## Representando os números não inteiros no computador

Para armazenar os valores reais (inteiros e não inteiros) usa-se a representação em ponto flutuante normalizada

Nesta abordagem o número é expresso através de uma parte fracionária, chamada de mantissa e uma parte inteira que corresponde ao expoente do número mais o sinal do número.

$$x = \pm 0.d_1d_2\cdots d_p \times B^{e}$$

Exemplo:x = 12.345

$$x = +0.12345 \times 10^{+2}$$

Um número  $x \in \mathbb{R}$  armazenado neste sistema tem seguinte formato:

$$x = \pm 0.d_1d_2\cdots d_p \times B^{\mathbf{e}}$$

onde

$$d_{i's}$$
: dígitos da parte fracionária (mantissa)

$$p$$
: qte de dígitos na mantissa,  
 $d_1 \neq 0, 0 < d_i < B - 1, i = 2, \dots, p$ 

$$\pm$$
 : sinal do número

Um sistema de ponto flutuante é comumennte representado por

$$F = F(B, p, e_1, e_2),$$

onde p = é a quantidade de dígitos da mantissa. onde  $e_1, e_2 =$  menor e maior expoente possíveis de serem armazenados.

#### Outros exemplos

$$\pm 0.d_1d_2\cdots d_p\times B^{\mathbf{e}}$$

a) 
$$y = 12345000000$$

$$y = +0.12345 \times 10^{+11}$$

b) 
$$z = 0.0000012345$$

$$z = +0.12345 \times 10^{-6}$$

### Sistema de representação em ponto flutuante

Haverá na "palavra" um "espaço " reservado para o sinal, outro para o expoente do número (e o seu sinal) e o restante para para armazenar os dígitos do número.

Ex 1:  

$$x = 12.345 \rightarrow +0.123450000....0*10^{(2)}$$

#### Mais exemplos:

Suponha uma máquina que opere na base B=10, com mantissa de p=5 dígitos, e expoentes  $e_1=-9, e_2=+9$   $F(B=10, p=5, e_1=-9, e_2=+9)$  Os valores, abaixo, serão representados, nesta máquina, por:


Valor real | Valor armazenado(
$$x_{maq}$$
)  
 $x \mid \pm 0.d_1d_2d_3d_4d_5 \times 10^e$   
 $12.345 \mid +.12345 \times 10^{+2} \rightarrow 12.345$   
 $12.3 \mid +.12300 \times 10^{+2} \rightarrow 12.3$   
 $0.12345 \mid +.12345 \times 10^0 \rightarrow 0.12345$ 

Nesta máquina ( $F(B = 10, p = 5, e_1 = -9, e_2 = +9)$ ) os valores serão representados por

Nesta máquina  $F(B = 10, p = 5, e_1 = -9, e_2 = +9)$ Nos positivos:

O menor valor positivo ( $x_{min}$ ):  $+0.10000 \times 10^{-9}$ 

O maior valor positivo ( $x_{max}$ ) :+0.99999 × 10<sup>9</sup>



Simétrico nos negativos

O menor (em módulo) valor negativo  $(-x_{min})$ :  $-0.10000 \times 10^{-9}$  O maior (em módulo) valor negativo  $(-x_{max})$ :  $-0.99999 \times 10^{9}$ 

#### Sistema de Ponto Flutuante

- Intervalo I:  $(-x_{max}, -x_{min}) \cup \{0\} \cup (x_{min}, x_{max})$ .
- Existe apenas um quantidade finita de valores que podem ser representados na faixa "representável" (em I).
- A MAIORIA dos valores que precisam ser respresentados serão armazenados via uma aproximação!.
- Assim haverá (na maioria das vezes) ARREDONDAMENTOS, causando os erros de arredondamentos

### Estratégias de arredondamento

• ESTRATÉGIA de arredondamento por CORTE (chopping) (ou ainda por falta):

Despreza se todos os dígitos que não cabem na mantissa, a partir do (p+1) *ésimo* dígito.

ex: Se 
$$F(B = 10, p = 5, e_1, e_2)$$
  
12.3456  $\rightarrow +.12345 \times 10^{+2} \rightarrow 12.345$ 

## Estratégias de arredondamento

• ESTRATÉGIA de arredondamento por CORTE (chopping) (ou ainda por falta):

Despreza se todos os dígitos que não cabem na mantissa, a partir do (p+1) *ésimo* dígito.

ex: Se 
$$F(B = 10, p = 5, e_1, e_2)$$
  
12.3456  $\rightarrow +.12345 \times 10^{+2} \rightarrow 12.345$ 

• ESTRATÉGIA de arredondamento para o MAIS PRÓXIMO Verifica se o valor do (p+1) ésimo dígito SE o (p+1) ésimo >= 5 soma se 1 ao p ésimo dígito e despreza-se todos os demais (a partir do p+1 ésimo) SENÃO despreza se todos os demais dígitos (a partir do (p+1) ésimo)

ex: 
$$12.3458 \rightarrow +.12346 \times 10^{+2} \rightarrow 12.346$$

#### Mais exemplos:

Suponha que se tenha uma máquina, que opere na base B=10, com mantissa de p=2 dígitos, e expoentes  $e_1=-9$ ,  $e_2=+9$  e arredondamento para o mais próximo.

$$F(10,2,-9,+9)$$

Os valores serão representados, nesta máquina, via:

Valor real 
$$\mid$$
 Valor armazenado( $x_{maq}$ )  
 $\times \mid \pm 0.d_1d_2 \times 10^e$   
 $1.72 \mid +.17 \times 10^{+1} \rightarrow 1.7$   
 $1.713 \mid +.17 \times 10^{+1} \rightarrow 1.7$ 

#### Mais exemplos:


Suponha que se tenha uma máquina, que opere na base B=10, com mantissa de p=2 dígitos, e expoentes  $e_1=-9$ ,  $e_2=+9$  e arredondamento para o mais próximo.

$$F(10, 2, -9, +9)$$

Os valores serão representados, nesta máquina, via:

Valor real | Valor armazenado(
$$x_{maq}$$
)  
 $x \mid \pm 0.d_1d_2 \times 10^e$   
 $1.72 \mid +.17 \times 10^{+1} \rightarrow 1.7$   
 $1.713 \mid +.17 \times 10^{+1} \rightarrow 1.7$   
 $1.78 \mid +.18 \times 10^{+1} \rightarrow 1.8$   
 $1.7632 \mid +.18 \times 10^{+1} \rightarrow 1.8$   
 $1.75 \mid +.18 \times 10^{+1} \rightarrow 1.8$ 

$$1.72 \rightarrow +.17 \times 10^{+1} \rightarrow 1.7$$
  
 $13.1 \rightarrow +.13 \times 10^{+1} \rightarrow 13$ 



#### Continuando com F(10, 2, -9, +9). Mais exemplos:

Valor real | Valor armazenado(
$$x_{maq}$$
)  
13.1 |  $+.13 \times 10^{+2} \rightarrow 13$   
13.617 |  $+.14 \times 10^{+2} \rightarrow 14$   
14.3 |  $+.14 \times 10^{+2} \rightarrow 14$   
13.99 |  $+.14 \times 10^{+2} \rightarrow 14$ 

### Continuando com F(10, 2, -9, +9). Mais exemplos:

Valor real | Valor armazenado(
$$x_{maq}$$
)
$$13.1 | +.13 \times 10^{+2} \rightarrow 13$$

$$13.617 | +.14 \times 10^{+2} \rightarrow 14$$

$$14.3 | +.14 \times 10^{+2} \rightarrow 14$$

$$13.99 | +.14 \times 10^{+2} \rightarrow 14$$

$$136.12 | +.14 \times 10^{+3} \rightarrow 140$$

$$144.12 | +.14 \times 10^{+3} \rightarrow 140$$


$$148.12 | +.14 \times 10^{+3} \rightarrow 150$$


$$0.000036 | +.36 \times 10^{-4} \rightarrow 0.000036$$


$$0.0000364 | +.36 \times 10^{-4} \rightarrow 0.000036$$

$$0.000037 | +.37 \times 10^{-4} \rightarrow 0.000037$$

$$110 \rightarrow +.11 \times 10^{+3} \rightarrow 110$$
  
 $111 \rightarrow +.11 \times 10^{+3} \rightarrow 110$ 







O erro na aproximação pela máquina  $F(B=10,2,e_1,e_2) 
ightarrow \pm 0.d_1d_2 imes 10^{-9}$ 

$$x = 1.74$$

Erro verdadeiro (em módulo) é:

$$|E_v| = |ValorReal - ValorRepresentado| = 1.74 - 1.7 = 0.04$$

Erro relativo (em módulo):

$$|E_{rel}| = |\frac{0.4}{1.74}| = 0.0229 \Rightarrow 2,29\%$$

### O erro na aproximação pela máquina

$$x = 174$$

Erro verdadeiro (em módulo) é:

$$|E_{\nu}| = |ValorReal - ValorRepresentado| = |174 - 170| = 4$$

$$|E_{rel}| = |\frac{4}{174}| = 0.0229 \Rightarrow 2,29\%$$

#### O erro contido na aproximação pela máquina em

x=0.0000174

Erro verdadeiro (em módulo) é:

$$|E_{\nu}| = |ValorReal - ValorRepresentado| = |0.0000174 - 0.000017| =$$

$$|E_{rel}| = |\frac{0.0000004}{0.000174}| = 0.0229 \Rightarrow 2,29\%$$

## Precisão da máquina

O sistema de ponto flutuante permite que a precisão seja a mesma independente da grandeza do número.

A precisão  $(\epsilon)$  da máquina corresponde ao erro relativo máximo (em módulo) que a máquina pode cometer ao representar os valores reais.

$$|E_{rel}| = |rac{ValorReal - ValorRepresentado}{ValorReal}| <= \epsilon$$

Torna se uma forma versátil para a representação de valores tão distintos! Fazendo uma analogia: se fosse necessário medir distâncias o sistema comporta-se como um micrômetro, uma trena, um teodolito e assim por diante dependendo da grandeza

#### RESUMINDO

- (1) Os valores reais são representados no computador usando o sistema de ponto flutuante e ao serem armazenados sofrem erros de arredondamento.
- (2) A precisão ( $\epsilon$ ) do computador corresponde ao erro relativo máximo (em módulo) que a máquina pode cometer ao representar os valores reais.

$$|E_{rel}| = |rac{ValorReal - ValorRepresentado}{ValorReal}| <= \epsilon$$

Esta precisão depende do tamanho da mantissa.

### Bibliografia Básica

- [2] Métodos Numéricos para Engenharia, Steven C. Chapa e Raymond P. Canale, Ed. McGraw-Hill, 5<sup>a</sup> Ed., 2008.
- [1] Algoritmos Numéricos, Frederico F. Campos, Filho 2<sup>a</sup> Ed., Rio de Janeiro, LTC, 2007.
- [3] Cálculo Numérico Aspectos Teóricos e Computacionais, Márcia A. G. Ruggiero e Vera Lúcia da Rocha Lopes, Ed. Pearson Education, 2ª Ed., 1996.