

Algoritmos Numéricos 2^a edição

Capítulo 4: Ajuste de curvas

Capítulo 4: Ajuste de curvas

4.1 Regressão linear simples

4.2 Qualidade do ajuste

4.3 Regressão linear múltipla

4.4 Ajuste via decomposição em valores singulares

4.5 Diferença entre regressão e interpolação

4.6 Exemplos de aplicação: tensão-deformação de aço e produto iônico da água

4.7 Exercícios

Relações entre variáveis

- Relações entre variáveis envolvidas em um experimento: determinísticas, semideterminísticas e empíricas.
- Determinísticas: variáveis relacionadas entre si por algum tipo de lei expressa por uma fórmula matemática precisa.
- Variação nas observações é atribuída a erros experimentais.
- Semideterminísticas: alguma teoria prescreve uma forma para a relação entre as variáveis.
- Realizar experimentos para obter informações acerca de parâmetros do modelo.
- Empíricas: relações entre variáveis envolvidas não são conhecidas.

Relações entre variáveis cont.

- Determinar uma fórmula matemática que relacione as variáveis.
- Diagrama de dispersão: gráfico com valores observados das variáveis fornece idéia da relação entre elas com algumas variações aleatórias.
- Somente com suficiente conhecimento sobre uma relação empírica é possível desenvolver uma teoria que conduza a uma fórmula matemática (semideterminística).

Perturbação na verdadeira relação

- Precisão limitada dos instrumentos de medida.
- Perturbações incontrolláveis das condições experimentais.
- Fatores que introduzem erros nos dados.
- Variação das leituras de uma variável: erros de medida experimentais e a outras variáveis, cujos valores se alteram durante um experimento.

Objetivo do ajuste de curvas

- Relacionar, por um modelo matemático, a variável resposta (ou dependente) com o conjunto de variáveis explicativas (ou independentes).
- Para ter controle.
- Determinar algum parâmetro.
- Fazer previsão acerca do comportamento da variável resposta.

Análise de regressão

- Conjunto de métodos:
- Estimativa de parâmetros.
- Análise de variância e de resíduos.
- Testes de hipóteses.
- Lidam com formulação de modelos matemáticos que descrevem relações entre variáveis.
- Modelos com propósito de predição e outras inferências estatísticas.
- Ajuste de curvas: determinação de parâmetros de modelos semideterminísticos.

Regressão linear simples

- Relações mais simples entre duas variáveis são as relações lineares.
- Variável independente ou explicativa x é relacionada com a variável dependente ou resposta y por meio de um modelo linear


$$y = b_0 + b_1x.$$

- Esboçar os dados em um gráfico de coordenadas cartesianas denominado diagrama de dispersão.
- Diagrama mostra a natureza da relação intrínseca entre as duas variáveis estudadas.

Diagrama de dispersão

- Variáveis explicativas x e as respostas y

| | | | | | |
|-----|-----|-----|-----|-----|-----|
| x | 0,3 | 2,7 | 4,5 | 5,9 | 7,8 |
| y | 1,8 | 1,9 | 3,1 | 3,9 | 3,3 |

 \Leftarrow 

Retas de regressão

- Modelo simples que relaciona duas variáveis x e y

$$y = \beta_0 + \beta_1 x + \epsilon.$$

- β_0 e β_1 : parâmetros a serem estimados.
- ϵ : componentes desconhecidos e aleatórios de erro que se sobrepõem à verdadeira relação linear.
- Como estimar os parâmetros β_0 e β_1 ?

Modelo 1

- Primeira tentativa: obtida por um polinômio interpolador linear.
- Não se pode traçar uma única reta que passe por todos os pontos simultaneamente.
- Reta esboçada a partir de dois pontos quaisquer, por exemplo, o primeiro e o último

| | | |
|-----|-----|-----|
| x | 0,3 | 7,8 |
| y | 1,8 | 3,3 |

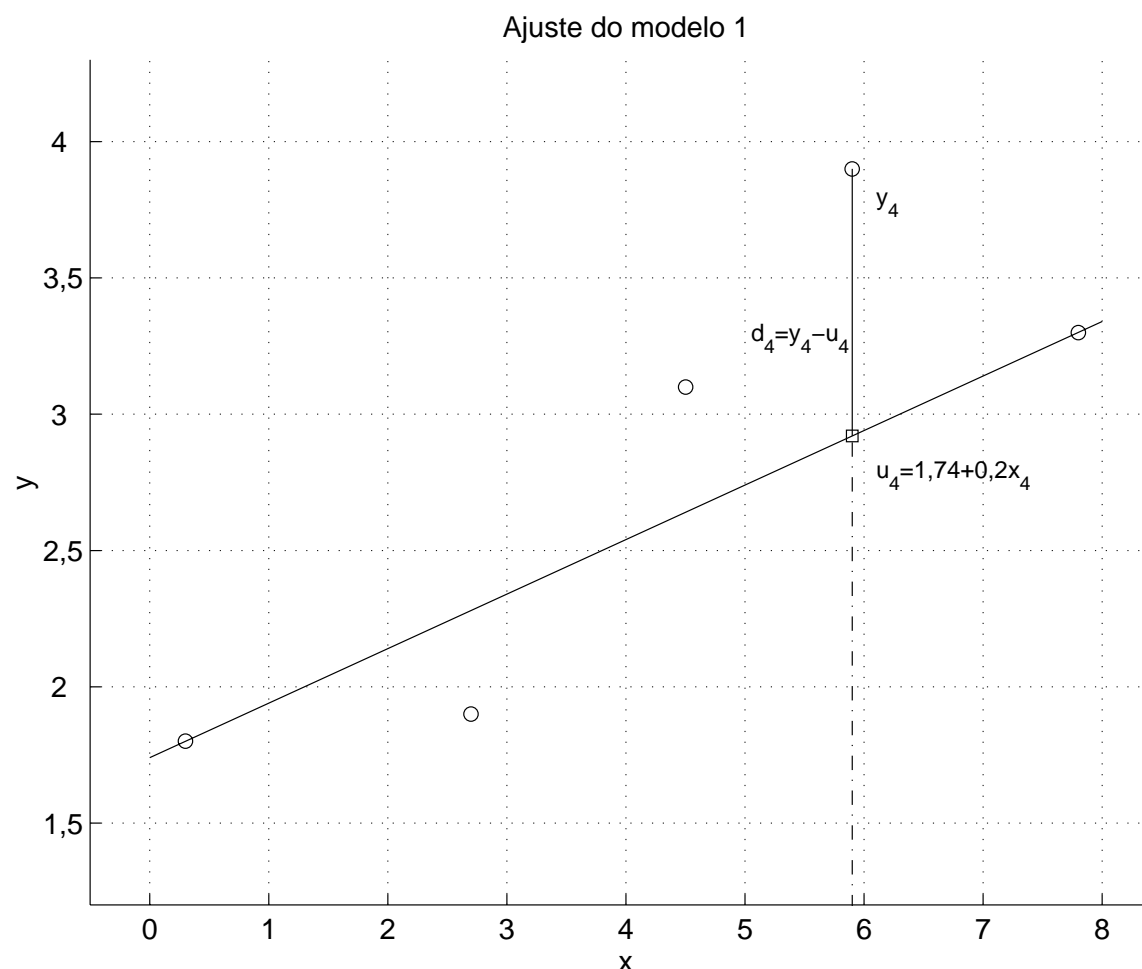
- Equação da reta $u(x)$ que passa por estes dois pontos

$$u(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0}(x - x_0) = 1,8 + \frac{3,3 - 1,8}{7,8 - 0,3}(x - 0,3) = 1,8 + 0,2(x - 0,3) \leadsto$$

$$u(x) = 1,74 + 0,2x.$$

Gráfico do modelo 1

- Modelo 1: $u = 1,74 + 0,2x$.
- $d_i = y_i - u_i$: distância vertical entre o i -ésimo ponto dado y_i e o ponto $u_i = 1,74 + 0,2x_i$ de mesma abscissa x_i .



Qualidade do modelo 1

- Qualidade do ajuste: soma de todas as n distâncias verticais de y_i aos pontos da reta $u_i = 1,74 + 0,2x_i$, considerando valores positivos de d_i

$$D(b_0, b_1) = \sum_{i=1}^n (y_i - u_i)^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2 = \sum_{i=1}^n d_i^2,$$

$$D(1,74; 0,2) = \sum_{i=1}^5 (y_i - 1,74 - 0,2x_i)^2.$$

- Resultados do ajuste pelo modelo 1: $u = 1,74 + 0,2x$.

| i | x_i | y_i | u_i | d_i |
|-------------------------|-------|-------|-------|-------|
| 1 | 0,3 | 1,8 | 1,80 | 0,00 |
| 2 | 2,7 | 1,9 | 2,28 | -0,38 |
| 3 | 4,5 | 3,1 | 2,64 | 0,46 |
| 4 | 5,9 | 3,9 | 2,92 | 0,98 |
| 5 | 7,8 | 3,3 | 3,30 | 0,00 |
| $D(1,74; 0,2) = 1,3164$ | | | | |

Modelo 2

- Segunda tentativa: também obtida por polinômio interpolador linear.
- Traçar a reta por dois pontos quaisquer.
- Pontos escolhidos não pertencem ao diagrama de dispersão, por exemplo,

| | | |
|-----|---|---|
| x | 2 | 6 |
| y | 2 | 3 |


- Equação da reta $u(x)$ que passa por esses pontos

$$u(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0}(x - x_0) = 2 + \frac{3 - 2}{6 - 2}(x - 2) = 2 + 0,25(x - 2) \leadsto$$

$$u(x) = 1,5 + 0,25x.$$

Gráfico do modelo 2

- Modelo 2: $u = 1,5 + 0,25x$.



Qualidade do modelo 2

- Resultados do ajuste do modelo 2

| i | x_i | y_i | u_i | d_i |
|-------------------------|-------|-------|-------|--------|
| 1 | 0,3 | 1,8 | 1,575 | 0,225 |
| 2 | 2,7 | 1,9 | 2,175 | -0,275 |
| 3 | 4,5 | 3,1 | 2,625 | 0,475 |
| 4 | 5,9 | 3,9 | 2,975 | 0,925 |
| 5 | 7,8 | 3,3 | 3,450 | -0,150 |
| $D(1,5; 0,25) = 1,2300$ | | | | |

- Modelo 2 é mais adequado

$$D(1,5; 0,25) = 1,2300 < D(1,74; 0,2) = 1,3164.$$

Método dos quadrados mínimos

- Qualidade do ajuste depende da equação da reta escolhida.
- Reta que não passa por dois pontos do diagrama de dispersão produziu resultado melhor.
- Por onde se deve traçar a reta de modo a obter o menor valor do desvio D ?
- Método dos quadrados mínimos consiste em encontrar uma estimativa da reta

$$u = \beta_0 + \beta_1 x.$$

- Produzir o menor valor possível do desvio

$$D(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - u_i)^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Dedução dos quadrados mínimos

- Função desvio

$$D(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - u_i)^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

- Derivadas parciais

$$\frac{\partial D(\beta_0, \beta_1)}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) \quad \text{e}$$

$$\frac{\partial D(\beta_0, \beta_1)}{\partial \beta_1} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i.$$

Mínimo da função $D(\beta_0, \beta_1)$

- Valores para os quais a função $D(\beta_0, \beta_1)$ possui um mínimo: onde as derivadas parciais se anulam.
- Se $D(b_0, b_1)$ for o ponto de mínimo de $D(\beta_0, \beta_1)$

$$-2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0 \longrightarrow \sum_{i=1}^n b_0 + \sum_{i=1}^n b_1 x_i = \sum_{i=1}^n y_i \quad \text{e}$$

$$-2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) x_i = 0 \longrightarrow \sum_{i=1}^n b_0 x_i + \sum_{i=1}^n b_1 x_i^2 = \sum_{i=1}^n x_i y_i.$$

Reta de quadrados mínimos

- Na forma matricial e simplificando a notação

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}. \quad (1)$$

- Valores em que $D(\beta_0, \beta_1)$ apresenta um mínimo são obtidos pela solução do sistema linear (1), denominado equações normais.
- Utilizando as operações l-elementares

$$\begin{bmatrix} n & \sum x_i \\ 0 & -\frac{1}{n} (\sum x_i)^2 + \sum x_i^2 \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ -\frac{1}{n} \sum x_i \sum y_i + \sum x_i y_i \end{bmatrix}.$$

- Parâmetros da reta de quadrados mínimos $u(x) = b_0 + b_1 x$

$$b_1 = \frac{\sum x_i \sum y_i - n \sum x_i y_i}{(\sum x_i)^2 - n \sum x_i^2} \quad \text{e} \quad b_0 = \frac{\sum y_i - b_1 \sum x_i}{n}. \quad (2)$$

Exemplo: ajuste linear por quadrados mínimos

Exemplo 1 Calcular a reta de quadrados mínimos utilizando dados da tabela

| | | | | | |
|-----|-----|-----|-----|-----|-----|
| x | 0,3 | 2,7 | 4,5 | 5,9 | 7,8 |
| y | 1,8 | 1,9 | 3,1 | 3,9 | 3,3 |

- Valores dos somatórios

| i | x_i | y_i | x_i^2 | $x_i y_i$ | y_i^2 |
|----------|-------|-------|---------|-----------|---------|
| 1 | 0,3 | 1,8 | 0,09 | 0,54 | 3,24 |
| 2 | 2,7 | 1,9 | 7,29 | 5,13 | 3,61 |
| 3 | 4,5 | 3,1 | 20,25 | 13,95 | 9,61 |
| 4 | 5,9 | 3,9 | 34,81 | 23,01 | 15,21 |
| 5 | 7,8 | 3,3 | 60,84 | 25,74 | 10,89 |
| Σ | 21,2 | 14,0 | 123,28 | 68,37 | 42,56 |

\Leftarrow

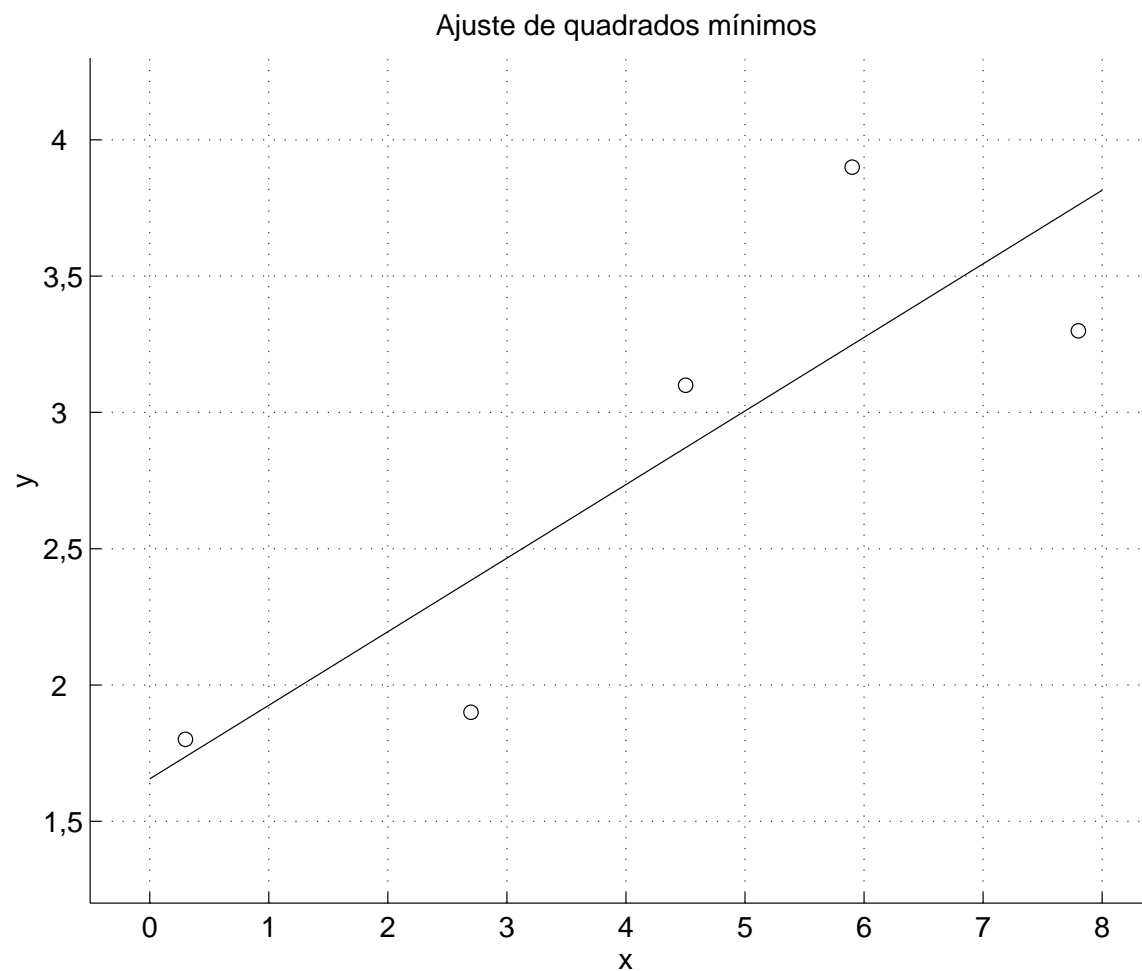
- Solução de quadrados mínimos

$$b_1 = \frac{\sum x_i \sum y_i - n \sum x_i y_i}{(\sum x_i)^2 - n \sum x_i^2} = \frac{21,2 \times 14,0 - 5 \times 68,37}{(21,2)^2 - 5 \times 123,28} \leadsto b_1 = 0,2698 \text{ e}$$

$$b_0 = \frac{\sum y_i - b_1 \sum x_i}{n} = \frac{14,0 - 0,2698 \times 21,2}{5} \leadsto b_0 = 1,6560.$$

Ajuste por quadrados mínimos

- Reta de quadrados mínimos: $u = 1,6560 + 0,2698x$



Qualidade do modelo

- Resultados do ajuste por quadrados mínimos

| i | x_i | y_i | u_i | d_i |
|------------------------------|-------|-------|--------|---------|
| 1 | 0,3 | 1,8 | 1,7369 | 0,0631 |
| 2 | 2,7 | 1,9 | 2,3845 | -0,4845 |
| 3 | 4,5 | 3,1 | 2,8701 | 0,2299 |
| 4 | 5,9 | 3,9 | 3,2478 | 0,6522 |
| 5 | 7,8 | 3,3 | 3,7604 | -0,4604 |
| $D(1,6560; 0,2698) = 0,9289$ | | | | |

- Melhor dos três modelos propostos

$$D(1,6560; 0,2698) = 0,9289 < D(1,5; 0,25) = 1,2300 < D(1,74; 0,2) = 1,3164.$$

Coeficiente de determinação

- Seja a expressão para o i -ésimo ponto

$$y_i - \bar{y} = (y_i - u_i) + (u_i - \bar{y}),$$

- sendo $u_i = b_0 + b_1 x_i$ e $\bar{y} = \frac{1}{n} \left(\sum_{i=1}^n y_i \right)$.

- Tomando o quadrado em ambos os termos da igualdade

$$(y_i - \bar{y})^2 = (y_i - u_i)^2 + (u_i - \bar{y})^2 + 2(y_i - u_i)(u_i - \bar{y}).$$

- Calculando o somatório para $i = 1, 2, \dots, n$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - u_i)^2 + \sum_{i=1}^n (u_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - u_i)(u_i - \bar{y}). \quad (3)$$

- Pode-se mostrar que $\sum_{i=1}^n (y_i - u_i)(u_i - \bar{y}) = 0$.

Soma de quadrados

- Somatórios

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - u_i)^2 + \sum_{i=1}^n (u_i - \bar{y})^2.$$

- SQTot (soma de quadrados total)

$$\sum_{i=1}^n (y_i - \bar{y})^2.$$

- SQRes (soma de quadrados residual)

$$\sum_{i=1}^n (y_i - u_i)^2.$$

- SQReg (soma de quadrados devido à regressão)

$$\sum_{i=1}^n (u_i - \bar{y})^2.$$

Cálculo de r^2

- Qualidade do ajuste do modelo $u = b_0 + b_1x$ aos dados

$$r^2 = \frac{\text{SQReg}}{\text{SQTot}} = \frac{\text{SQTot} - \text{SQRes}}{\text{SQTot}} \leadsto r^2 = 1 - \frac{\text{SQRes}}{\text{SQTot}}.$$

- r^2 : coeficiente de determinação

$$0 \leq r^2 \leq 1.$$

- Quanto mais próximo r^2 for da unidade, melhor será o ajuste.

Cálculo de r^2 cont.

- Considerando que

$$D(b_0, b_1) = \sum_{i=1}^n (y_i - u_i)^2 = \sum_{i=1}^n d_i^2, \quad (4)$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - 2\bar{y} \sum_{i=1}^n y_i + n\bar{y}^2 \rightsquigarrow \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - \frac{1}{n} \left(\sum_{i=1}^n y_i \right)^2.$$

- Coeficiente de determinação

$$r^2 = 1 - \frac{D(b_0, b_1)}{\sum y_i^2 - \frac{1}{n} (\sum y_i)^2}. \quad (5)$$

- Proporção da variação total dos dados em torno da média \bar{y} que é explicada pelo modelo de regressão.

Variância residual

- Variância residual σ^2

$$\sigma^2 = \frac{D(b_0, b_1)}{n - p}. \quad (6)$$

- $D(b_0, b_1)$: somatório dos desvios (dado por (4)).
- n : número de pontos e
- p : número de parâmetros estimados.
- No caso de regressão linear simples $u = b_0 + b_1x$: $p = 2$.
- Tanto o numerador quanto o denominador de (6) irão diminuir se forem introduzidos mais parâmetros no modelo.
- Redução global de σ^2 que definirá se mais parâmetros devem ou não ser incorporados ao modelo.

Exemplo: qualidade do ajuste

Exemplo 2 Calcular o coeficiente de determinação e a variância residual da tabela do exemplo anterior

| i | x_i | y_i | u_i | d_i |
|------------------------------|-------|-------|--------|---------|
| 1 | 0,3 | 1,8 | 1,7369 | 0,0631 |
| 2 | 2,7 | 1,9 | 2,3845 | -0,4845 |
| 3 | 4,5 | 3,1 | 2,8701 | 0,2299 |
| 4 | 5,9 | 3,9 | 3,2478 | 0,6522 |
| 5 | 7,8 | 3,3 | 3,7604 | -0,4604 |
| $D(1,6560; 0,2698) = 0,9289$ | | | | |

- Coeficiente de determinação

$$r^2 = 1 - \frac{D(b_0, b_1)}{\sum y_i^2 - \frac{1}{n} (\sum y_i)^2} = 1 - \frac{0,9289}{42,56 - (14,0)^2/5} \leadsto r^2 = 0,7235.$$

- Variância residual

$$\sigma^2 = \frac{D(b_0, b_1)}{n - p} = \frac{0,9289}{5 - 2} \leadsto \sigma^2 = 0,3096.$$

Exemplo: reta de quadrados mínimos

Exemplo 3 Calcular a reta de quadrados mínimos

| | | | | | | | | |
|-----|-----|-----|-----|-----|------|------|------|------|
| x | 1,2 | 2,5 | 3,0 | 4,1 | 6,2 | 7,1 | 8,8 | 9,5 |
| y | 6,8 | 6,1 | 9,9 | 9,7 | 12,1 | 17,9 | 18,0 | 21,5 |

- Dispositivo para regressão linear simples por quadrados mínimos

| i | x_i | y_i | x_i^2 | $x_i y_i$ | y_i^2 | u_i | d_i | d_i^2 |
|----------|-------|-------|---------|-----------|---------|----------|---------|---------|
| 1 | 1,2 | 6,8 | 1,44 | 8,16 | 46,24 | 5,4037 | 1,3963 | 1,9497 |
| 2 | 2,5 | 6,1 | 6,25 | 15,25 | 37,21 | 7,7330 | -1,6330 | 2,6667 |
| 3 | 3,0 | 9,9 | 9,00 | 29,70 | 98,01 | 8,6289 | 1,2711 | 1,6157 |
| 4 | 4,1 | 9,7 | 16,81 | 39,77 | 94,09 | 10,5999 | -0,8999 | 0,8098 |
| 5 | 6,2 | 12,1 | 38,44 | 75,02 | 146,41 | 14,3627 | -2,2627 | 5,1198 |
| 6 | 7,1 | 17,9 | 50,41 | 127,09 | 320,41 | 15,9753 | 1,9247 | 3,7045 |
| 7 | 8,8 | 18,0 | 77,44 | 158,40 | 324,00 | 19,0213 | -1,0213 | 1,0431 |
| 8 | 9,5 | 21,5 | 90,25 | 204,25 | 462,25 | 20,2756 | 1,2244 | 1,4992 |
| Σ | 42,4 | 102,0 | 290,04 | 657,64 | 1528,62 | 102,0003 | -0,0004 | 18,4085 |

Exemplo: reta de quadrados mínimos cont.

- Cálculo dos parâmetros

$$b_1 = \frac{\sum x_i \sum y_i - n \sum x_i y_i}{(\sum x_i)^2 - n \sum x_i^2} = \frac{42,4 \times 102,0 - 8 \times 657,64}{(42,4)^2 - 8 \times 290,04} \leadsto b_1 = 1,7918$$

$$b_0 = \frac{\sum y_i - b_1 \sum x_i}{n} = \frac{102,0 - 1,7918 \times 42,4}{8} \leadsto b_0 = 3,2535.$$

- Coeficiente de determinação

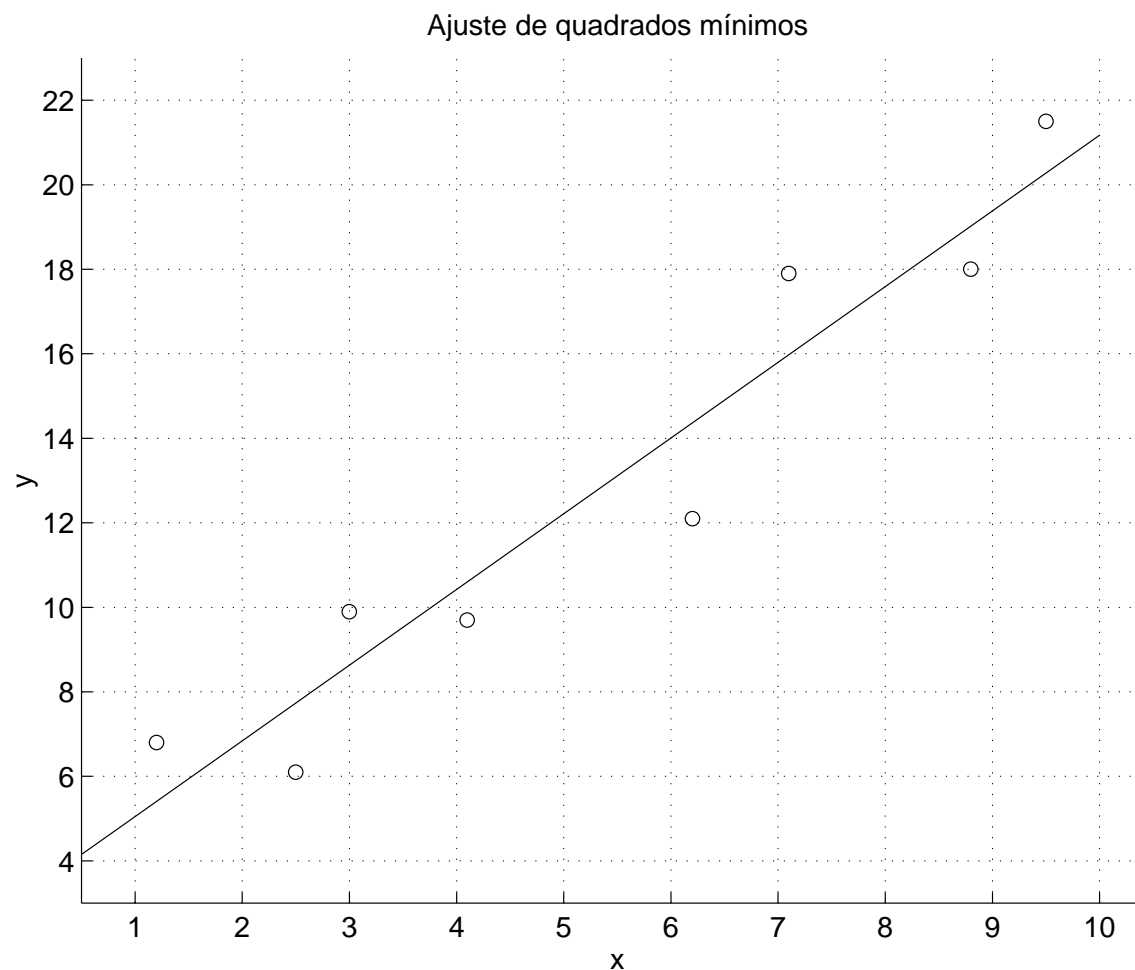
$$r^2 = 1 - \frac{D(b_0, b_1)}{\sum y_i^2 - \frac{1}{n} (\sum y_i)^2} = 1 - \frac{18,4085}{1528,62 - (102,0)^2/8} \leadsto r^2 = 0,9193.$$

- Variância residual

$$\sigma^2 = \frac{D(b_0, b_1)}{n - p} = \frac{18,4085}{8 - 2} \leadsto \sigma^2 = 3,0681.$$

Gráfico da reta de quadrados mínimos

- Equação de quadrados mínimos: $u = 3,2535 + 1,7918x$.



Regressão linear múltipla

- Modelo mais completo que relaciona a variável resposta y com as p variáveis explicativas x_i

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \epsilon, \quad (7)$$

- β_i , $i = 0, 1, \dots, p$: parâmetros a serem estimados e
- ϵ : variável aleatória desconhecida que interfere na verdadeira relação linear.
- Método dos quadrados mínimos utilizado para estimar os $p + 1$ parâmetros β_i

$$D(\beta_0, \beta_1, \beta_2, \dots, \beta_p) = \sum_{i=1}^n (y_i - u_i)^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_p x_{ip})^2,$$

- sendo x_{ij} a i -ésima observação da j -ésima variável explicativa.

Método dos quadrados mínimos

- Derivadas parciais da função desvio $D(\beta_0, \beta_1, \beta_2, \dots, \beta_p)$

$$\frac{\partial D(\beta_0, \beta_1, \beta_2, \dots, \beta_p)}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_p x_{ip}),$$

$$\frac{\partial D(\beta_0, \beta_1, \beta_2, \dots, \beta_p)}{\partial \beta_1} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_p x_{ip}) x_{i1},$$

$$\frac{\partial D(\beta_0, \beta_1, \beta_2, \dots, \beta_p)}{\partial \beta_2} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_p x_{ip}) x_{i2},$$

$$\vdots$$

$$\frac{\partial D(\beta_0, \beta_1, \beta_2, \dots, \beta_p)}{\partial \beta_p} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \dots - \beta_p x_{ip}) x_{ip}.$$

Mínimo da função desvio D

- Se $D(b_0, b_1, b_2, \dots, b_p)$ for o ponto de mínimo da função $D(\beta_0, \beta_1, \beta_2, \dots, \beta_p)$

$$\frac{\partial D(b_0, b_1, b_2, \dots, b_p)}{\partial \beta_i} = 0, \quad i = 0, 1, \dots, p$$

$$-2 \sum_{i=1}^n (y_i - b_0 - b_1 x_{i1} - b_2 x_{i2} - \dots - b_p x_{ip}) = 0 \leadsto \sum_{i=1}^n b_0 + \sum_{i=1}^n b_1 x_{i1} + \sum_{i=1}^n b_2 x_{i2} + \dots + \sum_{i=1}^n b_p x_{ip} = \sum_{i=1}^n y_i,$$

$$-2 \sum_{i=1}^n (y_i - b_0 - b_1 x_{i1} - b_2 x_{i2} - \dots - b_p x_{ip}) x_{i1} = 0 \leadsto \sum_{i=1}^n b_0 x_{i1} + \sum_{i=1}^n b_1 x_{i1} x_{i1} + \sum_{i=1}^n b_2 x_{i2} x_{i1} + \dots + \sum_{i=1}^n b_p x_{ip} x_{i1} = \sum_{i=1}^n x_{i1} y_i,$$

$$-2 \sum_{i=1}^n (y_i - b_0 - b_1 x_{i1} - b_2 x_{i2} - \dots - b_p x_{ip}) x_{i2} = 0 \leadsto \sum_{i=1}^n b_0 x_{i2} + \sum_{i=1}^n b_1 x_{i1} x_{i2} + \sum_{i=1}^n b_2 x_{i2} x_{i2} + \dots + \sum_{i=1}^n b_p x_{ip} x_{i2} = \sum_{i=1}^n x_{i2} y_i,$$

$$\vdots$$

$$-2 \sum_{i=1}^n (y_i - b_0 - b_1 x_{i1} - b_2 x_{i2} - \dots - b_p x_{ip}) x_{ip} = 0 \leadsto \sum_{i=1}^n b_0 x_{ip} + \sum_{i=1}^n b_1 x_{i1} x_{ip} + \sum_{i=1}^n b_2 x_{i2} x_{ip} + \dots + \sum_{i=1}^n b_p x_{ip} x_{ip} = \sum_{i=1}^n x_{ip} y_i.$$

Equações normais

- Sistema de equações lineares na forma matricial

$$\begin{bmatrix} n & \sum x_{i1} & \sum x_{i2} & \cdots & \sum x_{ip} \\ \sum x_{i1} & \sum x_{i1}x_{i1} & \sum x_{i2}x_{i1} & \cdots & \sum x_{ip}x_{i1} \\ \sum x_{i2} & \sum x_{i1}x_{i2} & \sum x_{i2}x_{i2} & \cdots & \sum x_{ip}x_{i2} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ \sum x_{ip} & \sum x_{i1}x_{ip} & \sum x_{i2}x_{ip} & \cdots & \sum x_{ip}x_{ip} \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_p \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_{i1}y_i \\ \sum x_{i2}y_i \\ \vdots \\ \sum x_{ip}y_i \end{bmatrix}. \quad (8)$$

- Vetor solução b $((p + 1) \times 1)$ do sistema de equações lineares fornece os parâmetros para a equação de quadrados mínimos

$$u = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p.$$

Regressão linear múltipla: qualidade do ajuste

- Coeficiente de determinação

$$r^2 = 1 - \frac{D(b_0, b_1, \dots, b_p)}{\sum y_i^2 - \frac{1}{n} (\sum y_i)^2}. \quad (9)$$

- Variância residual

$$\sigma^2 = \frac{D(b_0, b_1, b_2, \dots, b_p)}{n - p}. \quad (10)$$

Regressão polinomial

- Caso particular da regressão linear múltipla.
- Relaciona a variável resposta y com uma variável explicativa x

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_g x^g + \epsilon.$$

- Equações normais

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \cdots & \sum x_i^g \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \cdots & \sum x_i^{g+1} \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \cdots & \sum x_i^{g+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_i^g & \sum x_i^{g+1} & \sum x_i^{g+2} & \cdots & \sum x_i^{2g} \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_g \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \\ \vdots \\ \sum x_i^g y_i \end{bmatrix}. \quad (11)$$

Algoritmo: regressão linear múltipla e polinomial via equações normais

Algoritmo Regressão_linear_EN

```

{ Objetivo: Calcular parâmetros de quadrados mínimos de modelo linear múltiplo }
{ via equações normais }
parâmetros de entrada  $n, v, p, x, y$ 
    { número de pontos, número de variáveis, número de parâmetros, }
    { variáveis explicativas e variáveis respostas }
parâmetros de saída  $b, r2, sigma2, CondErro$ 
    { coef. de regressão, coef. de determinação, variância residual e condição de erro }
se  $v > 1$  e  $v + 1 \neq p$  então  $CondErro \leftarrow 1$ , abandone, fimse
     $CondErro \leftarrow 0$ ;  $vp1 \leftarrow v + 1$ ;  $pm1 \leftarrow p - 1$ 
    para  $i \leftarrow 1$  até  $n$  faça { inclusão de uma coluna de 1's relativa à  $b_0$  }
        para  $j \leftarrow vp1$  até 2 passo -1 faça  $x(i, j) \leftarrow x(i, j-1)$  fimpara;  $x(i, 1) \leftarrow 1$ 
    fimpara
    se  $v = 1$  e  $p > 2$  então { se regressão polinomial, então gera potências de x }
        para  $j \leftarrow 2$  até  $pm1$  faça
             $jp1 \leftarrow j + 1$ 
            para  $i \leftarrow 1$  até  $n$  faça  $x(i, jp1) \leftarrow x(i, 2)^j$ , fimpara
        fimpara
    fimse
    { equações normais }
    para  $i \leftarrow 1$  até  $p$  faça
        para  $j \leftarrow 1$  até  $p$  faça
             $Soma \leftarrow 0$ ; para  $k \leftarrow 1$  até  $n$  faça,  $Soma \leftarrow Soma + x(k, i) * x(k, j)$ , fimpara
             $Sxx(i, j) \leftarrow Soma$  { matriz dos coeficientes }
        fimpara
         $Soma \leftarrow 0$ ; para  $k \leftarrow 1$  até  $n$  faça,  $Soma \leftarrow Soma + x(k, i) * y(k)$ , fimpara
         $Sxy(i) \leftarrow Soma$  { vetor dos termos independentes }
    fimpara
     $[L, Det, CondErro] \leftarrow \text{Cholesky}(p, Sxx)$  { decomposição de Cholesky }
     $t \leftarrow \text{Substituições\_Sucessivas}(p, L, Sxy)$ 
    para  $i \leftarrow 1$  até  $p$  faça
        para  $j \leftarrow 1$  até  $i$  faça  $U(j, i) \leftarrow L(i, j)$ , fimpara; {  $U$  = transposta de  $L$  }
    fimpara
     $b \leftarrow \text{Substituições\_Retroativas}(p, U, t)$  { coeficientes }
     $D \leftarrow 0$ ;  $Sy2 \leftarrow 0$ 
    para  $i \leftarrow 1$  até  $n$  faça
         $u \leftarrow 0$ ; para  $j \leftarrow 1$  até  $p$  faça,  $u \leftarrow u + b(j) * x(i, j)$ , fimpara
         $d \leftarrow y(i) - u$ ;  $D \leftarrow D + d^2$ ;  $Sy2 \leftarrow Sy2 + y(i)^2$ 
    fimpara
     $r2 \leftarrow 1 - D / (Sy2 - Sxy(1)^2 / n)$  { coeficiente de determinação }
     $sigma2 \leftarrow D / (n - p)$  { variância residual }
fim algoritmo

```

Definição de modelo no algoritmo

- Modelos permitidos e correspondentes valores de v e p

$$u = b_0 + b_1x \rightsquigarrow v = 1, p = 2,$$

$$u = b_0 + b_1x_1 + b_2x_2 \rightsquigarrow v = 2, p = 3 \text{ e}$$

$$u = b_0 + b_1x + b_2x^2 \rightsquigarrow v = 1, p = 3.$$

- Modelos não permitidos *neste* algoritmo: $v > 1$ e $v + 1 \neq p$

$$u = b_0 + b_1x_1 + b_2x_2 + b_3x_2^2 \rightsquigarrow v = 2, p = 4.$$

Complexidade: regressão linear múltipla e polinomial via equações normais

| Operações | Complexidade |
|----------------|-----------------------|
| adições | $(p^2 + 3p + 2)n + 5$ |
| multiplicações | $(p^2 + 2p + 2)n + 1$ |
| divisões | 3 |

Regressão linear múltipla

| Operações | Complexidade |
|----------------|--|
| adições | $(p^2 + 2p + 4)n + p + 3$ |
| multiplicações | $(\frac{3}{2}p^2 + \frac{1}{2}p + 3)n + 1$ |
| divisões | 3 |

Regressão polinomial

- n : número de pontos.
- p : número de parâmetros.
- Potenciação contada como multiplicação.
- Desconsideradas operações para solução do sistema linear.

Exemplo: produto interno bruto dos Estados Unidos de 1947 a 1962

Exemplo 4 Ajustar os dados da tabela ao modelo

$$u = b_0 + b_1x_1 + b_2x_2,$$

usando o algoritmo

| i | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 |
|----------|------|------|------|------|------|------|------|------|------|------|------|------|------|------|------|------|
| x_{i1} | 60,3 | 61,1 | 60,2 | 61,2 | 63,2 | 63,6 | 65,0 | 63,8 | 66,0 | 67,9 | 68,2 | 66,5 | 68,7 | 69,6 | 69,3 | 70,6 |
| x_{i2} | 108 | 109 | 110 | 112 | 112 | 113 | 115 | 116 | 117 | 119 | 120 | 122 | 123 | 125 | 128 | 130 |
| y_i | 234 | 259 | 258 | 285 | 329 | 347 | 365 | 363 | 396 | 419 | 443 | 445 | 483 | 503 | 518 | 555 |

- x_1 : total de empregos (milhões),
- x_2 : população com 14 anos ou mais (milhões) e
- y : o PIB americano (bilhões de dólares).

Exemplo: produto interno bruto dos Estados Unidos de 1947 a 1962 cont.

```
% Os parametros de entrada
```

```
n = 16
```

```
v = 2
```

```
p = 3
```

```
x =
```

```
60.3000 108.0000
```

```
61.1000 109.0000
```

```
60.2000 110.0000
```

```
61.2000 112.0000
```

```
63.2000 112.0000
```

```
63.6000 113.0000
```

```
65.0000 115.0000
```

```
63.8000 116.0000
```

```
66.0000 117.0000
```

```
67.9000 119.0000
```

```
68.2000 120.0000
```

```
66.5000 122.0000
```

```
68.7000 123.0000
```

```
69.6000 125.0000
```

```
69.3000 128.0000
```

```
70.6000 130.0000
```

Exemplo: produto interno bruto dos Estados Unidos de 1947 a 1962 cont.

```

y =
234
259
258
285
329
347
365
363
396
419
443
445
483
503
518
555

% produzem os resultados
coeficientes de regressao
b(0) = -1.40740e+03
b(1) = 1.34511e+01
b(2) = 7.80271e+00
coeficiente de determinacao = 0.99267
variancia residual          = 8.37581e+01
condicao de erro              = 0

```

- Equação de quadrados mínimos $u = -1,40740 \times 10^3 + 1,34511 \times 10^1 x_1 + 7,80271 x_2$.
- Coeficiente de determinação $r^2 = 0,99267$.
- Variância residual $\sigma^2 = 83,7581$. \ll

Exemplo: raiz quadrada de x para $0,01 \leq x \leq 1$

Exemplo 5 A partir da tabela, que compila valores de \sqrt{x} para $0,01 \leq x \leq 1$, determinar o polinômio de quadrados mínimos de grau $g = 3$ utilizando o algoritmo

| i | x_i | $\sqrt{x_i}$ |
|-----|-------|--------------|
| 1 | 0,01 | 0,1000 |
| 2 | 0,10 | 0,3162 |
| 3 | 0,20 | 0,4472 |
| 4 | 0,30 | 0,5477 |
| 5 | 0,40 | 0,6325 |
| 6 | 0,50 | 0,7071 |
| 7 | 0,60 | 0,7746 |
| 8 | 0,70 | 0,8367 |
| 9 | 0,80 | 0,8944 |
| 10 | 0,90 | 0,9487 |
| 11 | 1,00 | 1,0000 |

Exemplo: raiz quadrada de x para $0,01 \leq x \leq 1$ cont.

```
% Os parametros de entrada
```

```
n = 11
```

```
v = 1
```

```
p = 4
```

```
x =
```

```
    0.0100
```

```
    0.1000
```

```
    0.2000
```

```
    0.3000
```

```
    0.4000
```

```
    0.5000
```

```
    0.6000
```

```
    0.7000
```

```
    0.8000
```

```
    0.9000
```

```
    1.0000
```

```
y =
```

```
    0.1000
```

```
    0.3162
```

```
    0.4472
```

```
    0.5477
```

```
    0.6325
```

```
    0.7071
```

```
    0.7746
```

```
    0.8367
```

```
    0.8944
```

```
    0.9487
```

```
    1.0000
```

Exemplo: raiz quadrada de x para $0,01 \leq x \leq 1$ cont.

```
% fornecem os resultados  
coeficientes de regressao  
b(0) = 1.01126e-01  
b(1) = 2.06854e+00  
b(2) = -2.17822e+00  
b(3) = 1.01865e+00  
coeficiente de determinacao = 0.99738  
variancia residual          = 2.96085e-04  
condicao de erro             = 0
```

- Polinômio de quadrados mínimos que aproxima \sqrt{x} para $0,01 \leq x \leq 1$

$$u = 1,01865x^3 - 2,17822x^2 + 2,06854x + 0,10113.$$

- Coeficiente de determinação $r^2 = 0,99738$.
- Variância residual $\sigma^2 = 2,96085 \times 10^{-4}$.


Exemplo: população do Brasil

Exemplo 6 Sejam os dados históricos dos censos demográficos do Brasil, de acordo com o Instituto Brasileiro de Geografia e Estatística (IBGE), apresentados na tabela

| Ano | Urbana | Rural |
|------|-------------|------------|
| 1940 | 12.880.182 | 28.356.133 |
| 1950 | 18.782.891 | 33.161.506 |
| 1960 | 31.303.034 | 38.767.423 |
| 1970 | 52.084.984 | 41.054.053 |
| 1980 | 80.436.409 | 38.566.297 |
| 1991 | 110.990.990 | 35.834.485 |
| 1996 | 123.076.831 | 33.993.332 |
| 2000 | 137.953.959 | 31.845.211 |

Deseja-se determinar qual o melhor grau para uma regressão polinomial.

Exemplo: diagrama de dispersão



- Ajuste urbana x ano não deve ser feito por um polinômio de grau 1.
- Polinômio de grau mais elevado.

Exemplo: escolha do grau do polinômio de quadrados mínimos


| g | r^2 | σ^2 |
|-----|---------|--------------------------|
| 1 | 0,96602 | $9,58219 \times 10^1$ |
| 2 | 0,99776 | $7,59261 \times 10^0$ |
| 3 | 0,99939 | $2,57228 \times 10^0$ |
| 4 | 0,99940 | $3,42930 \times 10^0$ |
| 5 | 0,99980 | $1,65615 \times 10^0$ |
| 6 | 0,99998 | $4,17203 \times 10^{-1}$ |

- g : grau do polinômio.
- r^2 : coeficiente de determinação.
- σ^2 : variância residual.
- Mudanças de variáveis para reduzir erros de arredondamento.
- Variável explicativa centrada de modo que $x = \text{Ano} - 1970$.
- Variável resposta dada em milhões de habitantes $y = \text{Urbana} \times 10^{-6}$.

Exemplo: escolha do grau do polinômio de quadrados mínimos cont.

| g | r^2 | σ^2 |
|-----|---------|--------------------------|
| 1 | 0,96602 | $9,58219 \times 10^1$ |
| 2 | 0,99776 | $7,59261 \times 10^0$ |
| 3 | 0,99939 | $2,57228 \times 10^0$ |
| 4 | 0,99940 | $3,42930 \times 10^0$ |
| 5 | 0,99980 | $1,65615 \times 10^0$ |
| 6 | 0,99998 | $4,17203 \times 10^{-1}$ |

- r^2 aumenta quando grau do polinômio de quadrados mínimos aumenta.
- σ^2 vai reduzindo até grau $g = 3$ e depois começa a oscilar.
- Grau escolhido para o ajuste polinomial.
- Evitar grau elevado.
- Ideal seria $n \gg p$.

Exemplo: polinômio de grau 3

urbana x ano

Transformações não lineares

- Modelos não lineares nos parâmetros transformados em modelos lineares.
- Substituição de variáveis por funções dessas variáveis.

$$y = ax^b \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x);$$

$$y = ab^x \rightsquigarrow \log_e(y) = \log_e(a) + \log_e(b)x;$$

$$y = ae^{bx} \rightsquigarrow \log_e(y) = \log_e(a) + bx;$$

$$y = e^{a+bx_1+cx_2} \rightsquigarrow \log_e(y) = a + bx_1 + cx_2;$$

$$y = ax_1^b x_2^c \rightsquigarrow \log_e(y) = \log_e(a) + b \log_e(x_1) + c \log_e(x_2);$$

$$y = \frac{1}{a + bx_1 + cx_2} \rightsquigarrow \frac{1}{y} = a + bx_1 + cx_2;$$

$$y = \frac{1}{1 + e^{a+bx_1+cx_2}} \rightsquigarrow \log_e \left(\frac{1}{y} - 1 \right) = a + bx_1 + cx_2.$$

Exemplo: cinética de reação química de primeira ordem

Exemplo 7 Em uma reação química de primeira ordem, a constante k de velocidade se relaciona com a concentração c e o tempo t pela expressão

$$c = c_0 e^{-kt},$$

onde c_0 é a concentração inicial de um reagente. Usando os dados da tabela e o algoritmo, calcular a constante de velocidade

| | | | | | |
|-----|------|------|------|------|------|
| i | 1 | 2 | 3 | 4 | 5 |
| t | 0,1 | 0,2 | 0,3 | 0,4 | 0,5 |
| c | 0,56 | 0,32 | 0,21 | 0,11 | 0,08 |

- t : tempo (segundos).
- c : concentração (M).
- Para tal,

$$c = c_0 e^{-kt} \leadsto \log_e(c) = \log_e(c_0) - kt.$$

Exemplo: cinética de reação química de primeira ordem cont.

```
% Os parametros de entrada
n = 5
v = 1
p = 2
t =
    0.1000
    0.2000
    0.3000
    0.4000
    0.5000
logc =
   -0.5798
   -1.1394
   -1.5606
   -2.2073
   -2.5257
% fornecem os resultados
b(0) = -1.14650e-01
b(1) = -4.95970e+00
coeficiente de determinacao = 0.99179
variancia residual          = 6.78379e-03
condicao de erro              = 0
```

- Equação de regressão: $\log_e(c) = -1,14650 \times 10^{-1} - 4,95970t \leadsto c_0 = e^{-1,14650 \times 10^{-1}} = 0,89168 \text{ M}.$
- $k = 4,95970 \text{ segundos}^{-1}.$
- Coeficiente de determinação $r^2 = 0,99179.$
- Variância residual $\sigma^2 = 6,78379 \times 10^{-3}.$

Malcondicionamento das equações normais

- Seja a equação de regressão polinomial

$$u = b_0 + b_1x + b_2x^2 + \dots + b_gx^g,$$

- parâmetros b_i calculados pelas equações normais.
- Dados (ano, urbana) da tabela com número de pontos $n = 8$.

Malcondicionamento das equações normais cont.

- g : grau do polinômio de regressão.
- r^2 : coeficiente de determinação.
- $\kappa_2(X^T X)$: número de condição em norma-2 da matriz dos coeficientes $X^T X$ das equações normais.

| g | r^2 | $\kappa_2(X^T X)$ |
|-----|---------|------------------------|
| 1 | 0,96602 | $4,514 \times 10^2$ |
| 2 | 0,99776 | $8,298 \times 10^5$ |
| 3 | 0,99939 | $6,498 \times 10^8$ |
| 4 | 0,99940 | $8,591 \times 10^{11}$ |
| 5 | 0,99980 | $7,418 \times 10^{14}$ |
| 6 | 0,99998 | $9,923 \times 10^{17}$ |
| 7 | 1,00000 | $6,753 \times 10^{20}$ |

- À medida que o grau g do polinômio aumenta, $r^2 \longrightarrow 1$.
- $\kappa_2(X^T X) \longrightarrow \infty$.
- Equações normais possuem matriz dos coeficientes malcondicionada.

Ajuste via decomposição em valores singulares

- Modelo de regressão linear múltipla na forma matricial

$$y = X\beta + \epsilon,$$

- y : vetor $(n \times 1)$ contendo as n observações da variável resposta,
- X : matriz $(n \times (p + 1))$, $n \geq p + 1$, contendo os n valores das p variáveis explicativas, além da primeira coluna de 1's relativa a β_0 ,
- β : vetor $((p + 1) \times 1)$ dos parâmetros a serem estimados e
- ϵ : vetor $(n \times 1)$ dos erros aleatórios.

Forma matricial

$$y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ 1 & x_{31} & x_{32} & \cdots & x_{3p} \\ 1 & x_{41} & x_{42} & \cdots & x_{4p} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} \quad \text{e} \quad \epsilon = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \epsilon_4 \\ \vdots \\ \epsilon_n \end{bmatrix}.$$

Cálculo dos parâmetros

- Método dos quadrados mínimos: minimizar a função

$$f(\beta) = \|y - X\beta\|_2^2 = (y - X\beta)^T (y - X\beta).$$

- Pelas regras de diferenciação matricial

$$\frac{\partial f(\beta)}{\partial \beta^T} = \frac{\partial f(\beta)}{\partial (y - X\beta)^T} \frac{\partial (y - X\beta)}{\partial \beta^T} = 2(y - X\beta)^T (-X) = -2(y - X\beta)^T X.$$

$$\frac{\partial f(\beta)}{\partial \beta} = -2X^T (y - X\beta).$$

- A função $f(\beta)$ apresenta um mínimo em $f(b)$, onde b é o ponto em que a derivada se anula

$$\frac{\partial f(b)}{\partial \beta} = -2X^T (y - Xb) = 0 \leadsto (X^T X)b = X^T y.$$

- Equações normais (8) na forma matricial.

Equações normais

- Segunda derivada

$$\frac{\partial(\partial f(\beta)/\partial\beta)}{\partial\beta^T} = \frac{\partial(-2X^T y + 2X^T X \beta)}{\partial\beta^T} = 2X^T X.$$

- Matriz $X^T X$ tem elementos reais, é não singular e definida positiva.
- O ponto $f(b)$ é, de fato, um mínimo de $f(\beta)$.
- O sistema $(X^T X)b = X^T y$ apresenta uma única solução.
- Equações normais formam um sistema malcondicionado.
- Processo alternativo para a estimativa de β que evita a formação da matriz $X^T X$.

Decomposição em valores singulares

- Decomposição em valores singulares consiste em fatorar uma matriz X ($n \times (p + 1)$), tal que

$$X = USV^T, \quad (12)$$

- U : matriz ortogonal ($n \times n$),
- V : matriz ortogonal ($(p + 1) \times (p + 1)$) e
- S : matriz diagonal ($n \times (p + 1)$) da forma

$$S = \begin{bmatrix} S_1 \\ 0 \end{bmatrix},$$

- S_1 : matriz quadrada diagonal de ordem $p + 1$.

Estimativa dos parâmetros

- Soma de quadrados residual

$$\|y - Xb\|_2^2 = \|y - USV^T b\|_2^2.$$

- Matriz ortogonal U^T não altera o valor da norma

$$\|y - Xb\|_2^2 = \|U^T y - U^T USV^T b\|_2^2 \rightsquigarrow \|y - Xb\|_2^2 = \|U^T y - SV^T b\|_2^2.$$

- Definindo

$$U^T y = a = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad (13)$$

- a_1 : vetor de tamanho $p + 1$ e a_2 : vetor de tamanho $n - p - 1$,

$$\tilde{b} = V^T b, \quad (14)$$

$$S\tilde{b} = \begin{bmatrix} S_1 \\ 0 \end{bmatrix} \tilde{b} = \begin{bmatrix} S_1 \tilde{b} \\ 0 \end{bmatrix},$$

$$\|y - Xb\|_2^2 = \left\| \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} - \begin{bmatrix} S_1 \tilde{b} \\ 0 \end{bmatrix} \right\|_2^2 \rightsquigarrow \|y - Xb\|_2^2 = \|a_1 - S_1 \tilde{b}\|_2^2 + \|a_2\|_2^2.$$

Estimativa dos parâmetros cont.

- Soma de quadrados residual será mínima quando \tilde{b} for a solução do sistema diagonal

$$S_1 \tilde{b} = a_1.$$

- Em vista de (14) e da ortogonalidade de V ,

$$\boxed{b = V \tilde{b}}. \quad (15)$$

- Soma de quadrados residual

$$D(b_0, b_1, \dots, b_p) = \|a_2\|_2^2 = a_2^T a_2.$$

- Valores preditos

$$u = Xb = USV^T b = US \tilde{b} = U \begin{bmatrix} S_1 \tilde{b} \\ 0 \end{bmatrix} \rightsquigarrow \boxed{u = U \begin{bmatrix} a_1 \\ 0 \end{bmatrix}}.$$

- Vetor desvio d

$$\boxed{d = U \begin{bmatrix} 0 \\ a_2 \end{bmatrix}}. \quad (16)$$

Exemplo: regressão linear via DVS

Exemplo 8 Calcular os parâmetros da reta de quadrados mínimos do Exemplo 1 utilizando a decomposição em valores singulares.

- Matriz X e vetor y

$$X = \begin{bmatrix} 1 & 0,3 \\ 1 & 2,7 \\ 1 & 4,5 \\ 1 & 5,9 \\ 1 & 7,8 \end{bmatrix} \quad \text{e} \quad y = \begin{bmatrix} 1,8 \\ 1,9 \\ 3,1 \\ 3,9 \\ 3,3 \end{bmatrix}.$$

Exemplo: regressão linear via DVS cont.

- Decomposição em valores singulares de X

$$U = \begin{bmatrix} 0,0414 & -0,8144 & -0,3904 & -0,3366 & -0,2635 \\ 0,2513 & -0,4559 & 0,1351 & 0,3940 & 0,7453 \\ 0,4087 & -0,1871 & 0,8174 & -0,2246 & -0,2816 \\ 0,5311 & 0,0219 & -0,2412 & 0,6611 & -0,4714 \\ 0,6972 & 0,3057 & -0,3209 & -0,4939 & 0,2712 \end{bmatrix},$$

$$S = \begin{bmatrix} 11,2679 & 0 \\ 0 & 1,1467 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \quad \text{e} \quad V = \begin{bmatrix} 0,1713 & -0,9852 \\ 0,9852 & 0,1713 \end{bmatrix}.$$

Exemplo: regressão linear via DVS cont.

- Por (13)

$$a = U^T y = \begin{bmatrix} 6,1910 \\ -1,8179 \\ 0,0883 \\ 0,3949 \\ -0,8747 \end{bmatrix}.$$

- Vetor \tilde{b} é a solução do sistema diagonal $S_1 \tilde{b} = a_1$

$$\begin{bmatrix} 11,2679 & 0 \\ 0 & 1,1467 \end{bmatrix} \begin{bmatrix} \tilde{b}_1 \\ \tilde{b}_2 \end{bmatrix} = \begin{bmatrix} 6,1910 \\ -1,8179 \end{bmatrix} \rightsquigarrow \tilde{b} = \begin{bmatrix} 0,5494 \\ -1,5853 \end{bmatrix}.$$

- Vetor b dos coeficientes é obtido por (15)

$$b = V \tilde{b} \rightsquigarrow b = \begin{bmatrix} 1,6559 \\ 0,2697 \end{bmatrix}.$$

- (ver exemplo).

Algoritmo: regressão linear múltipla e polinomial via DVS

Algoritmo Regressão_linear_DVS

```

{ Objetivo: Calcular parâmetros de quadrados mínimos de modelo linear múltiplo }
{ via decomposição em valores singulares }
parâmetros de entrada  $n, v, p, x, y$ 
{ número de pontos, número de variáveis, número de parâmetros, }
{ variáveis explicativas e variáveis respostas }
parâmetros de saída  $b, r2, sigma2, CondErro$ 
{ coef. de regressão, coef. de determinação, variância residual e condição de erro }
se  $v > 1$  e  $v + 1 \neq p$  então  $CondErro \leftarrow 1$ , abandone, fimse
 $CondErro \leftarrow 0$ ;  $vp1 \leftarrow v + 1$ ;  $pm1 \leftarrow p - 1$ 
para  $i \leftarrow 1$  até  $n$  faça { inclusão de uma coluna de 1's relativa à  $b_0$  }
    para  $j \leftarrow vp1$  até 2 passo  $-1$  faça  $x(i, j) \leftarrow x(i, j - 1)$  fimpara
     $x(i, 1) \leftarrow 1$ 
fimpara
se  $v = 1$  e  $p > 2$  então { se regressão polinomial, então gera potências de  $x$  }
    para  $j \leftarrow 2$  até  $pm1$  faça
         $jp1 \leftarrow j + 1$ 
        para  $i \leftarrow 1$  até  $n$  faça  $x(i, jp1) \leftarrow x(i, 2)^j$ , fimpara
    fimpara
fimse
 $[U, S, V] \leftarrow dvs(x)$  { chamada da rotina para decomposição em valores singulares }
para  $i \leftarrow 1$  até  $n$  faça { Cálculo do vetor auxiliar  $a = U^T y$  }
     $a(i) \leftarrow 0$ 
    para  $j \leftarrow 1$  até  $n$  faça  $a(i) \leftarrow a(i) + U(j, i) * y(j)$  fimpara
fimpara
para  $i \leftarrow 1$  até  $p$  faça { Cálculo do vetor dos coeficientes  $b = VS_1^{-1}a_1$  }
     $b(i) \leftarrow 0$ 
    para  $j \leftarrow 1$  até  $p$  faça
         $b(i) \leftarrow b(i) + V(i, j)/S(j, j) * a(j)$ 
    fimpara
fimpara
 $D \leftarrow 0$  { Cálculo do desvio }
para  $i \leftarrow p + 1$  até  $n$  faça,  $D \leftarrow D + a(i)^2$ , fimpara
 $Sy \leftarrow 0$ ;  $Sy2 \leftarrow 0$  { Cálculo dos somatórios auxiliares }
para  $i \leftarrow 1$  até  $n$  faça
     $Sy \leftarrow Sy + y(i)$ ;  $Sy2 \leftarrow Sy2 + y(i)^2$ 
fimpara
 $r2 \leftarrow 1 - D/(Sy2 - Sy^2/n)$  { coeficiente de determinação }
 $sigma2 \leftarrow D/(n - p)$  { variância residual }
fim algoritmo

```

||

Definição de modelo no algoritmo

- Modelos permitidos e correspondentes valores de v e p

$$u = b_0 + b_1x \rightsquigarrow v = 1, p = 2,$$

$$u = b_0 + b_1x_1 + b_2x_2 \rightsquigarrow v = 2, p = 3 \text{ e}$$

$$u = b_0 + b_1x + b_2x^2 \rightsquigarrow v = 1, p = 3.$$

- Modelos não permitidos *neste* algoritmo: $v > 1$ e $v + 1 \neq p$

$$u = b_0 + b_1x_1 + b_2x_2 + b_3x_2^2 \rightsquigarrow v = 2, p = 4.$$

Complexidade: regressão linear múltipla e polinomial via DVS

| Operações | Complexidade |
|----------------|------------------------------|
| adições | $n^2 + (p+2)n + p^2 - p + 5$ |
| multiplicações | $n^2 + 2n + p^2 - p + 1$ |
| divisões | $p^2 + 3$ |

Regressão linear múltipla

| Operações | Complexidade |
|----------------|--|
| adições | $n^2 + 4n + p^2 + 3$ |
| multiplicações | $n^2 + (\frac{1}{2}p^2 - \frac{3}{2}p + 3)n + p^2 - p + 1$ |
| divisões | $p^2 + 3$ |

Regressão polinomial

- n : número de pontos,
- p : número de parâmetros.
- Potenciação tratada como multiplicações.
- Desconsideradas operações para decomposição em valores singulares.

Exemplo: uso do algoritmo

Exemplo 9 Ajustar os dados do Exemplo 4 ao modelo $u = b_0 + b_1x_1 + b_2x_2$ usando o algoritmo.

```
% Os parametros de entrada
```

```
n = 16
```

```
v = 2
```

```
p = 3
```

```
x =
```

```
60.3000 108.0000
```

```
61.1000 109.0000
```

```
60.2000 110.0000
```

```
61.2000 112.0000
```

```
63.2000 112.0000
```

```
63.6000 113.0000
```

```
65.0000 115.0000
```

```
63.8000 116.0000
```

```
66.0000 117.0000
```

```
67.9000 119.0000
```

```
68.2000 120.0000
```

```
66.5000 122.0000
```

```
68.7000 123.0000
```

```
69.6000 125.0000
```

```
69.3000 128.0000
```

```
70.6000 130.0000
```

Exemplo: uso do algoritmo cont.

```
y =  
234  
259  
258  
285  
329  
347  
365  
363  
396  
419  
443  
445  
483  
503  
518  
555  
  
% produzem os resultados  
coeficientes de regressao  
b(0) = -1.40740e+03  
b(1) = 1.34511e+01  
b(2) = 7.80271e+00  
coeficiente de determinacao = 0.99267  
variancia residual          = 8.37581e+01  
condicao de erro             = 0
```

- Equação de quadrados mínimos: $u = -1,40740 \times 10^3 + 1,34511 \times 10^1 x_1 + 7,80271 x_2$,
- $r^2 = 0,99267$ e $\sigma^2 = 83,7581$ (ver exemplo).

Comparação dos métodos computacionais para RLM

- Equações normais: vantagens
 - Maior velocidade com que podem ser formadas e resolvidas.
 - Com o uso de *precisão dupla*, a diferença de exatidão dos dois métodos, poucas vezes, valerá a pena ser considerada.
- Equações normais: desvantagens
 - Número de condição da matriz $X^T X$ é o quadrado daquele da matriz X .
 - Difícil computar as matrizes $X^T X$ e $X^T y$, exatamente.
 - Perturbações feitas no problema básico podem ter consequências desastrosas.

Comparação dos métodos computacionais para RLM cont.

- Decomposição em valores singulares: vantagens
 - Superiores propriedades numéricas.
 - Grande quantidade de memória disponível a um custo relativamente baixo.
- Decomposição em valores singulares: desvantagens
 - Requerem maior quantidade de memória.
 - Complexidade computacional é maior que a da decomposição de Cholesky.

Diferença entre regressão e interpolação

- Polinômio interpolador de grau $n - 1$ construído de modo a passar por n pontos

$$P_{n-1}(x) = a_0 + a_1x + a_2x^2 + \dots + a_{n-1}x^{n-1}.$$

- Possui n coeficientes a_i , $i = 0, 1, \dots, n - 1$.
- Número de pontos utilizados para gerar o polinômio interpolador é igual ao número de coeficientes do polinômio.
- Polinômio de regressão de grau g , utilizando n pontos

$$U_g(x) = b_0 + b_1x + b_2x^2 + \dots + b_gx^g,$$

- tal que $g \leq n - 1$.
- Quando $g = n - 1$ o polinômio de regressão será idêntico ao polinômio interpolador.

Sistema linear e equações normais

- Polinômio interpolador de grau $g = 1$ que passa por $n = 2$ pontos (x_1, y_1) e (x_2, y_2) .
- Coeficientes obtidos pela solução do sistema linear

$$\begin{bmatrix} 1 & x_1 \\ 1 & x_2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

- Pré-multiplicando pela transposta da matriz dos coeficientes

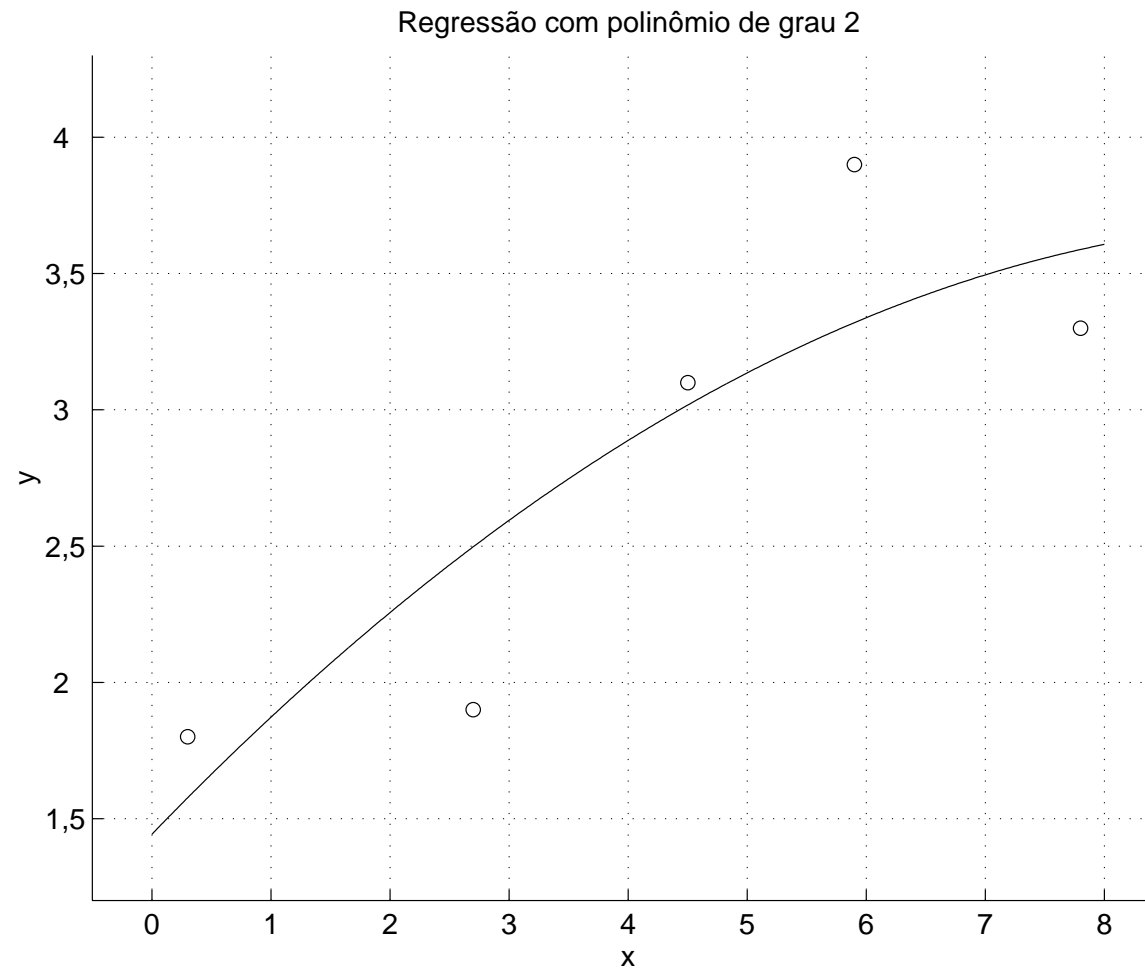
$$\begin{bmatrix} 1 & 1 \\ x_1 & x_2 \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ x_1 & x_2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \leadsto$$

$$\begin{bmatrix} 2 & x_1 + x_2 \\ x_1 + x_2 & x_1^2 + x_2^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} y_1 + y_2 \\ x_1 y_1 + x_2 y_2 \end{bmatrix}.$$

- Sistema linear idêntico às equações normais (1), para $n = 2$, utilizadas para calcular os parâmetros de uma regressão linear simples.

Regressão polinomial quadrática


- Dados da tabela.



$$n = 5 \text{ e } g = 2$$

Regressão idêntica à interpolação

- Polinômio passa por todos os pontos do diagrama de dispersão.



$$n = 5 \text{ e } g = n - 1 = 4$$

Uso da regressão e da interpolação

- Em termos de complexidade computacional, a interpolação é um processo mais simples que a regressão polinomial.
- A interpolação deve ser utilizada quando se necessita de um valor intermediário não constante de uma tabela.
- A regressão tem que ser utilizada quando se deseja estimar um parâmetro de um modelo semideterminístico e/ou prever um valor dado por esse modelo.
- A variância residual torna-se indefinida quando o número de parâmetros p do modelo for igual ao número de pontos n

$$\sigma^2 = \frac{D(b_0, b_1, b_2, \dots, b_p)}{n - p}.$$

Fim

Capítulo 4: Ajuste de curvas