Estrutura de Dados II (ED2)

Aula 20 - Radix Sort

Departamento de Informática (DI) Centro Tecnológico (CT) Universidade Federal do Espírito Santo (UFES)

(Material baseado nos slides do Professor Eduardo Zambon)

Introdução

- Até agora: abstrair os itens a serem ordenados com a definição de uma chave de ordenação e fazer comparação de chaves.
- Outro método: algoritmos de ordenação por radicais (radix sorting) trabalham diretamente com os "dígitos" das chaves, comparando-as em partes.
- Aula de hoje: apresentação das diferentes implementações de radix e dos algoritmos de ordenação radix sort.
- Objetivos: compreender as aplicações e o funcionamento do método de ordenação radix sort.

Referências

Chapter 10 - Radix Sorting

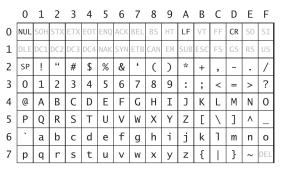
R. Sedgewick

Strings e Alfabetos

Tipo de dado char

Tipo de dado char em C:

- Tipicamente é um inteiro de 8 bits.
- Suporta a codificação ASCII de 7 bits.
- Pode representar no máximo 256 caracteres.



Hexadecimal to ASCII conversion table

Em Java: suporta Unicode 16 de bits.

Estrutura de Dados II (ED2) 4/4

Strings em C

Tipo de dado string em C:

- Linguagem não possui um tipo string explícito.
- Representado por um char*.
- Como arrays em C não carregam o seu próprio tamanho, strings são terminadas pelo caractere '\0'.
- Maior parte das operações implementadas em string.h.

Strings em C são mutáveis ⇒ Cuidado ao usar como chaves!

Manipulação de *strings* em C é muito propensa a erros. Exemplo:

```
int main() {
    char *s = "abc";
    s[0] = 'd'; // 'a' to 'd'
    // Segmentation fault... -_-
}
```

Novo tipo de dado String

Novo tipo String para evitar o inferno astral de ter de lidar com array de char terminado por ' $\$ \0'.

```
typedef struct {
   char *c;
   int len;
} String;
```

Vantagens:

- Pode ajudar na imutabilidade tornando a estrutura opaca.
- Obter o tamanho de uma string agora é constante.
- Elimina erros como do slide anterior já que todas as strings são alocadas no heap.

Novo tipo de dado String: operações

Comparar duas *strings* a partir do caractere na posição *d*.

```
int compare_from(String *s, String *t, int d) {
   int min = s->len < t->len ? s->len : t->len;
   for (int i = d; i < min; i++) {
      if (s->c[i] < t->c[i]) { return -1; }
      if (s->c[i] > t->c[i]) { return 1; }
   }
   return s->len - t->len;
}
```

Retorna:

- -1: se s < t.
- **1**: se s > t.
- 0: se s = t.

Atenção:

- Se s é prefixo de t, retorna < 0.
- Exemplo: she < shells.

Novo tipo de dado String: operações

Demais operações são triviais de implementar a partir de compare_from.

```
int compare(String *s, String *t) {
   return compare_from(s, t, 0);
}
```

Interface usual de Item também fica simples.

Comparando duas strings

Q: Quantas comparações de caracteres são necessárias para comparar duas strings de comprimento *W*?

р	r	e	f	е	t	С	h
0	1	2	3	4	5	6	7
р	r	e	f	i	Х	е	S

Tempo de execução: Proporcional ao comprimento do maior prefixo em comum.

- Proporcional a *W* no pior caso.
- Mas geralmente é sublinear em relação a W.

Alfabetos

String: Sequência de símbolos (caracteres, dígitos) sobre um alfabeto fixo.

Radix: Número R de símbolos de um alfabeto (tamanho).

name	R()	lgR()	characters
BINARY	2	1	01
OCTAL	8	3	01234567
DECIMAL	10	4	0123456789
HEXADECIMAL	16	4	0123456789ABCDEF
DNA	4	2	ACTG
LOWERCASE	26	5	abcdefghijklmnopqrstuvwxyz
UPPERCASE	26	5	ABCDEFGHIJKLMNOPQRSTUVWXYZ
PROTEIN	20	5	ACDEFGHIKLMNPQRSTVWY
BASE64	64	6	ABCDEFGHIJKLMNOPQRSTUVWXYZabcdef ghijklmnopqrstuvwxyz0123456789+/
ASCII	128	7	ASCII characters
EXTENDED_ASCII	256	8	extended ASCII characters
UNICODE16	65536	16	Unicode characters

Estrutura de Dados II (ED2) 10/41

Contagem Indexada por Chaves

Sumário: desempenho dos algoritmos de ordenação

Quantidade de operações feita por cada algoritmo.

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N²	1/4 N ²	1	~
mergesort	$N \lg N$	$N \lg N$	N	V
quicksort	1.39 N lg N *	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
	* probabilistic			

Limite inferior: pelo menos ∼ N lg N comparações.

- Q: É possível fazer melhor? (Apesar do limite inferior.)
- A: Sim, evitando comparação de chaves.
- Comparação de chaves: decisões binárias.
- Comparação por radix R: decisões têm R resultados.

Estrutura de Dados II (ED2)

Key-indexed counting: suposições sobre as chaves

Suposição: chaves são inteiros entre $0 \in R - 1$.

Implicação: podemos usar as chaves como índices de *array*.

Aplicações:

- Ordenar uma string pela primeira letra.
- Ordenar empregados por seção.
- Ordenar números de telefone por código de área.
- Sub-rotina em um algoritmo de ordenação (em breve).

input	ection	sorted result		
		(by section)		
Anderson	2	Harris	1	
Brown	3	Martin	1	
Davis	3	Moore	1	
Garcia	4	Anderson	2	
Harris	1	Martinez	2	
Jackson	3	Miller	2	
Johnson	4	Robinson	2	
Jones	3	White	2	
Martin	1	Brown	3	
Martinez	2	Davis	3	
Miller	2	Jackson	3	
Moore	1	Jones	3	
Robinson	2	Taylor	3	
Smith	4	Williams	3	
Taylor	3	Garcia	4	
Thomas	4	Johnson	4	
Thompson	4	Smith	4	
White	2	Thomas	4	
Williams	3	Thompson	4	
Wilson	4	Wilson	4	
	†			
	keys are			
sma	ıll integers			

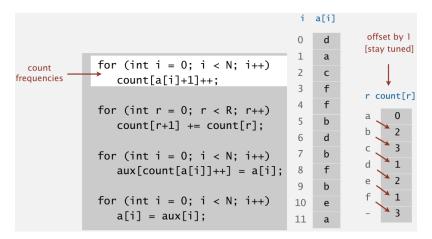
Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

- Vetor auxiliar 1: count[] de tamanho R+1.
- Vetor auxiliar 2: aux [] de tamanho N.
- No exemplo abaixo: R = 6.

```
a[i]
for (int i = 0; i < N; i++)
   count[a[i]+1]++;
for (int r = 0; r < R; r++)
   count[r+1] += count[r]:
for (int i = 0; i < N; i++)
                                             f for 5
   aux[count[a[i]]++] = a[i]
for (int i = 0; i < N; i++)
                               9
                                   b
   a[i] = aux[i];
                              10
```

Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

■ P.1: Contar a frequência de cada valor usando count [].



Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

P.2: Computar a frequência acumulada.

```
a[i]
              for (int i = 0; i < N; i++)
                 count[a[i]+1]++:
                                                           a
                                                                  r count[r]
                                                           c
              for (int r = 0; r < R; r++)
compute
                 count[r+1] += count[r];
cumulates
              for (int i = 0; i < N; i++)
                 aux[count[a[i]]++] = a[i];
                                                           f
              for (int i = 0; i < N; i++)
                                                           b
                                                      9
                                                                       12
                 a[i] = aux[i];
                                                      10
                                                           e
                                                      11
                                                           а
                                                       6 keys < d, 8 keys < e
                                                      so d's go in a[6] and a[7]
```

Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

■ P.3: Mover os itens para um vetor auxiliar.

```
a[i]
                                                                       aux[i]
                                                                         a
        for (int i = 0; i < N; i++)
                                                а
                                                                         а
            count[a[i]+1]++:
                                                       r count[r]
                                                C
                                                                         b
                                                                         b
        for (int r = 0; r < R; r++)
                                                                         b
            count[r+1] += count[r]:
                                                b
                                                                         C
                                                d
                                                                         d
        for (int i = 0; i < N; i++)
move
            aux[count[a[i]]++] = a[i];
                                                b
                                                                         d
items
                                                            12
        for (int i = 0; i < N; i++)
                                                b
                                                            12
            a[i] = aux[i];
                                                                    10
                                           10
                                                е
                                           11
                                                                    11
                                                a
```

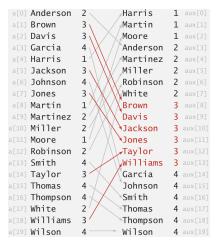
Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

■ P.4: Copiar de volta para o vetor original (se necessário).

```
a[i]
                                                                      aux[i]
                                                                       a
        for (int i = 0; i < N; i++)
                                                а
                                                                       a
            count[a[i]+1]++;
                                                       r count[r]
                                                b
                                                                       h
                                                                       b
                                                            2
        for (int r = 0; r < R; r++)
                                                                       b
                                                       b
            count[r+1] += count[r];
                                                C
                                                            6
                                                                       c
                                                                       d
        for (int i = 0; i < N; i++)
                                                       d
            aux[count[a[i]]++] = a[i]:
                                                            9
                                                                       d
                                                       е
                                                            12
                                                                       e
        for (int i = 0; i < N; i++)
                                                                       f
                                                            12
copy
            a[i] = aux[i];
back
                                           10
                                                                   10
                                           11
                                                                   11
```

Key-indexed counting: análise

- Tempo de execução é ~ 3N + R.
- **E**spaço extra é $\sim N + R$.
- Método é estável.



Key-indexed counting: implementação em C

Versão final generalizada para uso em outros sorts:

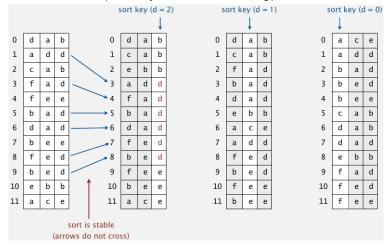
■ Faz a contagem sobre o d-ésimo caractere.

```
void count_sort(String* *a, String* *aux, int *count,
                int lo, int hi, int d, int R) {
    clear count array(count, R);
    for (int i = lo; i <= hi; i++) { // Count frequencies.</pre>
        count[char at(a[i], d) + 2]++;
    for (int r = 0; r < R+1; r++) { // Compute cumulates.
        count[r+1] += count[r];
    for (int i = lo; i <= hi; i++) { // Move items.
        int p = count[char at(a[i], d) + 1]++;
        aux[p] = a[i];
    for (int i = lo; i <= hi; i++) { // Copy back.
        a[i] = aux[i - lo];
```

LSD Radix Sort

LSD (Least Significant Digit) radix sort

- Considera os caracteres da direita para a esquerda.
- Faz uma ordenação estável usando o d-ésimo caractere como chave (usa key-indexed counting).



LSD radix sort: correção

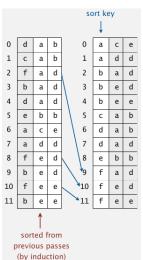
Proposição: LSD ordena *strings* de tamanho fixo de forma ascendente.

Prova (por indução em i):

Depois da passada *i*, as *strings* estão ordenadas pelos <u>últimos</u> *i* caracteres.

- Duas strings com chave de ordenação diferentes: key-indexed sort as coloca na ordem relativa adequada.
- Duas strings com chave de ordenação iguais: estabilidade as mantém ordem relativa adequada.

LSD sort é estável porque key-indexed sort é estável.



LSD radix sort: implementação em C

```
void sort(String* *a, int N) {
    int W = 3; // Change accordingly to input size.
    int R = 256;
    String* *aux = create_str_array(N);
    int* count = create_count_array(R);
    for (int d = W-1; d >= 0; d--) {
        count_sort(a, aux, count, 0, N-1, d, R);
    free (count):
    free (aux);
```

Sumário: desempenho dos algoritmos de ordenação

Quantidade de operações feita por cada algoritmo.

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N ²	1/4 N ²	1	V
mergesort	N lg N	N lg N	N	~
quicksort	1.39 N lg N*	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
LSD sort †	W(3N+R)	W(3N+R)	N + R	~
† fixed-length W keys	* probabilistic			

Q: E se as strings não são todas do mesmo tamanho?

Estrutura de Dados II (ED2) 25/41

Como fazer um censo nos anos de 1900?

Censo de 1880 (nos EUA):

- 1500 pessoas processando manualmente os dados.
- Processamento levou 7 anos.

Herman Hollerith: Desenvolveu uma máquina para automatizar a contagem e ordenação.

- Usou cartões perfurados para registrar os dados.
- Máguina ordena uma coluna por vez (em 12 pilhas).





Hollerith tabulating machine and sorter

punch card (12 holes per column)

Censo de 1890: Completado em 1 ano.

Estrutura de Dados II (ED2) 26/41

Como ficar rico ordenando nos anos de 1900?

Cartões perfurados (1900 a 1950):

- Também eram úteis para contabilidade, inventário e outros processos de negócios.
- Principal mídia para entrada, armazenamento e processamento de dados.

A empresa de Hollerith depois se fundiu com mais 3 outras para formar a Computing Tabulating Recording Corporation (CTRC). Empresa foi renomeada em 1924.



LSD radix sort: um momento na história (1960s)







punched cards



card reader



mainframe



line printer

To sort a card deck

- start on right column
- put cards into hopper
- machine distributes into bins
- pick up cards (stable)
- move left one column
- continue until sorted



card sorter

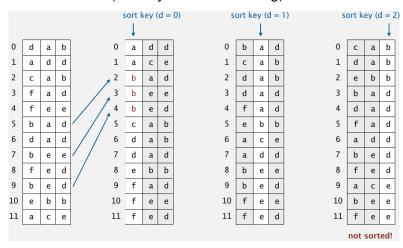


Lysergic Acid Diethylamide (Lucy in the Sky with Diamonds)

MSD Radix Sort

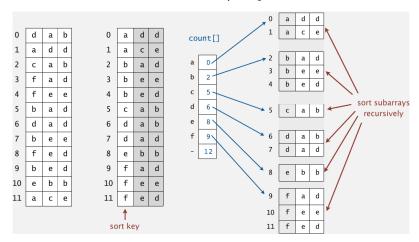
LSD invertido

- Considera os caracteres da esquerda para a direita.
- Faz uma ordenação estável usando o *d*-ésimo caractere como chave (usa *key-indexed counting*).



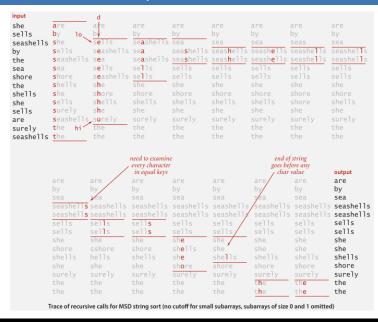
MSD (Most Significant Digit) radix sort

- Particiona o array em R partes segundo o primeiro caractere, usando key-indexed counting.
- Ordena recursivamente cada partição.



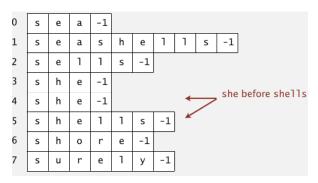
Estrutura de Dados II (ED2)

MSD radix sort: exemplo



Strings de tamanho variável

Considerar que as *strings* têm um caractere extra no final menor que todos os outros.



Implementação em C é bem simples.

```
#define char_at(S, D) ((D < S->len) ? S->c[D] : -1)
```

MSD radix sort: implementação em C

Caractere "-1" fica na posição 1 de count.

```
for (int i = lo; i <= hi; i++) // Count frequencies.
    count[char_at(a[i], d) + 2]++;</pre>
```

Código abaixo reutiliza aux mas não count. Necessário porque chamadas recursivas modificariam o vetor count.

```
#define R 256
void rec_MSD(String* *a, String* *aux, int lo, int hi, int d) {
  if (hi <= lo) return:</pre>
  int* count = create count array(R);
  count_sort(a, aux, count, lo, hi, d, R); // Key-indexed count.
  for (int r = 1; r < R+1; r++) // Sort R arrays recursively.</pre>
    rec MSD(a, aux, lo + count[r], lo + count[r+1] - 1, d+1);
  free (count):
void sort(String* *a, int N) {
  String* *aux = create_str_array(N);
 rec MSD(a, aux, 0, N-1, 0);
  free (aux):
```

MSD radix sort: problemas de desempenho

Observação 1: algoritmo muito lento para sub-arrays pequenos.

- Cada chamada de função precisa do seu próprio array count.
- Tabela ASCII: array tem tamanho 256.
- Unicode: array tem tamanho 65,536!
- Mesmo para ordenar um sub-array de tamanho 2 é necessário alocar o array count todo: não sabemos o conteúdo a ser ordenado.

Observação 2: temos um grande número de *sub-arrays* pequenos por causa da recursão.

Cut-off para insertion sort

Solução: *cut-off* para *insertion sort* para *sub-arrays* pequenos.

Insertion sort, mas começando no *d*-ésimo caractere.

```
void insert_sort_from(Item *a, int lo, int hi, int d) {
   for (int i = lo; i <= hi; i++) {
      for (int j = i; j > lo && less_from(a[j], a[j-1], d); j--) {
         exch(a[j], a[j-1]);
      }
   }
}
```

Relembrando: função $less_from()$ compara as *strings* a partir do d-ésimo caractere.

Modificar a função recursiva como de costume.

```
void rec_MSD(String* *a, String* *aux, int lo, int hi, int d) {
   if (hi <= lo + CUTOFF - 1) {
      insert_sort_from(a, lo, hi, d);
      return;
   }</pre>
```

MSD radix sort: desempenho

- MSD examina o mínimo de caracteres necessários para ordenar as chaves.
- Número de caracteres examinados depende das chaves.
- Pode ser sub-linear (no melhor caso) em relação ao tamanho da entrada!

Random (sublinear)	Non-random with duplicates (nearly linear)	Worst case (linear)			
1E I0402	are	1DNB377			
1H YL490	by	1DNB377			
1R 0Z572	sea	1DNB377			
2HXE734	seashells	1DNB377			
2I YE230	seashells	1DNB377			
2X0R846	sells	1DNB377			
3CDB573	sells	1DNB377			
3CVP720	she	1DNB377			
3I GJ319	she	1DNB377			
3KNA382	shells	1DNB377			
3TAV879	shore	1DNB377			
4CQP781	surely	1DNB377			
4Q GI284	the	1DNB377			
4Y HV229	the	1DNB377			
Characters examined by MSD string sort					

Estrutura de Dados II (ED2)

Sumário: desempenho dos algoritmos de ordenação

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N ²	1/4 N ²	1	V
mergesort	$N \lg N$	$N \lg N$	N	V
quicksort	1.39 N lg N*	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
LSD sort †	W (3N + R)	W(3N+R)	N + R	~
MSD sort ‡	W(3N+R)	$N \log_R N$	N + D R 1	~
* probabilistic † fixed-length W keys		D = function-call stack depth (length of longest prefix match)		

Estrutura de Dados II (ED2)

‡ average-length W keys

MSD radix sort: análise empírica

Casos de teste:

- dict: dicionário com as palavras embaralhadas contendo 370,099 palavras distintas.
- book: versão em texto simples do livro Guerra e Paz, de Liev Tolstói. Contém 562,639 palavras (com repetições).

Algorithm	dict	book	
System qsort	0.409	0.559	
Standard quick sort	0.430	0.499	
Key-counting sort (Only	works with	strings	of len = 1)
LSD	0.967	0.601	
MSD1: standard	1.327	0.309	
MSD2: cut-off ins-sort	0.229	0.202	

Note como cut-off para insertion sort faz diferença no MSD!

MSD radix sort vs. quick sort

Desvantagens do MSD radix sort:

- Espaço extra para aux[] e count[].
- Loop interno tem muitas instruções.
- Acessa a memória "aleatoriamente" (ruim para cache).

Desvantagens do quick sort.

- Número de comparações de strings não é linear.
- Precisa examinar várias vezes os mesmos caracteres quando há prefixos iguais longos.

Objetivo:

- Combinar as vantagens de MSD e quick sort.
- Vantagem do MSD: examina cada caractere uma vez.
- Vantagem do quicksort: loop interno simples, faz bom uso do cache.

Estrutura de Dados II (ED2) 4

American flag sort

Otimização 0: cut-off para insertion sort.

Otimização 1: Substituir recursão por uma pilha explícita.

- Empilha os sub-arrays a serem ordenados na pilha.
 (Igual quick sort não-recursivo.)
- Feito isso, basta um único array count [].

Otimização 3: Faça o particionamento R-way in place.

- Elimina o array aux[].
- Sacrifica estabilidade.

